

# 严格评估下 CRISPR-Cas9 sgRNA 编辑效率序列信号的跨数据集复现边界与第 18 位效应的外部模型验证

(作者信息待补)

2026 年 9 月 19 日

## 摘要

基因编辑效率的机器学习预测已取得大量进展，但绝大多数报告只给出单一数据集上的精度，既未检验该精度能否在**独立数据集**上复现，也未检验模型归因所指认的序列位置能否被**独立第三方模型**证实。更关键的是，若训练与测试之间存在同源序列，跨条件性能会被系统性高估，而这类问题在只报告精度时不可见。本文以“多数据集复现 → 多模型外部验证 → 可解释分析 → 反事实扰动 → 生物学假设”为证据链，在一个经过完整质量审计、序列级无泄漏的计算平台上回答三个问题：(1) 序列可预测性在不同数据集间是否复现？(2) 多模型归因指认的序列位置能否被独立外部模型证实？(3) 该位置能否转化为可证伪的最小扰动假设？

本文使用三个相互独立的公开数据集——DeepCRISPR (4 个细胞系、16 749 条 23 nt 靶序列、1 344 次受控训练运行)、Hiranniramol (1 309 条) 与 Labuhn (417 条)——在同一套特征构造、同一批 7 个模型配置 (Linear、XGBoost、MLP、双分支 CNN 卷积核  $k \in \{3, 5, 7\}$ 、Transformer) 与同一条身份类划分约束下训练，并引入独立第三方模型 CRISPRon 作为外部验证器。全文严格区分**六层证据**：预测证据 (E1)、关联证据 (E2)、归因证据 (E3)、反事实证据 (E4)、实验证据 (E5) 与因果证据 (E6)；本文不含任何 E5 证据，因此不产生任何 E6 层面的断言。

主要结果如下。**第一，序列可预测性是数据集依赖的，不可假定普遍复现。**在留出测试集上，DeepCRISPR 单细胞系划分的 7 个配置中位  $R^2$  仅为 0.067–0.120；Hiranniramol 在完全相同的流程下达到 0.345–0.489 (Transformer 最高， $R^2 = 0.489$ , Pearson = 0.709)；而 Labuhn 的 7 个配置全部为负 (−0.725 至 −0.050)，模型预测坍塌为近常数。与官方划分无关的全数据 5 折交叉验证复核给出同向结论：Hiranniramol 的 CV  $R^2 = +0.389$  远高于其标签置换零分布 ( $-0.467 \pm 0.038$ ,  $n = 200$ )，而 Labuhn 的 CV  $R^2 = -0.144$  仅比自身零分布 ( $-0.287 \pm 0.050$ ) 高 0.14。因此我们把“序列信号存在”限定为**数据集特异性结论**，而非普适结论。**第二，跨细胞系迁移失败。**真实留一细胞系 (LOCO) 划分下，7 个配置的中位  $R^2$  全部落在 −0.027 至 +0.010，与均值基线不可区分。**第三，表观环境通道未提供可检出的增量预测信息。**CTCF、DNase、H3K4me3、RRBS 的主效应  $|\overline{\Delta R^2}|$  为  $3.2 \times 10^{-4}$ – $1.5 \times 10^{-3}$ ，比预设效应门 0.01 低 1–2 个数量级，跨模型 bootstrap 区间全部跨 0，区组析因方差分析主效应  $p = 0.975$ – $0.9996$ ，四者均判为 Inconclusive。

**第四，也是本文证据链的收敛点：一个可由外部模型独立证实的位置效应。**四个非模型类 (XGBoost、CNN、MLP、Transformer) 的归因峰值在 65.6%–100% 的上下文中落在 PAM 邻近窗口 (17–20)，其单模型平均谱峰值分别位于第 18、20、18、19 位；线性模型例外 (21.9%，峰值在第 1 位)，因此把线性模型纳入等权平均后，跨模型平均谱峰值是第 1 位而非第 18 位 (E3)。我们按**预先登记、不接触任何突变侧信息**的规则从 DeepCRISPR 测试集中选出 8

条第 18 位为 C 的代表性野生型序列，仅替换第 18 位一个碱基 (C→A)，并用独立第三方模型 CRISPRon 评分 (E4，外部模型验证)。结果显示：本文 7 个模型与 CRISPRon 的扰动响应在 8 条序列中的 **7 条上方向一致** (Pearson  $r = 0.629$ , Spearman  $\rho = 0.476$ )，唯一分歧序列被保留而非剔除；CRISPRon 侧 7/8 条给出负向变化 (平均  $\Delta = -12.43$ )。进一步对全部 23 个位点做饱和 in-silico 突变 (552 条替换记录，其中 48 条破坏 PAM 被排除)，第 18 位的 C→A 平均变化为  $-12.425$ ，而其余位置平均仅  $+0.144$ ；按平均  $|\Delta|$  计第 18 位在 21 个可比位置中**排名第 1**，且逐序列看有 7/8 条排在第 1。与之独立的观测性关联 (E2) 方向一致但具细胞背景依赖：第 18 位 C 减 A 的实测平均效率差为 HCT116  $+0.090$ 、HeLa  $+0.092$ 、HL60  $+0.027$ 、HEK293T  $-0.015$ 。

综上，本文的贡献不是报告一个高精度预测器——事实上我们报告了该预测能力在不同数据集间的**复现失败**——而是在严格区分证据层级的前提下，把”序列可预测性有多可信”与”哪个序列位置值得实验检验”这两个问题分开回答：前者是数据集依赖的，后者在位置层级上获得了跨五类模型、跨独立外部模型与跨观测性关联的三方支持，因而可以转化为一个预登记可证伪的最小扰动假设 (第 18 位单碱基替换)。本文不含任何湿实验数据，全部结论的最高证据层级为 E4，不构成因果断言。作为方法学附带的整改结果，我们还纠正了自身历史批次中跨细胞系同源序列污染带来的性能高估 (*mixed* 中位  $R^2$  由  $0.118$  降至  $0.073$ ，LOCO 由  $+0.036$  降至  $-0.008$ )，并如实报告该下降。

**关键词：** CRISPR-Cas9；sgRNA 编辑效率；跨数据集复现；外部模型验证；可解释机器学习；反事实扰动；序列归因；六层证据；生物学假设生成

## 1 引言

### 1.1 从”预测精度”到”可复现性”：一个被系统性忽略的问题

CRISPR-Cas9 通过可编程的 RNA-DNA 配对实现定点切割，sgRNA 的活性差异使”实验前筛选高效位点”成为核心计算问题 [Jinek et al., 2012, Cong et al., 2013, Shalem et al., 2014]。早期方法依赖序列组成与位置偏好的人工规则 [Doench et al., 2014, Moreno-Mateos et al., 2015]，随后被数据驱动模型取代：DeepBind 与 Basset 证明卷积网络可从序列实验数据中学习局部序列特异性 [Alipanahi et al., 2015, Kelley et al., 2016]；DeepCRISPR 进一步把序列与细胞特异性表观遗传信息 (CTCF、DNase、H3K4me3、RRBS) 纳入统一编码 [Chuai et al., 2018]；Rule Set 2 等方法也大幅提升了预测能力 [Doench et al., 2016]；此后一系列深度模型与数据整合模型被用于 sgRNA 活性预测 [Kim et al., 2018, 2019, Xiang et al., 2021]。

然而，绝大多数此类工作报告的性能数字来自**单一数据集、单一次划分**，且很少检验该数字能否在**独立数据集**上复现。这一缺口有实质后果：如果序列可预测性本身是数据集依赖的，那么”某模型达到  $R^2 = 0.7$ ”这类陈述就不能被读作关于 sgRNA 设计的一般性结论，而只是关于某个特定 library、特定细胞系与特定测定方式的结论。独立基准测试已经显示，深度预测器在严格不重叠的评估集上泛化能力会明显下降 [Zhang et al., 2023, Konstantakos et al., 2022, Yuan et al., 2025]，但”下降了多少、在哪些数据集上仍然成立”很少被系统量化。

本文把这一问题作为第一研究问题：**在完全相同的特征构造、模型配置与评估脚本下，序列可预测性在三个相互独立的公开数据集上是否复现？**我们刻意不挑选数据集，而是同时报告两个外部数据集的结果——其中一个复现成功，另一个完全复现失败。

## 1.2 评估协议决定结论：身份类与泄漏审计

性能估计的可信度取决于划分是否把“同一身份”的样本完全隔离。同一 sgRNA 序列会在多个细胞系中被重复测量；若划分按记录随机分配，则同一条序列（及其反向互补）可同时出现在训练与测试两侧，模型在测试集上部分复现了已见序列的标签，跨条件性能因此被系统性高估。此类“记忆被计入泛化”的失效模式在机器学习基准中并不罕见 [Kaufman et al., 2012, Kapoor and Narayanan, 2023]，生物医学机器学习社区已提出系统性的排查问题清单 [Bernett et al., 2024]，基因组机器学习中亦有系统性讨论 [Whalen et al., 2022]，其中“跨细胞类型预测”被明确指为易受该问题影响的一类任务 [Schreiber et al., 2020]。

由此产生三个必须在方法层面显式回答的问题：（1）**身份类如何定义**（序列本身？其反向互补？同一 locus？）；（2）**划分是否真的按身份类隔离**，且这一点能否在运行期自证而非事后声称；（3）**训练所用划分与分析所用划分是否一致**。在以分组/嵌套结构为特征的数据上，随机交叉验证会违反独立性假设并给出乐观偏置的估计 [Roberts et al., 2017]，生物学序列基准因此主张构造与训练集序列独立的测试集 [Petti and Eddy, 2022]，并形成要求显式声明划分与相似性的报告规范 [Walsh et al., 2021]。本文在 §2.5 给出可执行约束：以  $\min(\text{seq}, \text{revcomp}(\text{seq}))$  为身份类整体划分、在划分函数内部计算重叠并在非零时直接中止、把划分摘要与数据/代码/环境指纹写入每个运行的元数据。

## 1.3 归因不是证据：为什么需要独立外部模型

预测能力的提升并不意味着研究者能够理解模型依据哪些因素作出判断。不同模型类别的可解释性各有边界：线性模型给出方向与统计量但表达受限；树模型可建模非线性与交互 [Chen and Guestrin, 2016]，但 Gain/Weight/Cover 没有方向；深度模型的内部表示难以直接解释。SHAP 与 Integrated Gradients 分别从 Shapley 值与公理化归因出发提供了通用解释工具 [Lundberg and Lee, 2017, Sundararajan et al., 2017]，Transformer 则以自注意力建模跨位置关系 [Vaswani et al., 2017]。

问题在于：即使在同一个数据集上多个模型类给出一致归因，这也不能排除它们**共同依赖了数据中的同一混杂结构** [Novakovsky et al., 2023]。因此本文引入一条更强的检验路径：把归因指认的序列位置转化为一个**最小扰动**，再用一个**完全独立、由他人训练、使用不同输入编码与不同标签尺度**的第三方模型去预测同一扰动的方向。如果两个系统的扰动响应方向一致，则“该位置对模型预测有实质影响”这一陈述就不再只依赖本文自己的模型族。这是本文的第二研究问题。我们使用 CRISPRon 作为外部模型 [Xiang et al., 2021]，因为它在输入构造（30 nt 窗口与 CRISPRoff 能量项）、训练数据与输出尺度上均与本文平台不同。

## 1.4 六层证据：把“能说什么”写死在方法里

综合上述，本文在方法层面固定一套**六层证据分类**（表 14），并要求全文每一处结论标注其所属层：

- **E1 预测证据**：模型能否在未见样本上预测标签（ $R^2$ 、Pearson、Spearman）；
- **E2 关联证据**：标签与某可观测属性是否同变（分组实测效率差、相关系数）；

- **E3 归因证据**：模型输出依赖输入的哪些部分（系数、SHAP、IG、注意力）；
- **E4 反事实证据**：模型在输入被扰动后如何响应（in-silico 突变，含外部模型）；
- **E5 实验证据**：真实实验中扰动是否改变结果——**本文不含任何 E5 证据**；
- **E6 因果证据**：干预是否在该体系中导致效应——**本文不作任何 E6 断言**。

该分类的作用是约束表达：低层证据不能升级为高层证据，高层证据的存在也不能反推低层证据。具体而言， $\Delta R^2$  只表示增量预测价值（E1）；attribution 幅值只表示模型依赖强度（E3），自身不构成统计显著性；in-silico 突变与外部模型评分只刻画模型行为（E4）；观测性碱基关联（E2）即使与 E3/E4 方向一致，也只说明模型捕捉到了数据中的同一统计结构，不构成因果。

## 1.5 研究问题与贡献

本文以一条五段式证据链组织全部工作：**多数据集复现** → **多模型外部验证** → **可解释分析** → **反事实扰动** → **生物学假设**。前四段各自产生不同层级的证据（E1–E4），第五段是把这些证据收敛为一个可证伪命题的结果；任何一段都不跨越到 E5/E6。

平台围绕三个研究问题组织分析：

**RQ1（复现）**：序列可预测性在独立数据集间是否复现？ (§3.2) **RQ2（外部证实）**：多模型归因指认的序列位置能否被独立外部模型证实？ (§3.9) **RQ3（可证伪化）**：该位置能否转化为预登记、可证伪的最小扰动假设？ (§3.10、§3.12)

据此，本文的贡献定位为：

1. **一个跨三个独立数据集的受控复现实验**：在同一套特征构造、7 个模型配置、身份类划分与评估脚本下，报告 DeepCRISPR ( $R^2$  中位 0.067–0.120)、Hiranniramol (0.345–0.489) 与 Labuhn (全部为负,  $-0.725$  至  $-0.050$ ) 三个截然不同的结果，并用与官方划分无关的全数据交叉验证独立复核。**我们不把复现失败隐藏在补充材料中，而是把它作为第一结论。**
2. **一条外部模型验证链**：用独立第三方模型 CRISPRon 对本文归因指认的最小扰动做方向性检验，得到 7/8 的跨模型方向一致性，并保留唯一分歧样本。
3. **一套可审计的泄漏防控与数据质量流程**，以及在结果层面自证的实例：1344/1344 次运行的序列与反向互补重叠均为 0，划分摘要逐条复核一致。
4. **对自身历史批次泄漏的整改与如实报告**：早期批次按记录随机划分导致跨条件性能被高估，整改并完整重跑后 *mixed* 中位  $R^2$  由 0.118 降至 0.073、LOCO 由  $+0.036$  降至  $-0.008$ ，而单细胞系划分基本不变 ( $0.070 \rightarrow 0.081$ )。
5. **在位置层级与区域层级分别报告多模型归因**，保留模型间分歧而非平均掉；并报告两个阴性结果（环境通道无增量预测证据、跨细胞系迁移失败）。
6. **一个最小扰动候选与预登记的实验设计**（第 18 位单碱基替换），明确其证据层级为 E4、其验证路径为 E5。

本文不主张平台在预测精度上优于已有方法；恰恰相反，本文的核心发现之一是这类精度在数据集之间不可移植。

## 2 材料与方法

### 2.1 平台总体架构

平台按“科学引擎生成结果文件、报告层消费结果文件”的原则组织（图 1）。数据质量控制、特征工程、受控训练、归因与统计模块之间只通过结构化结果文件（CSV/JSON/Markdown）交换信息，因此训练可在本地或高性能计算环境中独立执行，下游分析离线运行。平台在分析阶段不修改任何训练产物：所有统计量与图表均由只读结果文件重新计算，随机种子、阈值与分析方案统一记录在配置文件中。本文全部数值由本仓库脚本从结果文件重新计算生成 (§2.14)，不手工填写。

### 2.2 数据集：一个主数据集与两个外部复现数据集

**主数据集 (DeepCRISPR)**。公开数据集 [Chuai et al., 2018]，含四个细胞系 (HCT116、HEK293T、HeLa、HL60)，每条记录包含 23 nt 靶序列、实测归一化编辑效率与四条逐位点表观遗传轨道 (CTCF、DNase、H3K4me3、RRBS 的二值可及性)。过滤非法碱基后共 16 749 条序列进入分析（表 2）。

**外部复现数据集**。为使“序列可预测性能否复现”成为可检验命题而非断言，我们引入两个来源、规模与实验体系均不同的公开数据集：Hiranniramol (1 309 条，单细胞系，标签为 Edit Efficiency，原始为百分制) [Hiranniramol et al., 2020] 与 Labuhn (417 条，标签为 KO\_reporter\_assay，原始已在  $[0, 1]$ ) [Labuhn et al., 2018]。两者的 sgRNA 均为 20 nt；适配器在原始表的相关列中定位该 20 nt，取“sgRNA + 后 3 nt PAM”构成 23 nt 靶序列，并只保留 PAM 为 GG 的记录 (§2.3)。两个数据集**没有表观遗传通道**，因此只能参与序列通道实验。

**跨数据集可比性的保障**。三个数据集共用同一套特征构造代码、同一批 7 个模型配置、同一条身份类划分约束与同一份评估脚本；唯一的差异是输入数据与通道数。这是本文跨数据集比较能够成立的前提，也是我们刻意避免“每个数据集换一套流程”的原因。

数据编号经核对：DeepCRISPR 全部记录的第 22、23 位均为 G，即 PAM 位于第 21–23 位 (NGG)，第 1–20 位为 protospacer。本文据此定义 PAM 邻近种子区为第 17–20 位、种子核心区为第 9–16 位、PAM 远端区为第 1–8 位。表位编号全文采用 **1-based**（第 18 位即位置索引 18）；张量与数组下标为 0-based，两者在代码中显式换算。

### 2.3 特征表示与跨数据集一致性

序列采用  $23 \times 4$  one-hot 编码。对 DeepCRISPR，四条表观遗传轨道以逐位点二值形式拼接，形成  $23 \times 8$  输入张量（184 维展平特征）；对两个外部数据集，环境通道数为 0，输入为  $23 \times 4$ （92 维展平特征）。跨数据集比较在**序列通道**上进行，保证两者的模型容量与输入语义一致。

环境组合通过通道掩码实现：给定环境因子集合  $S$ ，未启用的表观通道整体置零，张量维度保持不变，从而保证不同环境组合之间的差异只反映信息可用性。平台对 0 通道情形做短路处理：环境组合集合退化为单元素 {sequence}，组合名称为 sequence，不产生任何  $\Delta R^2$  边。Linear Regression 按统计惯例剔除  $\_T$  参照列（DeepCRISPR 184→161；外部数据集 92→69），其余模型使用完整展平维。

**重复测量处理.** 同一 23 nt 序列若对应多条记录 (重复测量), 按**均值**合并为一条, 以保持”一条序列一个标签”的身份类语义; 若合并导致的丢弃比例超过 20%, 适配器直接报错而非静默截断。

## 2.4 受控实验设计

每个 (模型配置  $\times$  环境组合) 在三种划分下训练, 三者均满足同一条**身份不可跨划分**约束 (见 §2.5):

- *single*: 单细胞系内 70%/15%/15%, 种子 42, 四个细胞系各一次 (448 次运行);
- *all* (真实留一细胞系, LOCO): 以某一细胞系整体作为测试集; 训练池由其余三个细胞系构成, **先剔除与留出系共享身份类 (序列或其反向互补) 的全部序列**, 再按 85%/15% 划分训练/验证 (448 次运行, 每个细胞系 112 次);
- *mixed*: 四细胞系混合后按身份类整体划分 70%/15%/15%, 种子 42–45 (448 次运行)。

7 个模型配置  $\times$  16 个环境组合  $\times$  12 个 (划分, 种子) 设定共产生 **1 344 次训练运行**, 全部在留出测试集上评估 ( $R^2$ 、RMSE、MAE、Pearson、Spearman)。由于 LOCO 的训练池按留出系不同而缩减 ( $n_{\text{train}}$  由 1 453 至 12 313 不等), 跨细胞系比较需同时报告训练集规模。

两个外部复现数据集各自运行同一批 7 个模型配置的 *single* 划分 (单细胞系内 70%/15%/15%), 不涉及环境组合, 共  $2 \times 7 = 14$  次运行。

**性能口径的一致性约定.** 每个 run 目录同时包含 `*_metrics.json` (**测试集**) 与 `*_validation_metrics.json` (验证集)。全文所有性能数字**一律取测试集口径**; 验证集口径仅用于最优 epoch 选择, 不进入任何结论。该约定在代码层面强制 (§2.14), 以避免两个口径混用。

## 2.5 数据质量、划分身份与泄漏防控

本文把”结果是否可信”作为先于模型性能报告的对象, 因此在方法层面固定四项约束, 并在结果中逐项给出审计数字 (表 1)。

**(1) 身份类与 group-aware 划分.** 本研究的泛化声明是 *sequence-level*: 模型应面向”未见过的 sgRNA 序列”。因此划分的最小不可分单位不是单条记录, 而是**身份类**

$$\text{id}(s) = \min(s, \text{revcomp}(s)), \quad (1)$$

即序列本身与其反向互补被视为同一身份。该定义与”构造与训练集序列独立的测试集”这一基准设计原则一致 [Petti and Eddy, 2022, Roberts et al., 2017]。反向互补被纳入同一类, 是因为二者靶向同一 locus 的两条链、标签来自同一靶点, 属于近重复观测; 在本数据集中此类配对确实存在 (跨细胞系如 HCT116 与 rc(HeLa) 共 30 对)。三种划分均按身份类整体分配, 同一身份类的全部记录只能进入 train、valid 或 test 之一。LOCO 分支额外要求训练池不含留出系的任何身份类。

**(2) 划分运行期自证.** 划分函数在返回前计算 train/valid/test 之间的原始序列重叠、反向互补重叠与 locus 重叠, 写入每个 run 的元数据; 若在 group-aware 模式下出现任何序列级重叠

则直接抛错中止，而不是产出泄漏结果。同时计算划分摘要 `split_digest` (train/valid/test 序列集合与样本数的 SHA-256 前 16 位)，用于事后核验”训练所用划分等于分析所用划分”。

**(3) 全批一致性与数值发散隔离。**每个 run 记录数据指纹、代码指纹、环境指纹与设备解析结果。数值发散 ( $|R^2| \geq 10$ ，源于线性模型在共线性设计矩阵上的病态求解) **不被删除**，而是在全部统计中隔离并单列计数。按测试集口径，1344 次运行中有 **20 次** 发散，全部来自 Linear Regression (*single* 6、*mixed* 6、*all* 8)；验证集口径下为 33 次，该数字不作为性能统计依据。

**(4) 泄漏排查协议与历史整改披露。**除自动断言外，审计按生物学机器学习泄漏排查问题清单逐项核对 [Bennett et al., 2024, Kapoor and Narayanan, 2023]。项目早期批次 (`batch_20260909_full`) 的划分按记录随机分配，且 LOCO 分支未剔除留出系同源序列；审计发现该批次中同一 sgRNA 序列可同时出现在训练与测试两侧 (*mixed* 划分中约 36% 的测试记录命中训练序列，LOCO 约 33%)，并使 LOCO 分支退化为逐位等同于 *single*。整改后按上述身份类重新划分并**完整重跑全部 1344 次实验** (批次 `ultimate_run`)，本文全部数字仅来自该批次；旧批次结果仅用于泄漏前后对照 (§3.4)，不进入任何结论。

## 2.6 模型与归因方法

平台使用五类模型 (7 个配置)：Linear Regression (线性主效应与统计检验)、XGBoost (非线性与交互 [Chen and Guestrin, 2016])、MLP (一般非线性组合)、双分支 CNN (序列分支 + 环境分支，序列卷积核  $k \in \{3, 5, 7\}$ ，用于建模不同宽度的局部序列上下文) 与 Transformer (跨位置交互 [Vaswani et al., 2017])。归因方法分别为：回归系数 (含 SE、 $t$ 、 $p$ 、FDR)、TreeSHAP [Lundberg and Lee, 2017, Lundberg et al., 2020]、Integrated Gradients (IG) [Sundararajan et al., 2017]、CNN 的 IG 与 In Silico Mutagenesis (ISM，逐位点核苷酸替换效应) [Nair et al., 2022, Zhou and Troyanskaya, 2015] 以及注意力权重。

平台强制语义边界： $\Delta R^2$  表示增量预测价值 (E1)；attribution 表示模型依赖强度 (E3)；SNR 表示归因稳健性； $p$ /FDR 仅来自具备明确零假设的统计检验 (配对 bootstrap、置换检验、析因方差分析与富集检验)。**注意力权重、SNR 与树内部重要性均不作为统计显著性**，注意力在本研究中仅作支持性信息，不用于候选模式提取。

需要额外说明本文使用的两类归因幅值，因为它们在文献中同名但定义不同：(i) 归因谱为该模型在 23 个位置上归一化后的归因占比之和，用于跨位置比较；(ii) *SNR* 采用混合形式  $\text{mean}(|\varphi|)/\text{std}(\varphi)$ ，而非  $\text{mean}(|\varphi|)/\text{std}(|\varphi|)$ ，仅用于在 Importance- $\Delta R^2$  辅助视图中做特征级标注，**不是检验统计量，也不参与证据等级判定**。

## 2.7 环境因素析因分析

对每个 (划分，细胞系，模型，种子) 分组定义配对增量

$$\Delta R_{e|S}^2 = R^2(S \cup \{e\}) - R^2(S), \quad (2)$$

其中  $S$  为基线环境集合， $e$  为新增环境因子，二者来自同一测试集。平台枚举 16 节点 factorial lattice 的全部单因素边 (同一组合可有多父节点)，节点记录  $R^2$ /RMSE/MAE/Pearson/Spearman 均值，边记录配对的  $\Delta R^2$ 、 $\Delta \text{MAE}$ 、 $\Delta \text{RMSE}$ 。主效应为对全部不含  $e$  的背景  $S$  的条件增量均值；交互效应为  $I(a, b) = \Delta(a | S_0 \cup \{b\}) - \Delta(a | S_0)$  在背景  $S_0$  (不含  $a, b$ ) 与种子上的平均。

## 2.8 统计方法

(1) **逐样本配对 bootstrap**: 对每条 lattice 边, 使用两侧模型在同一测试样本上的逐样本预测, 以  $B = 2000$  次重采样计算  $\Delta R^2$  的百分位置信区间 ( $\alpha = 0.05$ , 种子 2024); 样本数不等或预测文件缺失时标记为不可用。(2) **Model-Level Bootstrap Interval ( $n = 7$  model configurations)**: 对每个环境因子, 先计算各模型稳定主效应的均值 (模型等权), 再对该模型向量重采样 ( $B = 2000$ , seed 2024), 保证置信区间与点估计同口径。自助法重采样单元是模型配置而非单条 *guide*, 所得区间用于刻画 *effect* 在不同模型归纳偏置之间的一致性 (*cross-model robustness*), 而不是 *guide* 总体的抽样不确定性; 7 个模型共享同一份数据、标签、预处理与划分, 不可视为独立生物学重复。(3) **置换检验**: 对逐样本损失差与条件增量使用符号翻转 (sign-flip) 随机化检验,  $B = 1000$ 。(4) **多重检验**: BH-FDR 仅在同一个科学问题族内校正 (环境边、环境主效应、环境交互、析因 ANOVA、motif 富集各自成族)。(5) **区组析因方差分析**: 以  $R^2$  为响应变量, 四个环境因子为二水平因子, 模型、细胞系与划分作为区组因子, 采用基于设计矩阵的 Type-II 边际平方和  $F$  检验 (含成对交互项), 效应量报告  $\eta^2 = SS_{\text{term}}/SS_{\text{total}}$ ; 数据不足时返回不可用而非近似值。

阈值集中于统一配置文件: 参与证据等级判定的为最小绝对增益门  $\min |\Delta R^2| = 0.01$ 、覆盖度  $\geq 2$  个模型、方向一致率  $\geq 0.80$ 、置换 FDR  $< 0.05$ 、bootstrap 迭代数  $\geq 200$  与数值发散阈值 10.0; SNR 阶梯 (2.5/1.8/1.2)、最小效应量 0.005 与 FDR 阶梯 (0.001/0.01) 仅用于 Importance- $\Delta R^2$  辅助视图的特征级标注, **不参与证据等级判定**。完整清单见补充表 15。

(6) **与官方划分无关的独立信号复核**. 由于三个数据集的规模与标签分布不同, 仅比较同一批划分下的测试  $R^2$  不足以区分“数据本身无信号”与“该划分恰好困难”。为此我们对每个外部数据集额外做一次与官方划分完全无关的复核: 在**全部**样本上用同一套 92 维特征跑 5 折交叉验证 (Ridge,  $\alpha = 1.0$ , 标准化后), 得到折外预测的  $R^2$ ; 再用同一组折外预测、以 200 次标签置换构造零分布 (种子 0)。判据是 CV  $R^2$  相对零分布的位置, 而不是  $R^2$  的绝对值。

## 2.9 序列模式发现

序列模式发现按“归因  $\rightarrow$  片段  $\rightarrow$  聚类  $\rightarrow$  共识  $\rightarrow$  富集  $\rightarrow$  稳定性”执行。首先计算归因特异性: 位置  $p$  上碱基  $b$  的得分定义为其归因值减去该位置其它碱基归因均值, 以避免原始幅值普遍偏高; 随后按位置级分位阈值 (0.90) 与局部连续性要求 ( $\geq 2$  个连续位置超过 0.75 分位) 提取窗口 (长度 4–12 nt, 每样本最多 2 个)。seqlet 按 CNN 核配置与方法分别聚类 (与簇共识一致率  $\geq 0.90$  则合并, 聚类后再对相似共识  $\geq 0.95$  二次合并)。共识以 IUPAC 退化码、人类可读形式与正则形式同时保存。候选模式需满足最小支持度 (seqlet  $\geq 30$ 、样本  $\geq 20$ )。由于当前批次的归因输出为无符号幅值, 模式方向不取自 attribution 符号, 而由“携带该模式的序列 vs 背景序列”的实测效率对比给出, 并在结果中标注来源。富集分析为可选步骤: 以效率上三分位序列为前景、全部可用序列为背景, 采用 Fisher 精确检验并在 motif 富集族内 BH-FDR 校正; 未执行富集时不报告任何  $p$  值。跨配置一致性通过比较不同 CNN 核与不同细胞系间共识序列的相似性 ( $\geq 0.80$ ) 评估; 当前批次没有 Transformer IG 产物, 因此 CNN 与 Transformer 的跨模型模式比较标记为不可用。

## 2.10 外部模型验证：独立第三方模型 CRISPRon

为检验“本文模型族对某序列位置的依赖是否只是本数据集的产物”，我们引入**独立第三方模型** CRISPRon [Xiang et al., 2021] 作为外部验证器。选择 CRISPRon 的理由是它与本文平台在三个方面完全独立：(i) 训练数据不同；(ii) 输入编码不同——它使用 30 nt 窗口（4 nt 前导 + 20 nt protospacer + 1 nt + GG + 3 nt 后随）并额外拼接一个由 CRISPRoff 计算的能&量特征  $\Delta G$ ，而本文输入为 23 nt one-hot；(iii) 输出尺度不同——CRISPRon 输出 0–100 的复合评分，而本文输出归一化效率。

**输入映射.** 项目位点  $k$  (1-based,  $k \in [1, 23]$ ) 映射到 30 nt 序列的下标  $\text{PRE\_GUIDE} + k - 1$  ( $\text{PRE\_GUIDE}=4$ )。由于本文 23 nt 序列以 PAM 的 GG 起始于第 21 位，而 CRISPRon 的窗口在 PAM 前多取 1 nt，故需从参考基因组补齐侧翼。我们使用 hg19（经核对，本文数据与 hg38 有 6/6 不匹配，与 hg19 一致），并按链向取窗：对正链取  $[\text{start}_0 - 4, \text{end} + 3)$ ，对负链取  $[\text{start}_0 - 3, \text{end} + 4)$ ，再做反向互补。映射正确性由 `describe_mapping()` 逐条输出并纳入审计。

**扰动与 QC.** 扰动仅在项目序列内部进行 (`mutate_project_sequence`)，侧翼与 PAM 保持逐位不变。每条记录在打分前后执行完整 QC：只改了目标位点、PAM 未变、侧翼一致、方向保持、WT 与突变体各恰好命中 1 个预期靶点；CRISPRon 会在正负两条链上扫描 30-mer，因此额外靶点被显式计数（本批 552 条替换记录中 3 条出现额外命中，均记录在案）。破坏 PAM 的替换（48 条）无法被 CRISPRon 识别，**被排除而非强行打分**。

**环境与黄金测试.** CRISPRon 运行于独立虚拟环境 (Python 3.10.20)。除官方安装步骤外，唯一偏离是 PyPI 版 ViennaRNA 不提供 `RNAfold` 可执行文件，我们提供同版本 Python API 的等价 shim。等价性不做口头声明，而由官方自带黄金测试证明：`bin/test.sh` 输出 `TEST ok`，且生成的 `30mers.fa`、`23mers.fa`、`CRISPRparams.tsv` 与 `crispron.csv` 与官方 `test/outdir.original/` 中的对应文件**逐字节相同**（SHA-256 相等）。完整安装记录、校验和与许可说明见 §7 与仓库文档。

## 2.11 反事实扰动协议与预登记的野生型选择规则

反事实扰动 (E4) 的价值取决于**扰动对象是否被事先确定**：若先看突变结果再挑选序列，方向一致性就失去意义。因此本文把野生型 (WT) 选择规则**预先写死在脚本中** (`SELECTION_RULE_VERSION = wt-pos18-representative-v1`)，并在选择结束时以 `assert_no_mutant_information_used()` 断言“用于选择的字段集合”中不含任何突变侧字段（实际断言结果为空列表）。

规则要点：(1) 候选池为 *single* 划分的**测试集** (group-aware, 种子 42, 四个细胞系)，不从训练集挑选；(2) 过滤条件为第 18 位为 C、PAM 为 NGG、按 canonical identity  $\min(\text{seq}, \text{revcomp}(\text{seq}))$  去重、标签有限且  $\in [0, 1]$ 、剔除各细胞系标签  $[P_1, P_{99}]$  之外的极端值、且必须能构造出合法 30-mer；(3) 在每个细胞系内部按标签三分位分层为 low/medium/high；(4) 每层取**最接近该层中位数**的一条（刻意不取极值）；(5) 最终 8 条 = low 2 + medium 2 + high 2 + 2 条“GC 明显不同但正常”的序列，附加约束为每个细胞系  $\leq 2$  条、两两序列错配  $\geq 4$  nt。C18A 序列只在选择**完成之后**由 `build_mutant()` 生成，脚本内不存在任何 CRISPRon 调用。

据此得到 8 条 WT (§3.10)。随后执行两个层级的扰动：

- **定向扰动**：对 8 条 WT 各做一次 C→A（第 18 位），用 CRISPRon 打分并与本文 7 个模型的符号化 ISM 预测变化做方向一致性比较；

- **饱和扰动**: 对 8 条 WT 的 23 个位点、每个位点全部 3 种非野生型替换做穷举 in-silico 突变 ( $8 \times 23 \times 3 = 552$  条), 用 CRISPRon 打分并计算每个位置的平均  $|\Delta|$ , 从而在**不预先指定位置**的前提下检验第 18 位是否确实突出。

## 2.12 证据整合与amp;六层证据

证据等级 (Evidence Tier) 由唯一的权威实现 (`analysis/evidence/integration.py` 的 `classify_evidence_tier`) 按四条门槛与两个正交”强度门”给出: (i) **覆盖度**: 与模型等权均值同号的模型数  $\geq 2$  (不足 2 且无强证据记为 Inconclusive, 等于 1 且有强证据记为 Tier 3); (ii) **方向一致率**: 多数方向占比  $\geq 0.80$  (仅 Tier 1 要求); (iii) **置信区间**: 跨模型 bootstrap 置信区间跨 0 记为 Inconclusive (迭代数  $< 200$  的置信区间不参与判定); (iv) **cell-line 上下文**: 跨细胞系标签为 Context-conflicting 时一票否决。两个强度门分工不同: *effect* 门要求因子级效应 ( $M$  个模型配置的等权平均  $\Delta R^2$ ) 满足  $|\overline{\Delta R^2}| \geq 0.01$  (**最小绝对预测增益门, 不是统计显著性阈值**); 统计门为该因子在置换检验中的 *Minimal Edge-level FDR across Tested Contexts*  $< 0.05$ , 它是 *existence-oriented* 证据 (回答”该因子是否至少在一个被测试上下文中出现统计证据”), 因跨上下文取最小而存在 extremum selection, **不是 factor-level FDR**。统计证据不能单独把因子提升为 **Tier 1**: Tier 1 要求覆盖度与方向一致率达标、稳健性条件成立、且 *effect* 门通过; 统计门用于支持已有 effect 证据、排除缺乏统计支持的候选, 并参与 Tier 2 与注释。由此: 满足覆盖度 + 一致率 + effect 门记为 Tier 1; 仅满足覆盖度记为 Tier 2; 单个模型且有支持性证据记为 Tier 3。

需要强调: \*\* 证据等级是对已有计算证据的收敛性、覆盖度与稳健性的综合评级, 不代表生物学效应强度, 也不是效应量排名、显著性刻度或因果结论 \*\*; 在增量效应很小的情形下 ( $|\Delta R^2| < 0.01$ ), 高等级仅表示多个模型对该小效应的判断一致 (或该小效应在置换检验下稳定), 不能解读为”强影响因素”。此外, edge-level 证据刻画的是”在给定背景下加入某因子”这一具体增量效应, 而析因 ANOVA 刻画的是因子及其交互在整个析因设计中的全局变异 (响应变量为留出  $R^2$ , 区组为模型/细胞系/划分); 两者回答不同问题, 因此”ANOVA 未检出显著主效应”与”某因子达到 Tier 1”并不矛盾, 不应互相引用为对方的证据或反例。

**与证据等级的层级关系**. 证据等级评的是 E1 层面的因子收敛性; 它不能跨越到 E2–E6。因此第 18 位位置效应不通过 `classify_evidence_tier` 评级, 而是在**六层证据**框架内逐层报告 (表 14): 它出现在 E3 (多模型归因的位置层级)、E4 (本文模型的符号化 ISM 与外部模型 CRISPRon 的扰动响应)、E2 (实测标签的分组关联) 三个**互相独立**的层级上, 但不含任何 **E5 证据**, 因此不构成 E6 因果结论。

## 2.13 候选优先级与amp;最小扰动方案

在证据整合之后, 平台按预先设定的标准从既有结果中筛选用于后续实验验证的候选: (i) 多模型支持; (ii) 效应具有方向; (iii) 至少在一个人细胞系中效应较大; (iv) 统计或稳健性证据非空白; (v) 可设计最小扰动 (单碱基替换或短序列破坏); (vi) 不依赖复杂环境操控。候选及其依据、最小扰动方案与优先级记录于表 13。平台在此环节只做**候选优先级排序**, 不进行序列从头生成, 也不声称任何候选已被实验验证。

## 2.14 软件与可复现性

平台实现为 Python 模块化分析引擎，训练与分析相互独立。所有统计量均由只读结果文件重新计算；分析方案、任务执行状态 (`analysis_status.json`) 与每个任务的产物路径同时落盘；报告层与图形界面只读取这些文件。

本文跨数据集复现所需的全部数字由 `analysis/paper_numbers.py` 从三个批次的结果文件与 `data/processed/` 重新计算，落盘为 `results/paper_rewrite/authoritative_numbers.json`；本文新增的表格由 `analysis/reporting/paper_rewrite/build_rewrite_tables.py` 从该 JSON 与 CRISPRon 产物生成；数据质量表由 `deploy/hpc/verify_hpc_rerun.py` 与 `analysis/reporting/paper/ma` 生成。所有表格不手工填写。

性能口径的一致性在代码层面强制：验收脚本 `verify_hpc_rerun.py` 显式排除 `*_validation_metrics.js` 只读取测试集指标，以避免同一批 run 在两个口径间漂移（该缺陷曾在早期版本中使数值发散计数被误记为 33，实际测试集口径为 20）。跨数据集与外部验证的接口、输入构造与 QC 均在 `analysis/external_validation/` 与 `analysis/candidates/` 中实现，并有对应的科学测试用例。

# 3 结果

本节按证据链组织：先确认结果本身可信 (§3.1)，再回答 RQ1——序列可预测性能否在独立数据集间复现 (§3.2–§3.4)，然后给出边界（跨细胞系迁移、环境通道） (§3.3、§3.5)，再回答 RQ2——多模型归因指认了什么、该指认能否被独立外部模型证实 (§3.6–§3.9)，最后回答 RQ3——该位置能否转化为可证伪的最小扰动假设 (§3.10、§3.11、§3.12)。每一小节的标题后标注其证据层级 (E1–E6，定义见表 14)。

## 3.1 数据质量与泄漏防控审计 (E1 前置条件)


**问题与方法.** 在报告任何模型性能之前，先确认结果本身是否可信：实验矩阵是否完整、划分是否自洽、是否存在跨划分的同源序列、全批是否运行在同一数据/代码/环境之上。

**观察 (直接计算观测).** 权威批次 `ultimate_run` 的审计结果见表 1：1344 次运行全部产出且可解析 (*single/all/mixed* 各 448)，无 0 字节文件、无 JSON 解析失败；**1344 个 run 的 `train`∩`test` 序列重叠与反向互补重叠全部为 0**；1344 次运行的划分摘要 `split_digest` 与本地按同一代码重算的结果**逐条一致 (0 处不一致)**，即训练实际使用的划分与分析阶段使用的划分完全相同；数据指纹、代码指纹、环境指纹各只有一种取值，960 个神经网络 run 全部在 GPU 上执行，无 CPU/GPU 混跑。

**口径修正的披露.** 每个 run 同时产出测试集与验证集两个指标文件。本文的全部性能数字统一取**测试集口径**。审计脚本早期版本未显式区分两者（依赖 `glob` 返回顺序），导致数值发散计数被记为 33；修正为显式排除验证集文件后，**测试集口径的发散 run 为 20 次 (全部为 Linear Regression: *single* 6、*mixed* 6、*all* 8)**，而 33 是验证集口径的数字。本文报告 20，并把该差异记录为口径约定的一部分 (§2.4)。

**统计证据.** 上述为覆盖度与一致性的穷举核对 (1344/1344)，不涉及抽样，因此不报告 *p* 值。

Platform: prediction → interpretation → evidence → hypothesis



**图 1:** 平台的科学发现流程。实验测量数据依次经过质量控制、特征配置、受控多模型实验、模型特异性归因、统计与析因分析、序列模式发现、细胞背景比较、外部模型验证与跨模型证据整合，最终形成候选因素与可检验假设。各阶段之间以结构化结果文件为接口，分析阶段只读训练产物。

**解释（假设）与边界.** 该审计能够支持的科学陈述是：在本文定义的身份类（序列及其反向互补）下，训练集与测试集之间不存在序列级污染，且划分在训练与分析两侧完全一致。它不能支持”数据中不存在任何形式的泄漏”这一更强陈述：同一 locus 的不同序列、同一细胞系内的批次效应、以及公共数据集本身的组成偏差均不在该检查的覆盖范围内。

**数据集与实验空间.** 三个数据集的组成与划分规模见表 2。DeepCRISPR 过滤后保留 16 749 条 23 nt 序列（HCT116 4 239、HEK293T 2 333、HeLa 8 101、HL60 2 076），四个细胞系的平均归一化效率接近（0.232–0.257）。全部记录的第 22、23 位均为 G，据此确定 PAM 位于第 21–23 位。DeepCRISPR 的设计空间为 7 个模型配置  $\times$  16 个环境组合  $\times$  12 个（划分，种子）设定 = 1 344 次运行；两个外部复现数据集各运行 7 个模型配置的 *single* 划分。

**表 1:** 数据质量与泄漏防控审计（ultimate\_run）。全部数值由 `deploy/hpc/verify_hpc_rerun.py` 生成，逐 run 明细见 `results/tables/audit/ultimate_run_verify_runs.csv`。该审计用于确认结果可信度，先于任何模型性能与科学结论报告。

| 审计项                          | 结果                        | 含义                                     |
|------------------------------|---------------------------|----------------------------------------|
| 计划实验数                        | 1344                      | 实验矩阵完整（single/all/mixed 各 448/448/448） |
| 可解析 run                      | 1344                      | 每个 run 均含 info 与测试集 metrics；无 0 字节文件   |
| 划分一致性 (split_digest)         | 12 组 / 1344 次复核 0 不一致     | 训练所用划分 == 分析所用划分                       |
| 序列重叠 (train $\cap$ test)     | 1344/1344 为 0             | min(seq, revcomp) 身份类不跨划分              |
| 反向互补重叠                       | 1344/1344 为 0             | L5 近重复不跨划分                             |
| 数据指纹                         | 1 组                       | 全批使用同一份数据                              |
| 代码指纹                         | 1 组                       | 全批使用同一版代码                              |
| 环境指纹                         | 1 组                       | 全批同一数值栈                                |
| GPU 运行数（神经网络模型）              | 960                       | 无 CPU/GPU 混跑                           |
| 数值发散 run ( $ R^2  \geq 10$ ) | 20（全部为 Linear Regression） | 隔离而非删除，统计中单列                           |

**表 2:** 三个数据集的组成与划分规模。DeepCRISPR 为本文的主数据集（4 个细胞系，含 4 条表观遗传通道）；Hiranniramol 与 Labuhn 为**外部复现数据集**，仅有序列通道。三者使用同一套特征构造、模型配置与评估脚本；标签均已归一化到 [0, 1]（Hiranniramol 原始为百分制、Labuhn 为 KO\_reporter\_assay，由适配器统一）。划分规模按 *single* 划分（70%/15%/15%，身份类整体分配）报告。

| dataset / cell line                                | $n$    | 均值    | 标准差   | $n_{\text{train}}$ / $n_{\text{valid}}$ / $n_{\text{test}}$ |
|----------------------------------------------------|--------|-------|-------|-------------------------------------------------------------|
| <i>DeepCRISPR</i> （主数据集；4 条表观通道，16 749 条 23 nt 序列） |        |       |       |                                                             |
| HCT116                                             | 4 239  | 0.254 | 0.172 | 2968 / 635 / 636                                            |
| HEK293T                                            | 2 333  | 0.238 | 0.120 | 1633 / 345 / 355                                            |
| HeLa                                               | 8 101  | 0.257 | 0.182 | 5669 / 1215 / 1217                                          |
| HL60                                               | 2 076  | 0.232 | 0.114 | 1453 / 311 / 312                                            |
| Total                                              | 16 749 | 0.250 | 0.165 | 11 723 / 2 506 / 2 520                                      |
| 外部复现数据集（仅序列通道）                                     |        |       |       |                                                             |
| Hiranniramol                                       | 1 309  | 0.692 | 0.371 | 916 / 196 / 197                                             |
| Labuhn                                             | 417    | 0.672 | 0.248 | 291 / 63 / 63                                               |

### 3.2 跨数据集复现：序列可预测性是数据集依赖的 (E1)

**问题与方法 (RQ1)**：这是本文的第一研究问题。在完全相同的特征构造、模型配置、身份类划分与评估脚本下，序列可预测性在三个相互独立的公开数据集上是否复现？我们同时报告两个外部数据集的结果，其中一个成功、另一个失败。为避免只比较“某一次划分下的测试  $R^2$ ”可能把“该划分恰好困难”误读为“数据无信号”，我们对每个外部数据集额外做一次与官方划分完全无关的复核：在全数据上用同一套 92 维特征做 5 折交叉验证，并以 200 次标签置换构造零分布 (§2.8)。

**观察 1 (三个数据集给出三个截然不同的结论)**：结果见表 4。

- **DeepCRISPR (主数据集)**: *single* 划分下 7 个配置的中位  $R^2$  仅为 0.067–0.120 (XGBoost 最高 0.120, CNN  $k=3$  最低 0.067), 中位 Pearson 0.273–0.349。即：信号为正但幅度有限。
- **Hiranniramol (复现成功)**：在完全相同的流程下，7 个配置的测试  $R^2$  为 0.345–0.489, Pearson 为 0.607–0.709。Transformer 最高 ( $R^2 = 0.489$ , Pearson = 0.709, Spearman = 0.665), CNN  $k=3$  最低 ( $R^2 = 0.345$ )。所有 7 个配置均优于 DeepCRISPR 上最好的配置。
- **Labuhn (复现失败)**：7 个配置的测试  $R^2$  全部为负，范围  $-0.725$  (Linear) 至  $-0.050$  (Transformer), Pearson 为  $-0.012$ – $0.165$ 。负  $R^2$  意味着模型的预测不如直接用测试集均值。

**观察 2 (独立复核确认上述差异不是划分造成的)**：与官方划分无关的全数据 5 折交叉验证给出同向结论：Hiranniramol 的 CV  $R^2 = +0.389$ ，而其标签置换零分布为  $-0.467 \pm 0.038$  ( $n = 200$ )，两者相差  $+0.855$ ，即信号远超零分布；Labuhn 的 CV  $R^2 = -0.144$ ，其自身零分布为  $-0.287 \pm 0.050$ ，两者仅相差  $+0.143$ 。换言之，Labuhn 在这个与划分无关的检验中也没有表现出可用的序列信号。

**观察 3 (Labuhn 的失败机制可诊断：预测坍塌而非标签无方差)**。一个自然的怀疑是“Labuhn 标签方差太小， $R^2$  因而不可靠”。该怀疑被数据排除：Labuhn 测试集标签标准差为 0.215 (范围 0.125–0.941)，与 Hiranniramol 的 0.367 同量级。真正的原因是**预测分布的形态** (表 3)：

- Hiranniramol：7 个配置的预测标准差与标签标准差之比为 0.67–0.83，模型确实展开了预测范围并与真值相关 ( $r = 0.61$ – $0.71$ )；
- Labuhn：6/7 个配置的该比值为 0.03–0.37——Transformer 的预测标准差仅 0.0070 (标签为 0.2153)，XGBoost 为 0.0158，即模型把预测压缩成了接近常数，因此  $R^2$  必然为负；
- 唯一的例外是 Linear：其比值为 0.93 (预测范围几乎与标签同宽)，但与真值的相关仅  $r = 0.165$ ，因此它的“方差”全是误差，反而给出了最差的  $R^2 = -0.725$ 。

两种失效模式不同 (坍塌 vs 方向错误)，但都指向同一结论：在这 291 条训练样本上，序列特征与 Labuhn 标签之间没有可被这批模型捕获的稳定关系。

**观察 4 (数据集间规模与标签差异不足以解释全部差异)**：三个数据集的规模差异很大 (16 749 / 1 309 / 417)。规模可以解释“小数据集更难”，但不能解释**方向**：Labuhn (417 条) 与

Hiranniramol (1309 条) 同属小规模、同为单细胞系、同为仅序列通道，却给出了符号相反的结论。因此本文的 RQ1 结论是：**序列可预测性的幅度乃至符号是数据集依赖的，不能被假定为跨数据集可移植的性质。**

**统计证据.** 观察 2 的置换检验 ( $n = 200$ ) 提供了零分布；观察 1 的每个数据集只有一次 *single* 划分，因此本文不对数据集间的  $R^2$  差异做显著性检验，仅报告点估计、零分布位置与失效机制的分解。

**解释（假设）与边界.** 本文不主张“Labuhn 上不存在任何序列效应”。可能的解释包括：该 library 的效率变异主要由序列之外的因素（染色质状态、转染效率、测定噪声）主导；291 条训练样本不足以支撑 69 维特征的拟合；或该数据集的 sgRNA 序列空间分布与 Hiranniramol / DeepCRISPR 不同。上述均为**待检验假设**。可以确定的只是本文的检验结果：在该数据集与该流程下未检出可用的序列可预测性。

**表 3:** Labuhn 与 Hiranniramol 的预测分布形态（测试集口径）。 $\text{sd}_{\text{pred}}/\text{sd}_y$  为预测标准差与标签标准差之比：接近 1 且相关系数为正表示模型展开了合理范围，接近 0 表示预测坍缩。Labuhn 的 6/7 个配置发生坍缩；Linear 未坍缩但与真值不相关 ( $r = 0.165$ )，故  $R^2$  最低。

| dataset                                         | model       | $\text{sd}_y$ | $\text{sd}_{\text{pred}}$ | $\text{sd}_{\text{pred}}/\text{sd}_y$ |
|-------------------------------------------------|-------------|---------------|---------------------------|---------------------------------------|
| <i>Hiranniramol</i> ( $n_{\text{test}} = 197$ ) |             |               |                           |                                       |
|                                                 | Transformer | 0.3674        | 0.3034                    | 0.83                                  |
|                                                 | CNN $k=3$   | 0.3674        | 0.2774                    | 0.76                                  |
|                                                 | MLP         | 0.3674        | 0.2648                    | 0.72                                  |
|                                                 | CNN $k=7$   | 0.3674        | 0.2623                    | 0.71                                  |
|                                                 | CNN $k=5$   | 0.3674        | 0.2596                    | 0.71                                  |
|                                                 | Linear      | 0.3674        | 0.2581                    | 0.70                                  |
|                                                 | XGBoost     | 0.3674        | 0.2446                    | 0.67                                  |
| <i>Labuhn</i> ( $n_{\text{test}} = 63$ )        |             |               |                           |                                       |
|                                                 | Linear      | 0.2153        | 0.2000                    | 0.93                                  |
|                                                 | CNN $k=7$   | 0.2153        | 0.0803                    | 0.37                                  |
|                                                 | MLP         | 0.2153        | 0.0659                    | 0.31                                  |
|                                                 | CNN $k=3$   | 0.2153        | 0.0595                    | 0.28                                  |
|                                                 | CNN $k=5$   | 0.2153        | 0.0485                    | 0.23                                  |
|                                                 | XGBoost     | 0.2153        | 0.0158                    | 0.07                                  |
|                                                 | Transformer | 0.2153        | 0.0070                    | 0.03                                  |

### 3.3 跨细胞系泛化失败 (E1)

**问题与方法.** 在单个数据集内部，模型能否迁移到未参与的细胞系？我们在 DeepCRISPR 上使用真实留一细胞系 (LOCO) 划分，训练池先剔除与留出系共享身份类的全部序列，再评估 7 个配置。

**观察.** *all* (LOCO) 划分下，7 个模型配置的中位  $R^2$  全部落在  $-0.027$  至  $+0.010$  之间 (CNN  $k=3$   $-0.027$ 、 $k=5$   $-0.022$ 、 $k=7$   $-0.011$ 、Transformer  $-0.009$ 、XGBoost  $-0.008$ 、MLP  $-0.001$ 、Linear  $+0.010$ )，即与**均值基线不可区分** (表 5、图 2A)。这些配置的**均值**则因左尾而更低 ( $-0.111$  至  $-0.072$ )，说明有少数 run 明显差于基线。按留出细胞系展开后异质性很大：以 CNN  $k = 3$  为例，HCT116  $R^2 = +0.043$ 、HeLa  $-0.023$ 、HL60  $-0.037$ 、HEK293T  $-0.266$  (图 2C)。

**表 4:** 跨数据集序列信号复现 (测试集口径)。DeepCRISPR 行为 *single* 划分下 64 次运行的中位数 (Linear 为 58 次有效运行), Hiranniramol 与 Labuhn 为各自单细胞系划分下的唯一一次运行。三者使用完全相同的特征构造、模型配置、身份类划分与评估脚本。下半部分为与官方划分无关的独立复核: 全数据 5 折 CV  $R^2$  与 200 次标签置换零分布。

| dataset                                    | model  | $R^2_{\text{test}}$ | Pearson            | Spearman  | $n$ runs |
|--------------------------------------------|--------|---------------------|--------------------|-----------|----------|
| <i>DeepCRISPR</i>                          |        |                     |                    |           |          |
| CNN $k=3$                                  | +0.067 | +0.273              | +0.267             |           | 64       |
| CNN $k=5$                                  | +0.073 | +0.305              | +0.316             |           | 64       |
| CNN $k=7$                                  | +0.092 | +0.335              | +0.331             |           | 64       |
| Linear                                     | +0.082 | +0.294              | +0.299             |           | 58       |
| MLP                                        | +0.096 | +0.320              | +0.320             |           | 64       |
| Transformer                                | +0.097 | +0.320              | +0.326             |           | 64       |
| XGBoost                                    | +0.120 | +0.349              | +0.343             |           | 64       |
| <i>Hiranniramol</i>                        |        |                     |                    |           |          |
| CNN $k=3$                                  | +0.345 | +0.607              | +0.571             |           | 1        |
| CNN $k=5$                                  | +0.360 | +0.609              | +0.577             |           | 1        |
| CNN $k=7$                                  | +0.424 | +0.654              | +0.630             |           | 1        |
| Linear                                     | +0.374 | +0.624              | +0.623             |           | 1        |
| MLP                                        | +0.355 | +0.622              | +0.634             |           | 1        |
| Transformer                                | +0.489 | +0.709              | +0.665             |           | 1        |
| XGBoost                                    | +0.472 | +0.695              | +0.662             |           | 1        |
| <i>Labuhn</i>                              |        |                     |                    |           |          |
| CNN $k=3$                                  | -0.177 | +0.120              | +0.058             |           | 1        |
| CNN $k=5$                                  | -0.216 | +0.087              | +0.103             |           | 1        |
| CNN $k=7$                                  | -0.281 | +0.048              | -0.037             |           | 1        |
| Linear                                     | -0.725 | +0.165              | +0.087             |           | 1        |
| MLP                                        | -0.204 | -0.012              | -0.176             |           | 1        |
| Transformer                                | -0.050 | +0.059              | -0.160             |           | 1        |
| XGBoost                                    | -0.080 | -0.001              | +0.044             |           | 1        |
| 独立复核 (全数据 5 折 CV, 与官方划分无关)                 |        |                     |                    |           |          |
| dataset                                    | $n$    | CV $R^2$            | 置换零分布 $R^2$        | CV - null |          |
| Hiranniramol                               | 1309   | +0.389              | -0.467 $\pm$ 0.038 | +0.855    |          |
| Labuhn                                     | 417    | -0.144              | -0.287 $\pm$ 0.050 | +0.142    |          |
| <i>DeepCRISPR</i> 合并规模: 16 749 条序列 (4 细胞系) |        |                     |                    |           |          |

作为对照，同一批模型在同数据集内的 *single* 划分上中位  $R^2$  为正 (0.067–0.120)。因此”序列信号存在”与”序列信号可跨细胞系迁移”是两个不同强度的陈述，本文只支持前者（且在 §3.2 已限定为数据集依赖）。

**解释（假设）与边界。** 可能的原因包括训练/测试之间的细胞背景分布漂移、表观特征在不同细胞系中的可比性不足，以及各细胞系序列组成差异。跨细胞类型预测的困难在方法学文献中已有报告 [Schreiber et al., 2020]，且细胞背景信息通常需要显式迁移建模而非默认由序列携带 [Elkayam et al., 2024]。这些均属**待检验假设**，本文不将其判为机制。

**边界（重要混杂）。** LOCO 的训练池因剔除留出系同源身份类而缩减 ( $n_{\text{train}}$  1 453–12 313)，因此”跨细胞系性能为负”同时包含”分布漂移”与”训练样本减少”两种因素，本文无法在本数据中完全分离二者。

**表 5:** Held-out test performance aggregated over experiments (canonical experiment-level table).  $n_{\text{valid}}$  is the number of non-divergent runs used for the statistics; diverged counts runs with  $|R^2| \geq 10$  (isolated, not used in the statistics, not deleted from the raw artifacts).

| model       | split  | n_experiments | n_valid | R2_median | R2_mean | R2_sd | RMSE_median | MAE_median | Spearman_median | diverged |
|-------------|--------|---------------|---------|-----------|---------|-------|-------------|------------|-----------------|----------|
| cnn(3 3)    | single | 64            | 64      | 0.067     | 0.063   | 0.018 | 0.145       | 0.117      | 0.267           | 0        |
| cnn(3 3)    | mixed  | 64            | 64      | 0.041     | 0.043   | 0.007 | 0.162       | 0.128      | 0.211           | 0        |
| cnn(3 3)    | all    | 64            | 64      | -0.027    | -0.072  | 0.120 | 0.153       | 0.123      | 0.031           | 0        |
| cnn(5 3)    | single | 64            | 64      | 0.073     | 0.061   | 0.042 | 0.144       | 0.115      | 0.316           | 0        |
| cnn(5 3)    | mixed  | 64            | 64      | 0.070     | 0.070   | 0.010 | 0.159       | 0.125      | 0.272           | 0        |
| cnn(5 3)    | all    | 64            | 64      | -0.022    | -0.084  | 0.181 | 0.155       | 0.124      | 0.112           | 0        |
| cnn(7 3)    | single | 64            | 64      | 0.092     | 0.092   | 0.041 | 0.144       | 0.114      | 0.331           | 0        |
| cnn(7 3)    | mixed  | 64            | 64      | 0.080     | 0.077   | 0.013 | 0.158       | 0.124      | 0.281           | 0        |
| cnn(7 3)    | all    | 64            | 64      | -0.011    | -0.084  | 0.206 | 0.155       | 0.124      | 0.116           | 0        |
| mlp         | single | 64            | 64      | 0.096     | 0.082   | 0.062 | 0.145       | 0.117      | 0.320           | 0        |
| mlp         | mixed  | 64            | 64      | 0.075     | 0.072   | 0.013 | 0.159       | 0.125      | 0.271           | 0        |
| mlp         | all    | 64            | 64      | -0.001    | -0.076  | 0.181 | 0.154       | 0.123      | 0.133           | 0        |
| transformer | single | 64            | 64      | 0.097     | 0.083   | 0.058 | 0.147       | 0.118      | 0.326           | 0        |
| transformer | mixed  | 64            | 64      | 0.073     | 0.075   | 0.011 | 0.158       | 0.125      | 0.273           | 0        |
| transformer | all    | 64            | 64      | -0.009    | -0.111  | 0.220 | 0.156       | 0.125      | 0.085           | 0        |
| xgboost     | single | 64            | 64      | 0.120     | 0.105   | 0.050 | 0.142       | 0.115      | 0.343           | 0        |
| xgboost     | mixed  | 64            | 64      | 0.094     | 0.095   | 0.008 | 0.157       | 0.124      | 0.301           | 0        |
| xgboost     | all    | 64            | 64      | -0.008    | -0.087  | 0.201 | 0.154       | 0.123      | 0.140           | 0        |
| linear      | single | 64            | 58      | 0.082     | 0.071   | 0.066 | 0.168       | 0.134      | 0.299           | 6        |
| linear      | mixed  | 64            | 58      | 0.069     | 0.073   | 0.011 | 0.160       | 0.127      | 0.257           | 6        |
| linear      | all    | 64            | 56      | 0.010     | -0.105  | 0.222 | 0.145       | 0.114      | 0.139           | 8        |


### 3.4 泄漏整改前后的对照（E1 方法学）

**问题与方法。** 项目早期批次 (batch\_20260909\_full) 采用按记录随机划分，且 LOCO 分支未剔除留出系同源序列。为量化该问题的影响，我们比较整改前后两个批次的同一批统计量（两批使用相同的数据、模型配置与环境组合，仅划分策略不同；旧批次不进入本文任何结论）。

**观察。** 整改后 *mixed* 划分的中位  $R^2$  由 0.1184 降至 0.0734，*all* (LOCO) 由 +0.0362 降至 -0.0083，而 *single* 划分基本不变 (0.0704  $\rightarrow$  0.0808)。

**解释（假设）。** 三种划分的差异化变化说明：受影响的正是”训练与测试之间存在同源序列”的情形。*single* 划分在单细胞系内部进行，序列唯一（该系内无重复序列），因此不受影响；*mixed* 与 LOCO 涉及跨细胞系合并，此前同一 sgRNA 序列可同时进入训练与测试两侧，模型在测试集上部分”记忆”了已见序列，从而系统性高估跨细胞系性能。

**边界。** 本文不主张”旧批次结果全部无效”：在无同源重复的 *single* 划分上两批结论一致。



**图 2:** 留出测试集预测性能 (每配置 64 次运行)。(A) *single*、*mixed* 与 *all* (真实 LOCO) 三种划分下各模型配置的  $R^2$  中位数; LOCO 分支整体落在 0 附近或以下。(B) *single* 划分下逐次运行的  $R^2$  分布 (散点为单次实验, 红线为中位数), 可见 Linear Regression 的发散运行。(C) 按留出细胞系展开的 LOCO 行, 显示极端的细胞系间异质性 (HEK293T 最低)。

同样也不主张”模型完全没有跨细胞系泛化能力”: LOCO 中位  $R^2$  接近 0 而非显著为负, 且 HCT116 作为留出系时仍为正 (+0.043)。准确的陈述是: 在排除同源序列污染后, 跨细胞系泛化性能从”弱正”变为”与均值基线无法区分”。

### 3.5 环境增量信息: 四个因子均未达到预设效应阈值 (E1)

**问题与方法.** 表观遗传环境是否在序列信息之外提供额外预测信息? 我们以 sequence-only 为基线, 对 16 个环境组合的全部 lattice 边计算配对  $\Delta R^2$ , 并用逐样本配对 bootstrap、符号翻转置换检验与区组析因方差分析三种互补方式评估。


**观察 1 (效应量级低于预设阈值).** 四个因子的跨模型等权平均主效应为: CTCF +0.0003 (95% 区间 -0.0035–0.0038)、DNase +0.0013 (-0.0013–0.0043)、H3K4me3 -0.0007 (-0.0033–0.0018)、RRBS -0.0015 (-0.0040–0.0010)。四个因子的区间全部跨 0, 且  $|\overline{\Delta R^2}|$  为  $3.2 \times 10^{-4}$  至  $1.5 \times 10^{-3}$ , 比预设的最小绝对增益门 0.01 低 1–2 个数量级 (表 6、图 3A–B)。

**观察 2 (边级与置换检验的一致性有限).** 在 1978 条可检验 lattice 边上, 逐样本配对 bootstrap 的 95% 置信区间有 640 条不跨 0 (CTCF 163/496、DNase 155/492、H3K4me3 168/494、RRBS 154/496); 四个因子的 *Minimal Edge-level FDR across Tested Contexts* 均为 0.0070, 但其为跨上下文取最小的 existence-oriented 证据 (FWER 上界 0.427–0.441), 不足以提升因子等级。

**观察 3 (区组析因方差分析未检出任何显著效应).** 以  $R^2$  为响应、四个环境因子为二水平因子、模型/细胞系/划分为区组的 Type-II 析因方差分析给出四个主效应  $p = 0.975$ – $0.9996$  (CTCF 0.9892、DNase 0.9996、H3K4me3 0.9753、RRBS 0.9867), 六个成对交互  $p = 0.58$ – $0.97$  (图 3D)。

**解释 (假设) 与边界.** 综合三种方法, 本数据集没有提供支持”这四个环境因子具有达到预设门槛的独立增量预测贡献”的证据。这一结论的准确含义是未检出, 而不是无作用:  $\Delta R^2$  度量的是在已有序列模型基础上的增量预测价值, 环境信息可能与序列特征冗余、可能受限于二值化编码的分辨率 [Klemm et al., 2019], 四个通道也不足以代表完整 cell state; 此外若干细胞系–通道组合近乎常数, 这会直接压缩可检测的效应上限。值得注意的是, 已有研究报告在 sgRNA 活

性预测中加入 DNase 可及性轨道后并未提升预测性能 [Wang et al., 2019]。因此本结果为”在通用多细胞系设定下未检出”。统计可检测性与生物学相关性是两件事，本文只报告前者。



**图 3:** 环境因素的增量预测贡献与统计证据。(A) 各模型配置对四个环境因子的主效应  $\Delta R^2$  (排除发散行)。(B) 主效应跨模型/上下文的分布。(C) 逐样本配对 bootstrap 中 95% 置信区间不跨 0 的 lattice 边数量 (分母为可检验边数)。(D) 区组析因方差分析的  $p$  值; 四个主效应与全部交互项均未达到  $p < 0.05$ 。所有效应量级均小于 0.01。

**表 6:** Environmental factors: cross-model incremental predictive value (mean main-effect  $\Delta R^2$  over models after excluding numerically diverged rows,  $|\Delta R^2| > 10$ ), model-level bootstrap interval ( $n = 7$  model configurations), paired per-sample edge bootstrap (CI excluding zero), permutation-based FDR, blocked factorial ANOVA and cell-line context label. Effect gate =  $|\text{model-equal-weight mean } \Delta R^2| \geq 0.01$ ; min\_edge\_FDR = Minimal Edge-level FDR across Tested Contexts (existence-oriented, extremum selection, not a factor-level FDR); n\_contexts = de-duplicated tested contexts; mlevel\_bootstrap = Model-Level Bootstrap Interval ( $n = 7$  model configurations).

| factor  | mean_dR2 | median_dR2 | effect_gate | n_models | direction_conflict | min_edge_FDR | n_contexts | selected_context | fewer_upper_bound | concordance | mlevel_bootstrap  | ci_excludes_zero | anova_F | anova_p | cell_line_context   | tier         |
|---------|----------|------------|-------------|----------|--------------------|--------------|------------|------------------|-------------------|-------------|-------------------|------------------|---------|---------|---------------------|--------------|
| CTCF    | 0.0003   | 0.0001     | fail        | 7        | yes                | 0.0070       | 63         | all/hl60/linear  | 0.4406            | 0.5714      | [-0.0035, 0.0038] | False            | 0.0773  | 0.9892  | Context-conflicting | Inconclusive |
| DNase   | 0.0013   | -0.0003    | fail        | 7        | yes                | 0.0070       | 61         | all/hl60/linear  | 0.4266            | 0.5714      | [-0.0013, 0.0043] | False            | 0.0142  | 0.9996  | Uncertain           | Inconclusive |
| H3K4me3 | -0.0007  | -0.0004    | fail        | 7        | yes                | 0.0070       | 62         | all/hl60/linear  | 0.4336            | 0.7143      | [-0.0033, 0.0018] | False            | 0.1204  | 0.9753  | Context-conflicting | Inconclusive |
| RRBS    | -0.0015  | -0.0018    | fail        | 7        | yes                | 0.0070       | 63         | all/hl60/linear  | 0.4406            | 0.5714      | [-0.0040, 0.0010] | False            | 0.0863  | 0.9867  | Uncertain           | Inconclusive |

### 3.6 多模型序列归因指向 PAM 邻近位置 (E3)

**问题与方法 (RQ2 的第一半)**。模型归因是否指向可重复的序列位置，且这种指向是否跨模型类一致？我们比较五类模型的主归因方法（线性系数、TreeSHAP、MLP-IG、CNN-IG、注意力）在 23 个位置上的归一化归因分布，并分别在单碱基位置与粗粒度区域两个层级汇总。

**观察 1 (单模型峰值: 4/5 个模型类落在 PAM 邻近窗口)**。每个模型类的跨上下文平均归因谱的峰值位置为: XGBoost 第 18 位 (0.1345)、MLP 第 18 位 (0.0857)、Transformer 第 19 位 (0.1045)、CNN 第 20 位 (0.0529)，即四个非模型类的峰值都落在 PAM 邻近窗口 17–20 内；唯一的例外是 Linear Regression，其峰值在第 1 位 (0.1977) ——线性模型在剔除  $\_T$  参照列后，首位碱基承担了基线效应。

**观察 2 (跨模型平均谱: 位置 1 与位置 18 之争取决于是否纳入 Linear)**。把五个模型类等权平均后，谱峰位于第 1 位 (0.0864)，其后为第 18 位 (0.0799)、第 20 位 (0.0708)、第 19 位 (0.0637)；该首位峰值完全由 Linear 贡献。剔除 Linear 后，四个模型的平均谱峰值为第 18 位 (0.0878)，其后为第 20 位 (0.0764)、第 19 位 (0.0669) (表 7)。本文因此不写”跨模型平均谱峰值即为第 18 位”这一概括，而是并列两种口径——这是”保留模型间分歧而非平均掉”的具体执行。

**观察 3 (逐上下文的峰值落点比例)**。在 *single* 划分的 64 个 (细胞系 × 环境) 上下文下, 统计各模型类的归因峰值是否落在 17–20 窗口: **XGBoost 100.0% (64/64)**、**CNN 96.9% (62/64)**、**MLP 90.6% (58/64)**、**Transformer 65.6% (42/64)**、**Linear 21.9% (14/64)**。众数位置分别为第 18 位 (XGBoost、MLP)、第 20 位 (CNN)、第 19 位 (Transformer)、第 1 位 (Linear)。

**观察 4 (区域层级: 仅两个模型类的最高区域为 PAM 邻近区)**。按四个粗粒度区域汇总 (对细胞系与上下文取平均) 后, XGBoost (PAM 邻近区 0.327) 与 Transformer (0.325) 的最高归因区域确为 PAM 邻近种子区 (17–20); 但 **CNN (0.344)** 与 **MLP (0.336)** 的最高区域为种子核心区 (9–16), 而 Linear Regression 的最高区域为 PAM 远端区 (0.416) (图 4B)。即只有 2/5 个模型类的最高区域是 PAM 邻近区。跨模型位置谱的平均两两 Spearman 相关系数为 0.34 (80 个上下文, 范围 0.03–0.56), top-3 位置重叠率 0.42。

**统计证据**。观察 1–4 均为归因幅值的描述性汇总。**attribution 幅值不构成统计显著性证据**; 本文不报告归因的  $p$  值, 也不把 SNR 当作检验统计量 (§2)。

**表 7: 位置层级归因 (E3; 测试集口径与 *single* 划分)**。上: 各模型类跨上下文平均归因谱的峰值位置与峰值, 以及逐上下文峰值落在 PAM 邻近窗口 (17–20) 的比例 (分母为 64 个细胞系 × 环境上下文)。下: 等权平均谱的前五位。**五模型平均谱的峰值是第 1 位而非第 18 位**, 该峰值完全由 Linear 贡献; 剔除 Linear 后峰值才是第 18 位。本文并列两种口径而不取其一。归因幅值仅表示模型依赖强度, 不构成统计显著性证据。

| model class     | 峰值位置                                                               | 峰值     | 峰值 $\in [17, 20]$ 的比例 | 众数位置 |
|-----------------|--------------------------------------------------------------------|--------|-----------------------|------|
| Linear          | 1                                                                  | 0.1977 | 21.9% (14/64)         | 1    |
| XGBoost         | 18                                                                 | 0.1345 | 100.0% (64/64)        | 18   |
| Transformer     | 19                                                                 | 0.1045 | 65.6% (42/64)         | 19   |
| MLP             | 18                                                                 | 0.0857 | 90.6% (58/64)         | 18   |
| CNN             | 20                                                                 | 0.0529 | 96.9% (62/64)         | 20   |
| 等权平均谱前五位        |                                                                    |        |                       |      |
| 五模型 (含 Linear)  | 1 (0.0864) > 18 (0.0799) > 20 (0.0708) > 19 (0.0637) > 21 (0.0461) |        |                       |      |
| 四模型 (剔除 Linear) | 18 (0.0878) > 20 (0.0764) > 19 (0.0669) > 1 (0.0586) > 21 (0.0519) |        |                       |      |

**解释 (假设) 与边界**。支持“PAM 邻近区域 (尤其第 18/20 位) 是与编辑效率最相关的序列位置”这一表述的证据在**位置层级较强**: 四个非模型类 (XGBoost、CNN、MLP、Transformer) 的逐上下文峰值落在 17–20 窗口的比例为 65.6%–100%, 且它们的单模型平均谱峰值都在该窗口内。但该表述有三个必须同时声明的边界: 其一, **Linear 完全不符合** (21.9%, 峰值在第 1 位), 因此不能说“五类模型一致”; 其二, 把 Linear 纳入平均后, **跨模型平均谱峰值是第 1 位而非第 18 位**; 其三, 在**区域层级仅为 2/5**。本文因此采用如下表述: 四个非模型类的位置归因峰值高度集中于 PAM 邻近窗口, 线性模型则集中于首位与 PAM 区; 两种口径下第 18 位都位列前二, 但并非在所有口径下都是第一。这一分歧被保留而非平均掉, 并作为 §3.9 选择第 18 位做外部验证的动机之一——但必须强调: **E3 自身不能说明该位置是否真的重要, 它只说明模型依赖该位置**。




图 4: 跨模型序列归因。(A) 五类模型在 23 个位置上的归一化归因谱 (阴影为 PAM 邻近种子区 17–20 与 PAM 21–23)。(B) 四个序列区域的平均归一化归因 (按模型); 仅 XGBoost 与 Transformer 的最高区域为 PAM 邻近区 (2/5)。归因幅值仅表示模型依赖强度, 不构成统计显著性证据; 不同模型的 importance 在模型内归一化, 绝对值不可跨模型类直接比较。

### 3.7 多尺度 CNN: 更宽的局部感受野带来小幅但可复现的提升 (E1 + E3)

**问题与方法.** 序列卷积核大小 (感受野) 是否影响预测与解释? 我们在 192 组严格配对的实验 (同一划分、细胞系、环境组合与种子, 仅卷积核不同) 中比较  $R^2$ , 并比较三个核配置的归因谱与候选模式长度。

**观察 1 (提升方向一致但幅度有限).** 配对差分为:  $k = 5$  相对  $k = 3$  提高 +0.0046 (95% bootstrap 区间  $-0.0029$ – $+0.0116$ , 66.2% 配对为正, 区间跨 0);  $k = 7$  相对  $k = 3$  提高 +0.0169 ( $+0.0077$ – $+0.0257$ , 79.7% 为正);  $k = 7$  相对  $k = 5$  提高 +0.0123 ( $+0.0070$ – $+0.0175$ , 70.8% 为正) (表 8、图 5A)。

**观察 2 (解释随之改变).** 区域平均归因显示, 感受野增大使归因向 PAM 邻近区与 PAM 区集中, 而 PAM 远端区下降 (图 5C)。这直接说明归因对模型超参数敏感。

**观察 3 (模式长度不随核大小改变).** 三个核配置提取的候选模式长度中位数均为 4 nt (分布 4–11), 说明卷积核大小是模型感受野参数, 不能等同于候选模式长度。

**解释 (假设) 与边界.** 结果支持一个模型层面的谨慎解释: 在本案例数据中, 更宽的局部感受野能更好地捕获 PAM 邻近上下文的依赖关系, 从而带来小幅但方向一致的预测提升。该结论限于  $E1$  与  $E3$ , 不能推断”更宽的序列上下文具有生物学因果必要性”。




图 5: CNN 感受野 (多尺度局部序列上下文) 分析。(A) 192 组配对实验的  $\Delta R^2$  (均值与 95% bootstrap 区间), 标注配对中为正的的比例与区间是否跨 0。(B) 三个核配置的位置归因谱。(C) 区域平均归因随核大小的变化。(D) 三配置提取的候选模式长度分布 (中位数均为 4 nt)。

**表 8:** CNN receptive-field (kernel size) ablation. Paired differences of held-out  $R^2$  over 192 matched experiment pairs (same split, cell line, environment and seed); CI is a percentile bootstrap over pairs.

| comparison | n_pairs | mean_dR2 | ci_low  | ci_high | pct_positive | excludes_zero |
|------------|---------|----------|---------|---------|--------------|---------------|
| k5 - k3    | 192     | 0.0046   | -0.0029 | 0.0116  | 0.6615       | False         |
| k7 - k3    | 192     | 0.0169   | 0.0077  | 0.0257  | 0.7969       | True          |
| k7 - k5    | 192     | 0.0123   | 0.0070  | 0.0175  | 0.7083       | True          |

### 3.8 候选序列模式及其统计支持 (E3 + 富集检验)

**问题与方法.** 归因能否进一步形成具有支持度、方向与统计检验的候选序列模式? 我们按 §2 流程从 CNN IG/ISM 归因中提取 seqlet 并聚类, 随后进行共识构建、支持度筛选与富集检验。

**观察.** 最终得到 **656 个候选模式** (标签反映跨核与跨细胞系复现性), 长度以 4nt 为主; 位置分布高度集中于 PAM 邻近区。富集检验 (前景为效率上三分位序列, 背景为全部可用序列) 共 656 次, 其中 **65 个通过 BH-FDR < 0.05 (9.9%)** (表 9)。

**统计证据.** 富集检验提供的是”该模式在高效序列中更常见”的统计支持; 由于多数候选模式与 PAM/种子区重叠, 其统计支持部分来自该区域的整体重要性, 未必构成独立的模式语法。

**解释 (假设) 与边界.** 三项限制尤须强调: 其一, 候选模式目前仅具**计算证据**, 跨模型比较仅限 CNN 三个核配置 (缺少 Transformer IG 产物), 因此不能宣称”跨模型收敛的生物学 motif”; 其二, 富集结果目前多在单一细胞系 (HeLa) 中达到显著, 属 context-dependent 候选; 其三, 通过 FDR 的 65 个模式须视为待实验验证的候选序列模式, 而不是功能性 motif。

**表 9:** Representative motif candidates discovered from CNN attribution. Support counts are seqlet instances; enrichment and FDR come from the Fisher exact test against the all-eligible-sequence background (BH-FDR within the motif\_enrichment family). Effect direction is the carrier-vs-background measured-efficiency contrast, not a causal effect.

| motif_id                              | human_pattern | iupac | regex | length | support_count | sample_support | cellline_support | effect_direction | mean_effect | enrichment | FDR   | evidence_strength       |
|---------------------------------------|---------------|-------|-------|--------|---------------|----------------|------------------|------------------|-------------|------------|-------|-------------------------|
| motif_cnn33_hela_sequence_cnn_ig_001  | CTGG          | CTGG  | CTGG  | 4      | 1273          | 1273           | 1                | -                | -0.046      | 0.870      | 1.000 | Moderate motif evidence |
| motif_cnn33_hela_sequence_cnn_ig_012  | CAGG          | CAGG  | CAGG  | 4      | 1083          | 1083           | 1                | -                | -0.030      | 0.934      | 1.000 | Moderate motif evidence |
| motif_cnn33_hela_sequence_cnn_ig_025  | GAGG          | GAGG  | GAGG  | 4      | 899           | 899            | 1                | +                | 0.012       | 1.081      | 0.031 | Strong motif evidence   |
| motif_cnn33_hela_all_cnn_ig_032       | AAGG          | AAGG  | AAGG  | 4      | 890           | 890            | 1                | -                | -0.010      | 0.983      | 1.000 | Moderate motif evidence |
| motif_cnn33_hela_sequence_cnn_ig_044  | ATGG          | ATGG  | ATGG  | 4      | 789           | 789            | 1                | +                | 0.011       | 1.050      | 0.259 | Moderate motif evidence |
| motif_cnn33_hela_sequence_cnn_ig_057  | GTGG          | GTGG  | GTGG  | 4      | 740           | 740            | 1                | +                | 0.017       | 1.030      | 0.466 | Moderate motif evidence |
| motif_cnn33_hela_sequence_cnn_ig_086  | AGGG          | AGGG  | AGGG  | 4      | 610           | 610            | 1                | +                | 0.028       | 1.068      | 0.206 | Moderate motif evidence |
| motif_cnn33_hela_sequence_cnn_ism_119 | GCTG          | GCTG  | GCTG  | 4      | 482           | 482            | 1                | -                | -0.061      | 0.872      | 1.000 | Model-specific motif    |
| motif_cnn53_hela_all_cnn_ig_120       | GCTGG         | GCTGG | GCTGG | 5      | 482           | 482            | 1                | -                | -0.061      | 0.801      | 1.000 | Model-specific motif    |
| motif_cnn33_hela_sequence_cnn_ig_147  | GGGG          | GGGG  | GGGG  | 4      | 435           | 435            | 1                | +                | 0.060       | 1.353      | 0.000 | Exploratory motif       |

### 3.9 外部模型验证: 独立第三方模型确认第 18 位扰动方向 (E4, 外部验证)

**问题与方法 (RQ2 的第二半).** §3.6 的结论完全建立在本文自己的模型族上: 五类模型可能共同依赖了同一份数据中的同一混杂结构。因此我们引入独立第三方模型 CRISPRon (不同训练数据、不同输入编码、不同输出尺度; §2.10), 把 E3 指认的位置转化为一个最小扰动, 检验两个独立系统对同一扰动的方向判断是否一致。

**观察 1 (预登记的选择规则).** 我们从 DeepCRISPR *single* 划分的**测试集**中, 按预先写死的规则 (独立于任何突变侧信息, 脚本内以断言强制) 选出 8 条第 18 位为 C 的代表性 WT 序列, 覆盖 low/medium/high 三个效率区间与 4 个细胞系 (表 10)。选择规则在扰动之前固定, 因此”下降多少”不可能影响”选了谁”。

**观察 2 (外部模型的扰动响应与本文模型族方向一致)**。每条 WT 只改第 18 位一个碱基 (C→A)，其余 22 nt 与全部侧翼逐位不变 (逐条 QC 通过：仅目标位点改变、PAM 未变、侧翼一致、方向保持、WT 与突变体各恰好命中 1 个预期靶点)。结果显示：

- **CRISPRon 侧：8 条中有 7 条给出负向变化** (方向一致率 0.875)， $\Delta$  均值为  $-12.43$ 、中位  $-13.82$ 、范围  $-27.17$  至  $+9.16$ ；
- **跨模型方向一致性为 7/8**：本文 7 个模型的符号化 ISM 预测变化 ( $\Delta_{\text{ours}}$ ) 与 CRISPRon 的  $\Delta$  在 7 条序列上同号；
- **两个系统的变化幅度也正相关**：Pearson  $r = 0.629$ ，Spearman  $\rho = 0.476$  ( $n = 8$ )；
- 唯一分歧为 **WT08** (本文模型  $\Delta_{\text{ours}} = -0.021$ ，CRISPRon  $\Delta = +9.16$ )。该序列被保留在全部统计中，而非剔除为异常值。

**观察 3 (外部验证的独立性是可核查的)**。CRISPRon 的安装与运行经过官方黄金测试：bin/test.sh 输出 TEST ok，且生成的中间文件与官方 test/outdir.original/ 中的对应文件逐字节相同 (SHA-256 相等)。CRISPRon 会在正负两条链上扫描 30-mer，因此额外靶点被显式计数 (本批 3 条记录出现额外命中，均记录在案)。

**统计证据**。方向一致性为 7/8，幅度相关的  $n = 8$ 。样本量小，本文不对  $r$  或  $\rho$  做显著性检验，也不把 0.875 解读为总体比例估计；报告的是这 8 个预登记实例上的实际一致性计数。

**解释 (假设) 与边界**。该结果把”第 18 位对模型预测有实质影响”这一陈述从单一模型族内的观察提升为跨独立系统的可复现观察。但必须严格限定：这仍然是**模型行为层面**的证据 (E4)。两个模型系统方向一致，可以说明它们捕捉到了同一统计结构，不能说明该结构对应真实的编辑效率变化。尤其注意：WT08 的分歧说明这一致性并非普遍成立，本文不隐去它。

**表 10: 外部模型验证：独立第三方模型 CRISPRon 对第 18 位 C→A 反事实扰动的响应。** 8 条野生型 (WT) 序列按预先登记规则从 DeepCRISPR 测试集选出 (第 18 位为 C)，扰动仅改变第 18 位一个碱基，其余 22 nt 与全部侧翼完全不变 (逐条 QC 通过)。 $\Delta_{\text{CRISPRon}}$  为 CRISPRon 复合评分 (0–100)； $\Delta_{\text{ours}}$  为本文 7 个模型基于符号化 in-silico 突变的预测变化均值  $\pm$  标准差 (归一化效率尺度)。**两个模型族的扰动响应在 8 条序列中的 7 条上方向一致** (Pearson  $r = 0.629$ ，Spearman  $\rho = 0.476$ ， $n = 8$ )；唯一分歧为 WT08，该结果保留而非剔除。

| sample | cell line | 实测效率  | CRISPRon WT | CRISPRon C18A | $\Delta_{\text{CRISPRon}}$ | $\Delta_{\text{ours}}$ | 方向一致 |
|--------|-----------|-------|-------------|---------------|----------------------------|------------------------|------|
| WT01   | hct116    | 0.110 | 50.74       | 23.57         | -27.17                     | $-0.102 \pm 0.038$     | 是    |
| WT02   | hek293t   | 0.144 | 47.79       | 34.03         | -13.76                     | $-0.026 \pm 0.025$     | 是    |
| WT03   | hek293t   | 0.214 | 29.75       | 20.85         | -8.90                      | $-0.055 \pm 0.032$     | 是    |
| WT04   | hela      | 0.267 | 35.93       | 15.33         | -20.60                     | $-0.109 \pm 0.053$     | 是    |
| WT05   | hct116    | 0.537 | 60.52       | 51.74         | -8.78                      | $-0.105 \pm 0.073$     | 是    |
| WT06   | hela      | 0.503 | 76.39       | 62.51         | -13.88                     | $-0.071 \pm 0.023$     | 是    |
| WT07   | hl60      | 0.344 | 50.68       | 35.21         | -15.47                     | $-0.050 \pm 0.027$     | 是    |
| WT08   | hl60      | 0.187 | 22.26       | 31.42         | +9.16                      | $-0.021 \pm 0.028$     | 否    |

CRISPRon 侧：7/8 条  $\Delta < 0$ ，方向一致率 0.875， $\Delta$  均值  $-12.43$  (中位  $-13.82$ ，范围  $-27.17$  至  $+9.16$ )




图 6: 外部模型验证 (E4)。左上: 8 条预登记 WT 序列在 C→A 前后由 CRISPRon 给出的评分配对变化。右上: 本文 7 个模型的  $\Delta_{\text{ours}}$  与 CRISPRon 的  $\Delta$  的对应关系 ( $r = 0.629$ ,  $\rho = 0.476$ ,  $n = 8$ ); 对角线上方/下方分别表示方向一致/不一致, WT08 为唯一分歧点。左下: 全部 552 条单碱基替换的  $\Delta$  矩阵 (按位置), 可见第 18 位列的颜色最深。右下:  $\Delta$  的分布。

### 3.10 反事实扰动：饱和突变独立地把第 18 位排在首位 (E4)

**问题与方法.** §3.9 检验的是”预先指定的位置”。为排除”我们恰好挑了一个看起来重要的位置”这一可能，我们做一个**不预先指定位置**的穷举检验：对 8 条 WT 的 23 个位点、每个位点的全部 3 种非野生型替换做饱和 in-silico 突变，用 CRISPRon 打分，再比较各位置的平均效应量级。

**观察 1 (第 18 位在全部可比位置中排名第 1) .** 共产生 552 条替换记录 ( $8 \times 23 \times 3$ )，其中 48 条破坏 PAM 而无法被 CRISPRon 识别、被排除，剩 504 条计分。按平均  $|\Delta|$  排序 (表 11)，前五位为第 18 位 (12.86) > 第 17 位 (7.68) > 第 20 位 (7.18) > 第 19 位 (6.99) > 第 16 位 (5.36)，**第 18 位排名 1/21**，且其量级约为第 2 名的 1.7 倍、最弱位置 (第 21 位 2.13、第 2 位 2.60) 的 5-6 倍。

**观察 2 (该排名在逐序列层面也稳定) .** 在每条序列内部单独排序，第 18 位在 8 条序列中的 **7 条上排第 1**、1 条 (WT08) 上排第 2，排序中位数为 1.0，平均百分位 0.975。

**观察 3 (C→A 的方向与该位置的特异性) .** 第 18 位的 C→A 平均变化为 **-12.425**，而其余 19 个存在可用 C→A 替换的位置平均仅 +0.144。即：在该位置上把 C 换成 A 会明显降低外部模型的预测评分，而同样操作放在别处则几乎没有影响。这与 §3.9 的定向扰动结果自洽。

**统计证据.** 每条序列在第 18 位只有 1 个观测，样本量不足以做位置间显著性检验。本文**只报描述统计与排名**，不报告  $p$  值。

**解释 (假设) 与边界.** 饱和实验的设计意义在于：它不是”我们想看第 18 位”，而是”穷举所有位置后第 18 位自己浮出来”。因此”第 18 位是外部模型最敏感的位置”这一陈述不再依赖于位置选择。但边界同样明确：这仍是**模型内部反事实 (E4)**。一个对输入某位置高度敏感的模式，可能在真实细胞中完全错误。第 18 位是否真的影响编辑效率，只能由 E5 (实验) 回答。

**表 11: 反事实扰动证据：**在 8 条 WT 序列上对 23 nt 靶序列的**全部单碱基替换**做饱和 in-silico 突变，并用外部模型 CRISPRon 评分。共 552 条替换记录 (8 序列  $\times$  23 位点  $\times$  3 种替换)，其中 48 条破坏 PAM 而无法被 CRISPRon 识别、被排除，剩 504 条计分；21 个位置可排名，20 个位置存在可用的 C→A 替换。第 18 位的 C→A 平均变化为 -12.425，而其余位置平均仅 +0.144；按平均  $|\Delta|$  计，第 18 位 (12.86) 在 21 个位置中**排名第 1**。逐序列看，第 18 位在 8 条序列中的 7 条上排序第 1、1 条上第 2 (排序中位数 1.0)。全部数值为**模型内部反事实**，不是实验测量。

| pos | 平均 $ \Delta $ | 排名 | pos | 平均 $ \Delta $ | 排名 | pos | 平均 $ \Delta $ | 排名 |
|-----|---------------|----|-----|---------------|----|-----|---------------|----|
| 1   | 3.22          | 14 | 8   | 3.57          | 11 | 15  | 5.22          | 6  |
| 2   | 2.60          | 20 | 9   | 3.32          | 13 | 16  | 5.36          | 5  |
| 3   | 3.09          | 17 | 10  | 2.92          | 18 | 17  | 7.68          | 2  |
| 4   | 3.19          | 15 | 11  | 3.83          | 9  | 18  | 12.86         | 1  |
| 5   | 3.69          | 10 | 12  | 3.56          | 12 | 19  | 6.99          | 4  |
| 6   | 3.18          | 16 | 13  | 4.54          | 7  | 20  | 7.18          | 3  |
| 7   | 2.77          | 19 | 14  | 4.14          | 8  | 21  | 2.13          | 21 |

### 3.11 观测性关联：第 18 位碱基效应及其细胞背景依赖 (E2)


**问题与方法.** 上述 E3/E4 全部是模型产物。作为一条与模型**无关**的证据线，我们直接比较实测标签：按第 18 位碱基分组，计算各细胞系的平均归一化效率。

**观察 1 (方向与模型一致, 但幅度依赖细胞系)**. 第 18 位 C 减 A 的实测平均效率差为: HCT116 +0.090 (C 0.309 vs A 0.219)、HeLa +0.092 (0.315 vs 0.223)、HL60 +0.027 (0.256 vs 0.229)、**HEK293T -0.015 (0.224 vs 0.239, 方向反转)** (图 7B)。

**观察 2 (同一关联在外部数据集上的强度不同)**. 作为独立对照, 我们计算了 GC 含量 (protospacer 20 nt) 与实测效率的相关: Hiranniramol  $r = +0.262$  ( $p < 10^{-4}$ ), 而 Labuhn  $r = +0.094$  ( $p = 0.054$ , 不显著)。这与 §3.2 的结论一致: 同一个”序列-效率”关联家族, 在 **Hiranniramol 上可检出、在 Labuhn 上检不出**。

**统计证据.** 观察 1 的差值来自实测标签的分组比较 (观测性关联; 各细胞系 C 组样本量不足以支撑位置  $\times$  碱基的完整交叉检验), **不是模型产物**。观察 2 的  $p$  值为单变量 Pearson 相关的  $p$  值, 未做多重校正 (仅作两数据集对照, 不用于筛选)。

**解释 (假设) 与边界.** 综合 E2-E4 三条独立线索, 第 18 位获得了三方支持: 模型归因把它排在首位 (E3)、本文模型族与独立外部模型对它的扰动方向一致 (E4)、实测标签在三个细胞系上给出同向的碱基关联 (E2)。但三者都不能推广为因果, 且 E2 本身揭示了一个必须报告的限制: **该关联在 HEK293T 上方向反转**。因此本文表述为”细胞背景依赖的观测性关联”, 而不是”第 18 位碱基决定效率”。



**图 7: 细胞背景下的效应异质性。** (A) 各环境因子的平均  $\Delta R^2$  按细胞系展开 (排除发散行)。(B) 第 18 位碱基效应在四个细胞系中的方向与幅度 (HCT116/HeLa 为正且较大, HL60 较小, HEK293T 反向)。(C) 按模型与划分统计的 cell-line context 标签分布: 冲突与不确定占多数。

### 3.12 证据整合与生物学假设 (E1-E4 汇总, 无 E5/E6)

**问题与方法 (RQ3).** 如何把预测增量、模型归因、外部验证、反事实扰动与观测性关联组织为可比较、可追溯的证据, 并据此排定后续实验的候选?

**观察 1 (环境因素: 四个因子全部为 Inconclusive)**. CTCF、DNase、H3K4me3、RRBS 均未通过 effect 门 ( $|\Delta R^2|$  为  $3.2 \times 10^{-4}$ – $1.5 \times 10^{-3}$ , 门槛 0.01), 跨模型 bootstrap 区间全部跨 0; CTCF 与 H3K4me3 另带 cell-line Context-conflicting 标签, DNase 与 RRBS 为 Uncertain。因此四者均判为 **Inconclusive** (表 6、图 8)。

**观察 2 (序列层面: 四个非模型类一致, 区域层级部分一致)**. 一致的部分是 PAM 邻近位置在位置层级被四个非模型类排在最高位 (XGBoost/CNN/MLP/Transformer 的逐上下文峰值有 65.6%–100% 落在 17–20); 分歧的部分包括线性模型峰值在第 1 位 (且把五模型平均谱的峰值拉到第 1 位)、Transformer 注意力与梯度/树归因不一致、以及 CNN/MLP 在区域汇总下更偏向种子核心区。这些分歧被保留为 model-dependent evidence, 而不被平均掉。

**观察 3 (本文证据链的收敛点: 第 18 位的三方独立支持)**. 表 12 汇总第 18 位在六层证据框架中的位置。该位置是本文唯一同时获得 E2、E3、E4 三层独立支持的候选, 且其中最关键的跨系统一致性 (§3.9) 与无位置预设的饱和检验 (§3.10) 均为本文新增。

**观察 4 (其余候选)**. 除第 18 位外, 按预设标准还筛出两类候选序列模式破坏 (表 13): C2 为 GAGG (出现在全部 3 个 CNN 核变体, carrier-vs-background 效应 +0.012, Fisher OR= 1.11, BH-FDR= 0.031), C3 为 GGGG (2 个核变体, 效应 +0.060, OR= 1.38, BH-FDR=  $3.2 \times 10^{-5}$ )。两者均仅在单一细胞系 (HeLa) 中达到富集显著 (BH-FDR < 0.05), 故优先级低于 C1。


**统计证据.** 观察 1 的门槛与区间判定见 §2.12; 观察 3–4 汇总的是已在各小节报告过的量, 此处不引入新的检验。

**解释 (假设) 与边界: 一个可证伪的生物学假设.** 综合上述, 本文提出的假设是:

在本文数据所覆盖的 *sgRNA* 中, *PAM* 邻近区第 18 位的碱基身份与编辑效率存在关联, 且该关联的方向在多个模型族与一个独立外部模型上一致; 把第 18 位由 *C* 替换为 *A* 会降低编辑效率。该效应的大小依赖于细胞背景。

该假设的可证伪形式与最小扰动方案为: 保持 *sgRNA* 其余 22 nt 完全不变, 仅替换第 18 位 ( $C \leftrightarrow A$ ), 在同一实验体系中测定归一化编辑效率并做配对比较; 预期方向为  $C > A$ , 预期效应量参考 E2 的观测差 (HCT116/HeLa 约 +0.09) 与 E4 的外部模型预测 ( $\Delta_{\text{CRISPRon}} = -12.43$  分)。若配对实验显示方向相反或效应为零, 则该假设被推翻。

必须强调其证据边界: **所有候选均为待验证假设, 本文不包含任何湿实验验证。** 第 18 位的方向性结论由模型内部扰动 (E4) 与观测性碱基关联 (E2) 支持, **不构成因果证据**; 模型归因的一致性 (E3) 也不等于生物学正确性——多个模型类一致只能说明它们依赖了相似的特征, 不能排除它们共同依赖了数据中的混杂结构。这正是本文引入独立外部模型 (E4) 与饱和扰动的原因, 也是这些证据仍止步于 E4 的原因。



**图 8:** 证据整合: 环境因子的跨模型平均主效应与 95% bootstrap 区间, 并标注证据等级。四个因子全部为 Inconclusive, 且  $|\Delta R^2|$  均小于 0.01。Importance- $\Delta R^2$  辅助视图见补充图 9。

表 12: 本文证据链的收敛点: 第 18 位在六层证据框架中的支持情况。三方支持来自互相独立的证据来源 (模型归因、外部模型扰动、实测标签关联), 这是本文最强的计算证据组合; 但缺少 E5 (实验) 证据, 因此止步于假设。

| 层  | 该层对第 18 位的结论                                                   | 关键数字                                                                               | 独立性来源                |
|----|----------------------------------------------------------------|------------------------------------------------------------------------------------|----------------------|
| E1 | 不直接评价位置 (评价整体预测能力)                                             | 跨数据集 $R^2$ : 0.067–0.120 / 0.345–0.489 / 全负                                        | 三个独立数据集              |
| E2 | 第 18 位 C 组的实测效率高于 A 组 (HCT116/HeLa/HL60)                       | +0.090 / +0.092 / +0.027; HEK293T −0.015 (反转)                                      | 实测标签, 与模型无关          |
| E3 | 四个非模型类 (XGBoost/CNN/MLP/Transformer) 的位置归因峰值集中在 PAM 邻近窗口 17–20 | 逐上下文峰值落在 17–20 的比例 65.6%–100%; 单模型谱峰值分别为第 18、20、18、19 位。Linear 例外 (21.9%, 峰值第 1 位) | 五类不同归纳偏置 (但不独立于数据)   |
| E4 | 本文 7 模型与独立外部模型 CRISPRon 对 C18A 的扰动方向 7/8 一致; 饱和突变把第 18 位排 1/21 | $r = 0.629$ , $\rho = 0.476$ ; C→A 均值 −12.425 vs 其余 +0.144                         | 独立第三方模型 (不同数据、编码、尺度) |
| E5 | 无                                                              | —                                                                                  | —                    |
| E6 | 不作断言                                                           | —                                                                                  | —                    |

表 13: Candidate hypotheses prioritised from the existing results for minimal follow-up perturbation experiments. No wet-lab validation was performed in this study; effects are model-derived or measured associations, not causal estimates.

| candidate                                       | type              |                                                       |
|-------------------------------------------------|-------------------|-------------------------------------------------------|
| C1: position-18 base substitution               | single-nucleotide | peak in 17-20 window for 4/5 model classes (minimum 2 |
| C2: GAGG candidate pattern (enriched)           | motif disruption  |                                                       |
| C3: GGGG candidate pattern (most enriched)      | motif disruption  |                                                       |
| reference: CTGG (highest support, not enriched) | motif disruption  |                                                       |

**表 14:** 本文使用的六层证据分类。每一层回答不同的问题、有不同的失效模式，且不能相互替代：低层证据不能升级为高层证据，高层证据的存在也不能反推低层证据。全文每一处结论均在括号中标注其所属层（E1–E6）。本文**不含任何 E5 证据**，因此不产生任何 E6 层面的因果断言。

| 层  | 名称    | 回答的问题           | 本文中的实例                                                    | 该层 <b>不能</b> 支持     |
|----|-------|-----------------|-----------------------------------------------------------|---------------------|
| E1 | 预测证据  | 模型能否在未见样本上预测标签？ | 测试集 $R^2$ /Pearson/Spearman；跨数据集复现；CRISPRon 的 WT/C18A 评分差 | 因果；机制；模型”理解”了生物学    |
| E2 | 关联证据  | 标签与某可观测属性是否同变？  | 第 18 位 C 与 A 分组的实测效率差（按细胞系）；GC 含量与效率的相关系数                 | 因果；方向性机制；对该属性的干预效应  |
| E3 | 归因证据  | 模型输出依赖输入的哪些部分？  | 线性系数、TreeSHAP、IG、CNN 逐位点归因、注意力                            | 统计显著性；生物学重要性；因果     |
| E4 | 反事实证据 | 模型在输入被扰动后如何响应？  | 符号化 ISM（第 18 位 C→A/G/T）；逐位点饱和突变；候选模式破坏                    | 真实编辑效率的变化；实验可验证的效应量 |
| E5 | 实验证据  | 真实实验中扰动是否改变结果？  | 本文无（见 §7 的预登记实验设计）                                        | 超越所测体系的外推           |
| E6 | 因果证据  | 干预是否在该体系中导致效应？  | 本文不作任何此类断言                                                | —                   |

4 讨论

4.1 最重要的发现是一个阴性结果：序列可预测性不可移植

本文最初的预期是”在严格无泄漏的评估下，序列信号会下降但依然存在”。三个数据集的受控复现实验给出了更尖锐的答案：信号在 DeepCRISPR 上弱（中位  $R^2$  0.067–0.120）、在 Hiranniramol 上强（0.345–0.489）、在 Labuhn 上**完全不存在**（全部为负）。而且这不是划分造成的假象——一个与官方划分完全无关的全数据交叉验证给出同向结论，Labuhn 的 CV  $R^2$  (−0.144) 仅比它自己的标签置换零分布 (−0.287 ± 0.050) 高 0.14。

这一结果的实践含义是直接的：”某模型在 sgRNA 效率预测上达到  $R^2 = 0.7$ ”这类陈述，**不能作为关于 sgRNA 设计的一般性知识被引用**，除非同时说明它在哪些独立数据集上被复现、以及复现失败的比例。这也解释了为什么独立基准测试反复观察到”报告性能在严格评估下明显下降”[Zhang et al., 2023, Konstantakos et al., 2022]：问题可能不只是评估不够严格，而是**可预测性本身强烈依赖具体的数据集**。

本文因此把”复现”从一句声明变成了一个需要逐数据集报告的结果。我们刻意保留了复现失败的数据集，而不是只报告成功的那个——后者会让结论看起来强得多，但也会让读者无法判断该结论的适用边界。

## 4.2 归因需要外部系统才能成为可检验的陈述

多模型归因在文献中常被当作“解释”的终点：如果线性系数、SHAP、IG 与注意力都指向同一个位置，似乎就可以说该位置重要。本文的做法揭示了两点。

**第一，多模型一致本身不能排除共同混杂。**本文五类模型共享同一份数据、同一份标签与同一套预处理；它们一致指向第 18 位，原则上也可能是因为它们共同依赖了数据中某个与第 18 位相关的结构（例如该位点的碱基分布与 GC 含量、与 locus 类型、与细胞系组成的耦合）。仅凭 E3 无法区分“第 18 位重要”与“第 18 位是某个混杂的代理”。

**第二，换一个系统可以明显提高证据强度。**当我们用 CRISPRon——一个由他人训练、使用 30 nt 窗口与 CRISPRoff 能量项、输出 0–100 复合评分的模型——去预测同一个最小扰动时，两个系统在 8 个预登记实例中的 7 个上方向一致，且变化幅度正相关 ( $r = 0.629$ )。这一步不能证明第 18 位在生物学上重要（那需要 E5），但它确实把结论从“我们的模型这样做”推进到“两个独立构造的模型系统对同一扰动给出同向响应”。这是 E3 无法单独达到的强度。

我们特意保留了两处“不好看”的结果，因为它们是这一结论可信度的条件：唯一分歧样本 WT08 被保留在统计中；饱和突变虽然把第 18 位排在第 1，但第 2 名（第 17 位，7.68）与第 3 名（第 20 位，7.18）并不遥远，说明第 18 位的突出是量级上的而非类别上的。

## 4.3 “未检出”是结果，不是失败

本文报告了三类阴性或未检出结果：环境通道无增量预测证据（四因子均 Inconclusive）、跨细胞系迁移失败（LOCO 中位  $R^2$  与 0 不可区分）、Labuhn 上无序列信号。它们各自有不同性质，不应被笼统地归为“模型不行”。

**环境通道的结果有明确的可检测性上限。**四个因子的  $|\overline{\Delta R^2}|$  为  $3.2 \times 10^{-4}$ – $1.5 \times 10^{-3}$ ，比预设门 0.01 低 1–2 个数量级，跨模型区间全部跨 0，析因 ANOVA  $p = 0.975$ – $0.9996$ 。三者一致。但这一“未检出”受两个具体限制约束：环境通道只有 4 条二值轨道，不足以代表完整 cell state；若干细胞系–通道组合近乎常数，直接压缩了可检测效应上限。因此正确的陈述是“在通用多细胞系设定与该编码分辨率下未检出”，而不是“表观遗传信息与编辑效率无关”——已有研究在特定细胞类型中报告了表观特征带来的增益 [Ito et al., 2024, Luboshitz et al., 2026]，而另一些研究报告加入 DNase 轨道后并未提升性能 [Wang et al., 2019]。本文的结果与后者一致。

**跨细胞系迁移的失败夹杂了训练集缩减。**LOCO 的训练池因剔除留出系同源身份类而缩减至 1453–12313 条，“分布漂移”与“样本减少”两种因素在本文数据中不可分离 (§5)。因此本文只报告“与均值基线不可区分”，不报告“跨细胞系必然失败”。

## 4.4 把“能说什么”写进方法：六层证据的实际作用

六层证据分类（表 14）不是装饰性的，它在本文中至少三次改变了结论的写法。

**第一次：防止 E3 冒充统计证据。**归因幅值在本文中被明确排除在证据等级判定之外，SNR 也明确为辅助标注而非检验统计量 (§2)。因此“第 18 位归因最高”这句话只能写成描述性汇总，不能写成“显著”。

**第二次：防止 E4 冒充 E5。**外部模型验证得到 7/8 的一致性，这是一个相当整齐的结果。如果没有证据分层，很容易被写成“第 18 位替换降低编辑效率”。本文统一表述为“两个模型系

统对同一扰动的预测变化方向一致”，并明确指出这仍是模型行为。WT08 的分歧也因此在此文中被如实保留，而不是作为噪声处理。

**第三次：防止 E2 与 E3/E4 的”三方一致”被升级为因果。**三条线索方向一致确实提高了候选的可信度，但 E2 自身就揭示了反例（HEK293T 上方向反转）。三条线索不能相互替代：E2 是观测关联，E3 是模型依赖，E4 是模型扰动。它们在同一位置的汇合说明该位置值得实验检验，仅此而已。

#### 4.5 平台定位：不是更高精度，而是更清楚的分界

本文不主张平台在预测精度上优于已有方法。DeepCRISPR 主数据集上的中位  $R^2$  仅 0.067–0.120，跨细胞系迁移失败，环境通道无增益；这些数字都低于文献中常见的报告值，而本文认为这种”低”更接近严格评估下的真实水平。平台的贡献在于把”哪些结论在什么证据强度上成立”变成流程的输出：数据质量审计给出 E1 的可信度前提，跨数据集复现给出 E1 的适用边界，归因与外部验证给出 E3/E4 的收敛点，观测性关联给出 E2 的独立对照，候选表给出 E5 的实验设计，而证据分层确保这五者不会被混为一谈。

这也带来一个方法学上的连带结果：本文在整改自身历史批次的泄漏时，发现并修正了一个更隐蔽的问题——同一批 run 同时产出测试集与验证集指标，而审计脚本依赖文件枚举顺序取值，导致数值发散计数在两个口径间漂移（33 与 20）。该缺陷不影响任何模型训练，但会影响”结果是否可信”这类元数据的准确性。我们把它写进论文而不是静默修掉，因为它正属于本文主张要审计的那一类问题：**报告数字的口径必须被显式固定并被代码强制。**

## 5 局限性

本节把限制按”复现实验的可比性、数据、模型与评估、外部验证、因果、泛化”六层列出，并在每一条后标注本文是否已给出对应证据。凡本文未能验证者，一律标为未解决，不以推断代替证据。

### 5.1 复现实验的可比性

1. **三个数据集并非同分布，规模差异大。**DeepCRISPR 16 749 条（4 细胞系、含 4 条表观通道）、Hiranniramol 1 309 条（单细胞系、仅序列）、Labuhn 417 条（单细胞系、仅序列）。因此”信号在 Hiranniramol 上强、在 Labuhn 上无”这一差异中，规模与数据集本身两个因素无法完全分离。本文的辩护是：规模可以解释”更难”，但不能解释 Labuhn 上 7/7 个配置全部为负这一方向性事实，且 Hiranniramol 与 Labuhn 在规模、细胞系数、通道数上同类却结论相反。状态：已量化（表 4），混杂未完全消除。
2. **每个外部数据集只有一次 *single* 划分。**Hiranniramol 与 Labuhn 各只有 7 次运行（7 个模型，单次划分），因此无法给出配置间的分布或中位数区间，也不能对数据集间  $R^2$  差异做显著性检验。本文的补偿措施是与官方划分无关的 5 折 CV 复核 (§3.2)。状态：已用独立复核补偿，但重复次数仍为 1。
3. **两个外部数据集的标签语义与 DeepCRISPR 不完全一致。**DeepCRISPR 为归一化编辑效率，Hiranniramol 原始为 Edit Efficiency（百分制），Labuhn 为 KO\_reporter\_assay。

适配器统一到  $[0, 1]$ , 但三者的测定方式、细胞体系与 readout 不同, 因此跨数据集的  $R^2$  不可读作”同一量的预测难度比较”, 只能读作”同一流程在不同数据集上的可预测性比较”。状态: 已在方法与表注中限定。

4. **外部数据集没有表观遗传通道, 因此无法检验环境结论的复现性。**本文关于”环境通道无增量预测证据”的结论仅来自 DeepCRISPR, 没有第二个带表观通道的数据集可供复现。状态: 未解决。

## 5.2 数据层面

1. **使用公开数据, 非本研究自建实验。**全部标签与表观轨道来自公开数据集 [Chuai et al., 2018, Hiranniramol et al., 2020, Labuhn et al., 2018], 其 library 设计、实验批次与筛选条件由原始研究决定; 本研究无法追溯每个位点的实验批次效应。状态: 已确认的边界, 不可由本文数据解决。
2. **DeepCRISPR 内部细胞系数数量有限且不平衡。**仅 4 个细胞系, 样本量 2076–8101 (相差近 4 倍)。混合与 LOCO 划分下, 训练与测试的细胞系构成差异会同时改变样本量与序列组成, 本文无法完全分离二者影响。状态: 已量化 (表 2), 未解决。
3. **环境变量仅四条且分辨率有限。**CTCF、DNase、H3K4me3、RRBS 为逐位点二值可及性编码; 四个通道不足以代表完整 cell state (三维染色质结构、转录因子占据、细胞周期、DNA 修复状态等未纳入)。部分细胞系–通道组合近似常数, 会直接压缩可检测效应上限。状态: 已报告效应量级与区间 (§3.5), 但未逐通道量化方差, 属未解决。
4. **泄漏审计的身份类仅覆盖序列与反向互补。**本文审计覆盖 sequence 与 reverse-complement 两个层级, 未覆盖同一 locus 的不同序列、同源但不完全相同的序列以及公共数据库层面的重复提交。状态: 审计边界已明确 (§3.1); 更广层级的污染未排除。
5. **历史泄漏批次的对照受限于两批可比的统计量。**本文仅在 *single/mixed/all* 三个中位  $R^2$  上做前后对照 (§3.4), 未对旧批次重算全部下游分析。状态: 对照范围有限, 已在文中标注。

## 5.3 模型与评估层面

1. **预测性能总体较弱, 且在 Labuhn 上为负。**DeepCRISPR *single* 中位  $R^2$  为 0.067–0.120, *mixed* 为 0.041–0.094, LOCO 为  $-0.027$  至  $+0.010$ ; Labuhn 全部为负 ( $-0.725$  至  $-0.050$ )。本文不将预测精度作为主要贡献, 也不据此判断生物学重要性。状态: 已量化 (表 5、表 4)。
2. **LOCO 的”分布漂移”与”训练集缩减”混杂。**为保证无同源泄漏, LOCO 训练池剔除了与留出系共享身份类的全部序列 (HCT116 留出时剔除 4266 条、HeLa 4285 条、HL60 173 条、HEK293T 0 条), 训练样本量随留出系由 12313 降至 1453。跨细胞系性能下降同时包含两种原因, 本文无法在本数据中定量分离。状态: 剔除条数已量化, 混杂未解决。

3. **模型选择未独立于评估集。**平台在同一批测试集上比较 7 个模型配置与 16 个环境组合，属探索性比较；虽有配对设计与 bootstrap/置换稳健性检验，仍存在选择偏差风险。本文不把“某配置最优”作为结论。状态：已声明，未通过嵌套验证解决。
4. **不同模型的 attribution 语义不同。**线性系数、TreeSHAP、IG、ISM 与注意力权重在定义、尺度与可加性上均不同；本文在模型内部归一化后比较相对分布，并禁止跨模型比较绝对值。状态：已在方法与图注中限定。
5. **归因对超参数敏感。**CNN  $k = 7$  的归因谱与  $k = 3/5$  差异较大 (§3.7)，说明解释结果依赖模型配置；本文通过保留多配置交叉验证暴露该敏感性，而不选取单一“最好”配置。状态：已展示。
6. **自助区间的推断单位是模型而非样本。**因子级区间为 *Model-Level Bootstrap Interval* ( $n = 7$  个模型配置)；7 个模型共享同一份数据、标签、预处理与划分，不构成独立生物学重复，该区间刻画 effect 的跨模型稳健性，不应解释为总体抽样置信区间， $n = 7$  下百分位自助法的覆盖性质亦无严格保证。状态：已限定。
7. **部分 run 数值发散。**按测试集口径，20 个 Linear Regression run 出现  $|R^2| \geq 10$  (共线性设计矩阵导致病态求解)，全部被隔离而非删除，相关统计量以有效 run 数报告。状态：已量化并在表中单列。

#### 5.4 外部模型验证层面

1. **外部验证只有 8 个实例。**定向扰动的一致性 (7/8) 与幅度相关 ( $r = 0.629$ ,  $\rho = 0.476$ ) 均基于  $n = 8$ ，本文不对其做显著性检验，也不把 0.875 读作总体比例估计。状态：已限定；扩大样本量属未来工作。
2. **CRISPRon 本身也有误差，且不是“真值”。**本文使用 CRISPRon 作为独立系统，而不是作为金标准。两个模型系统方向一致，只能说明它们捕捉到同一统计结构；若该结构本身是数据中的系统性偏差，两者会一起错。状态：已明确 (§3.9 解释与边界)。
3. **WT 选择规则虽已预登记，但仍受候选池约束。**8 条 WT 取自 DeepCRISPR *single* 测试集且要求第 18 位为 C，因此该验证的总体是“第 18 位为 C 的 DeepCRISPR 序列”，不能自动外推到其它碱基或其它数据集。状态：规则与版本号已记录，适用范围已限定。
4. **30-mer 构造依赖参考基因组与链向判定。**外部验证需要从 hg19 补齐侧翼 (本文 23nt 序列本身不含侧翼)。链向取窗曾出现实现错误 (负链窗口反向)，修正后与参考序列逐条一致；但该步骤的正确性依赖坐标与基因组版本，本文通过逐条 QC 与额外靶点计数来约束，仍属需要外部复核的环节。状态：已逐条 QC 并记录；已确认 hg19 与数据一致 (hg38 为 6/6 不匹配)。

#### 5.5 因果层面

1. **预测关联不等于因果关系。**本文全部结果均为观察性数据上的预测、归因与模型反事实分析，不能支持“某因素导致编辑效率变化”的陈述。

2. **in-silico 饱和突变与 CRISPRon 打分都是模型内部反事实 (E4), 不是实验验证 (E5)。**  
第 18 位 C→A 的方向性结论刻画的是模型的敏感性, 而非 Cas9 在细胞内的行为。
3. **无湿实验验证。**本文未开展任何 guide 效率测定、竞争实验或结构实验, 所有”候选”均停留在待验证状态 (E5 为空)。
4. **观测性碱基关联存在混杂。**第 18 位 C 与 A 的效率差在不同细胞系中幅度与方向不同, 而四个细胞系的序列组成、样本量与标签分布均不同, ”位置 18 的碱基效应”与”携带该碱基的序列子集的其它特征”在本数据中不可完全分离 (E2)。
5. **模型归因的一致性不等于生物学正确性 (E3)。**多个模型类给出一致归因只能说明它们在当前数据上依赖了相似的特征, 不能排除它们共同依赖了数据中的混杂结构。这是本文引入外部模型验证的原因, 也是该验证仍止步于 E4 的原因。

## 5.6 泛化层面

1. **结论不可直接外推到其它 Cas 蛋白。**本文仅使用 SpCas9 (NGG PAM) 数据, 不覆盖 Cas12a、碱基编辑器、先导编辑或其它编辑模式。
2. **结论不可直接外推到其它细胞系与实验协议。**LOCO 结果显示跨细胞系迁移失败, 且三个数据集的复现结果互相矛盾, 因此性能结论不应外推到未参与训练的数据集或细胞类型。
3. **”序列可预测性不可移植”这一结论本身也需在更多数据集上检验。**本文只有两个外部复现数据集, 其中一成一败。更一般的主张需要更多独立数据集的系统采样; 本文只报告这一采样结果, 不把它当作普遍定律。
4. **平台层面的结论比具体数值更可外推。**”流程可追溯、泄漏可审计、证据可分层、外部模型可验证”属于方法学贡献; 具体效应量级与候选因素均限于本文数据集。

## 6 结论

本文以”多数据集复现 → 多模型外部验证 → 可解释分析 → 反事实扰动 → 生物学假设”为证据链, 在严格无泄漏、序列级不相交的评估下重新回答了”sgRNA 效率的序列信号有多可信、哪个位置值得实验检验”这两个问题。全文结论按六层证据 (E1-E6, 表 14) 组织, 每条均标注其强度与边界。

1. **数据可信度 (E1 前提, 穷举核对, 强):** 1344 次运行的实验矩阵完整, 1344/1344 的  $\text{train} \cap \text{test}$  序列重叠与反向互补重叠为 0, 划分摘要逐条复核一致, 全批运行于同一数据、代码与数值栈之上 (表 1)。按测试集口径, 数值发散 run 为 20 次 (全部为 Linear Regression)。
2. **序列可预测性是数据集依赖的, 不可移植 (E1, 强):** 在完全相同的特征、模型与评估流程下, DeepCRISPR *single* 划分的 7 个配置中位  $R^2$  为 0.067–0.120, Hiranniramol 为 0.345–0.489 (Transformer 最高,  $R^2 = 0.489$ , Pearson = 0.709), 而 Labuhn 的 7 个配置全部为负 (−0.725 至 −0.050)。与官方划分无关的全数据 5 折 CV 复核给出同向结论: Hiranniramol +0.389 (零分布  $-0.467 \pm 0.038$ ), Labuhn −0.144 (零分布  $-0.287 \pm 0.050$ )。Labuhn 的

失败机制可诊断为预测坍缩：6/7 个配置的预测标准差与标签标准差之比仅 0.03–0.37。本文据此不把”序列信号存在”写作普适结论。

3. **跨细胞系迁移失败 (E1, 强)**: 真实 LOCO 划分下 7 个配置的中位  $R^2$  全部落在  $-0.027$  至  $+0.010$ , 与均值基线不可区分; 按留出系展开异质性大 (HEK293T 最低,  $R^2 = -0.266$ )。该结果同时混杂训练池缩减 ( $n_{\text{train}} 1453-12313$ ), 故只报告”不可区分”。
4. **环境通道未获得增量预测证据 (E1, 强)**: CTCF、DNase、H3K4me3、RRBS 的  $|\overline{\Delta R^2}|$  为  $3.2 \times 10^{-4}-1.5 \times 10^{-3}$ , 比预设门槛 0.01 低 1–2 个数量级; 跨模型区间全部跨 0; 区组析因方差分析主效应  $p = 0.975-0.9996$ 。四者均为 **Inconclusive**。该结论是未检出, 不是无作用, 且仅来自 DeepCRISPR (两个外部数据集无表观通道)。
5. **四个非模型类的位置归因指向 PAM 邻近窗口, 线性模型例外; 区域层级仅部分一致 (E3, 中)**: XGBoost、CNN、MLP、Transformer 的逐上下文归因峰值落在第 17–20 位窗口的比例分别为 100.0%、96.9%、90.6%、65.6%, 其单模型平均谱峰值分别位于第 18、20、18、19 位; **线性模型仅 21.9%, 峰值在第 1 位**。把线性模型纳入等权平均后, 跨模型平均谱峰值是第 1 位 (0.0864) 而非第 18 位 (0.0799); 剔除线性模型后峰值才是第 18 位 (0.0878)。按粗粒度区域汇总时只有 2/5 的最高区域为 PAM 邻近种子区。**归因幅值不构成统计显著性证据**。
6. **独立外部模型验证 (E4, 中)**: 按预登记规则选出的 8 条第 18 位为 C 的 WT 序列上, 本文 7 个模型与独立第三方模型 CRISPRon 对 C→A 扰动的方向在 **7/8 条上一致** (幅度相关  $r = 0.629$ 、 $\rho = 0.476$ ,  $n = 8$ ); CRISPRon 侧 7/8 条为负向 (平均  $\Delta = -12.43$ )。唯一分歧样本 WT08 被保留。
7. **无位置预设的反事实扰动 (E4, 中)**: 对 8 条 WT 做全部 552 条单碱基替换的饱和 in-silico 突变 (48 条破坏 PAM 被排除), 第 18 位按平均  $|\Delta|$  **排名 1/21** (12.86, 第 2 名为 7.68), 逐序列看 7/8 条排第 1; 第 18 位 C→A 平均变化  $-12.425$ , 其余位置平均仅  $+0.144$ 。
8. **观测性关联独立支持同向结论, 但具细胞背景依赖 (E2, 中)**: 第 18 位 C 减 A 的实测平均效率差为 HCT116  $+0.090$ 、HeLa  $+0.092$ 、HL60  $+0.027$ 、**HEK293T  $-0.015$  (方向反转)**。作为独立对照, GC-效率相关在 Hiranniramol 上为  $r = +0.262$  ( $p < 10^{-4}$ )、在 Labuhn 上为  $r = +0.094$  ( $p = 0.054$ ), 与 RQ1 结论一致。
9. **泄漏整改的如实报告 (E1 方法学, 中)**: 排除跨细胞系同源序列后, *mixed* 中位  $R^2$  由 0.118 降至 0.073, LOCO 由  $+0.036$  降至  $-0.008$ , 而 *single* 划分基本不变 ( $0.070 \rightarrow 0.081$ )。本文把该下降作为主要发现之一报告, 而不是需要解释掉的异常。
10. **可证伪的候选假设 (E4, 弱一中, 无 E5)**: 本文输出一个生物学假设——第 18 位碱基身份与编辑效率关联, C→A 降低效率, 效应大小依赖细胞背景——及其最小扰动验证方案 (保持其余 22nt 不变, 仅替换第 18 位并做配对测定)。该假设同时获得 E2、E3、E4 三层互相独立的支持, 但不含任何 **E5 证据, 因此不构成因果结论**。

综上, 本文的贡献不在于报告一个高精度预测器, 也不在于证明某个序列位置具有因果作用, 而在于展示一套能把”数据是否可信””结论能否复现””归因能否被外部系统证实””假设能

否被实验验证”四件事分开回答、且每件事都有明确证据层级的流程。按其输出，本文对领域最直接的提醒是：在引用任何 sgRNA 效率预测性能之前，应当先问它在多少个独立数据集上被复现过。

## 7 未来实验验证 (E5 的设计)

本文不包含任何湿实验数据，因此证据链止于 E4。本节说明如何用最小实验设计把 E4 推进到 E5，并给出预先登记的判定标准。所有方向均按”最小扰动 + 配对比较 + 预登记判据”组织。

**方向一 (对应本文主要候选 C1): 第 18 位单碱基替换的配对测定。**这正是本文 E4 证据所指向的实验。设计：取本文 8 条 WT (或另选若干第 18 位为 C 的 sgRNA)，仅替换第 18 位碱基 ( $C \leftrightarrow A$ )，保持其余 22 nt 完全不变，在同一实验体系中测定归一化编辑效率并做**配对比较**。预登记判据：(i) 主判据为配对效率差的方向与显著性 ( $H_0: \Delta = 0$ ，双侧，预先设定  $\alpha$  与最小可检测效应)；(ii) 预期方向为  $C > A$ ，效应量参考 E2 的观测差 (HCT116/HeLa 约 +0.09) 与 E4 的外部模型预测 ( $\Delta_{\text{CRISPRon}} = -12.43$  分)；(iii) 至少在一个以上细胞系中重复，以检验平台提示的上下文依赖性 (E2 显示 HEK293T 方向反转)。读出指标建议与本文数据一致 (归一化编辑效率)，并预先登记样本量、重复次数与分层比较方案。

**方向二 (对应候选 C2/C3): PAM 邻近候选序列模式的序列破坏。**在包含目标 4 nt 核心的 sgRNA 中替换该核心，同时匹配 GC 含量与长度以控制混杂，比较携带与不携带核心序列的实测效率。由于富集证据目前仅见于单一细胞系 (HeLa)，实验应优先在该细胞系中进行，并在其它细胞系作为探索性重复。判据同样预登记为配对/分层比较。

**方向三 (对应本文最重要的阴性结果): 跨数据集复现性的系统采样。**本文的 RQ1 结论建立在一个主数据集与两个外部数据集上 (一成一败)，样本量为 3。要将”序列可预测性不可移植”从本文的观察提升为领域的规律，需要在更多独立数据集上系统重复同一流程，并报告复现成功率与成功/失败数据集的属性 (规模、library 设计、readout、细胞体系)。建议把本文的流程 (同一特征构造、同一批模型、同一身份类划分、同一评估脚本) 作为固定协议，把”数据集”作为唯一的变量。

**方向四 (对应外部验证的局限): 扩大外部模型验证的样本量。**本文的 7/8 一致性基于 8 个预登记实例，无法做显著性检验。建议按同一预登记规则把实例数扩大到可支持区间估计的规模，并引入**第二个独立外部模型** (不同作者、不同架构)，从而检验”跨系统一致性”是否只是 CRISPRon 的特例。

**方向五 (方法学): 分离 LOCO 中的”分布漂移”与”训练集缩减”。**本文 LOCO 中两种因素混杂 (§5)。建议的对照设计为：在保持训练样本量不变的前提下构造无同源泄漏的训练池 (例如对留出系同源序列做等量重采样替代)，从而分离二者的贡献。

**方向六 (方法学): 环境结论需要第二个带表观通道的数据集。**本文”环境通道无增量预测证据”仅来自 DeepCRISPR。要判断该结论是数据集特异还是普遍，需要引入另一个同时具备序列与表观通道、且覆盖多细胞系的数据集，并复用同一套 lattice 边与析因分析。

**预期输出与判定标准。**上述方向的预期输出为”候选假设被支持/不被支持”的判定与效应量估计；判定应基于预先登记的统计方案 (分层或配对比较、多重检验校正) 并使用与本文一致的指标口径。特别地，**方向一是唯一能把本文最强候选从 E4 推进到 E5 的实验**；若其结果

与 E2/E3/E4 的三方一致方向矛盾, 则本文的主要候选假设被推翻——这正是该假设可证伪性的体现。

## 数据与代码可用性

**数据.** 三个数据集均来自公开资源: DeepCRISPR[Chuai et al., 2018]、Hiranniramol[Hiranniramol et al., 2020] 与 Labuhn[Labuhn et al., 2018]。原始文件位于 `data/raw/< 数据集 >/`, 处理后特征、标签与元数据位于 `data/processed/< 数据集 >/` (DeepCRISPR 为  $23 \times 8/184$  维, 两个外部数据集为  $23 \times 4/92$  维)。数据集适配、重复测量合并与 23nt 构造的规则见 `docs/reproducibility/EXTERNAL_DATA`。数据划分与泄漏审计代码位于 `core/data/splitting/`。

**结果批次.** 本文全部性能结论仅来自三个批次: 主批次 `ultimate_run` (1344 次运行, *single/all/mixed* 各 448)、外部复现批次 `ultimate_run_1` (Hiranniramol, 7 个模型) 与 `ultimate_run_2` (Labuhn, 7 个模型)。主批次的逐 run 验收明细 (覆盖度、划分摘要复核、序列与反向互补重叠、数据/代码/环境指纹、设备) 由 `deploy/hpc/verify_hpc_rerun.py` 生成并保存为 `results/tables/audit/ultimate_run_verify_{runs,summary,report}.csv/md`。存在已确认划分泄漏的历史批次 `batch_20260909_full` 已标记废弃, 仅用于 §3.4 的前后对照, 不作为任何结论依据。

**外部模型验证.** 第三方模型 CRISPRon 的官方发行包与依赖 (含 SHA-256 校验和) 位于 `deploy/external/crispron/package/` 与 `deploy/external/crispron/dependencies/`; 安装记录、与官方安装的唯一偏离 (PyPI 版 ViennaRNA 缺少 RNAfold 可执行文件, 改用同版本 Python API 等价 shim) 及其**黄金测试等价性证明**见 `deploy/external/crispron/INSTALL_NOTES.md` 与 `logs/selftest_result.md`; 适配器、输入映射与 QC 位于 `analysis/external_validation/`。野生型选择规则 (版本号 `wt-pos18-representative-v1`) 实现在 `analysis/candidates/wt_position18_selection`。其“不使用任何突变侧信息”的约束由脚本内断言强制执行。运行记录、原始输出与审计清单位于 `results/external_validation/<run>/`。完整方法说明见 `docs/reproducibility/EXTERNAL_MODEL_VALIDATION`。

**图表与表格的生成.** 全部图表由结果文件重新计算生成, 不手工填写:

- 图 1-7 与表 2-6: `analysis/reporting/paper/make_assets.py --batch ultimate_run` 与 `analysis/reporting/paper_analysis/build_paper_tables.py --batch ultimate_run`;
- 数据质量表 (表 1): `analysis/reporting/paper/make_data_quality_table.py --batch ultimate_run`;
- 跨数据集复现所需的全部数字 (表 2、表 4): `analysis/paper_numbers.py`, 落盘为 `results/paper_rewrite/authoritative_numbers.json`;
- 本文新增的外部验证与反事实扰动表 (表 10、表 11、表 14): `analysis/reporting/paper_rewrite/build_` 数字直接取自 `results/tables/external_validation/` 与上述 JSON。

分析方案 (AnalysisPlan)、任务执行状态与每个任务的产物路径随批次一并保存 (`summary/analysis_plan.analysis_status.json`、`execution_log.json`), 可逐项追溯 (附录 A.1)。

**口径约定.** 本文所有性能数字一律为**测试集口径**(\*\_metrics.json),验证集口径(\*\_validation\_metrics.json),仅用于最优 epoch 选择。该约定在 `deploy/hpc/verify_hpc_rerun.py` 中由代码强制 (显式排除验证集文件),并在 §3.1 披露了因早期版本未区分两者而导致的计数偏差 (33 vs 20)。

## 作者贡献

(待补)

## 利益冲突声明

作者声明不存在利益冲突。

## 参考文献

- Martin Jinek, Krzysztof Chylinski, Ines Fonfara, Michael Hauer, Jennifer A. Doudna, and Emmanuelle Charpentier. A programmable dual-RNA-guided DNA endonuclease in adaptive bacterial immunity. *Science*, 337(6096):816–821, 2012. doi: 10.1126/science.1225829.
- Le Cong, F. Ann Ran, David Cox, Shuailiang Lin, Robert Barretto, Naomi Habib, Patrick D. Hsu, Xuebing Wu, Wenyan Jiang, Luciano A. Marraffini, and Feng Zhang. Multiplex genome engineering using CRISPR/Cas systems. *Science*, 339(6121):819–823, 2013. doi: 10.1126/science.1231143.
- Ophir Shalem, Neville E. Sanjana, Ella Hartenian, Xi Shi, David A. Scott, et al. Genome-scale CRISPR-Cas9 knockout screening in human cells. *Science*, 343(6166):84–87, 2014. doi: 10.1126/science.1247005.
- John G. Doench, Ella Hartenian, Daniel B. Graham, Zuzana Tothova, Mudra Hegde, Ian Smith, Megan Sullender, Benjamin L. Ebert, Ramnik J. Xavier, and David E. Root. Rational design of highly active sgRNAs for CRISPR-Cas9-mediated gene inactivation. *Nature Biotechnology*, 32(12):1262–1267, 2014. doi: 10.1038/nbt.3026.
- Miguel A. Moreno-Mateos, Charles E. Vejnár, Jean-Denis Beaudoin, Juan P. Fernandez, Emily K. Mis, Mustafa K. Khokha, and Antonio J. Giraldez. CRISPRscan: designing highly efficient sgRNAs for CRISPR-Cas9 targeting in vivo. *Nature Methods*, 12(10):982–988, 2015. doi: 10.1038/nmeth.3543.
- Babak Alipanahi, Andrew DeLong, Matthew T. Weirauch, and Brendan J. Frey. Predicting the sequence specificities of DNA- and RNA-binding proteins by deep learning. *Nature Biotechnology*, 33(8):831–838, 2015. doi: 10.1038/nbt.3300.
- David R. Kelley, Jasper Snoek, and John L. Rinn. Basset: learning the regulatory code of the accessible genome with deep convolutional neural networks. *Genome Research*, 26(7):990–999, 2016. doi: 10.1101/gr.200535.115.

- Guohui Chuai, Hanhui Ma, Jifang Yan, Ming Chen, Nanfang Hong, Dongyu Xue, Chi Zhou, Chenyu Zhu, Ke Chen, Bin Duan, Fei Gu, Shuang Qu, Deshuang Huang, Jia Wei, and Qi Liu. DeepCRISPR: optimized CRISPR guide RNA design by deep learning. *Genome Biology*, 19(1):80, 2018. doi: 10.1186/s13059-018-1459-4.
- John G. Doench, Nicolo Fusi, Meagan Sullender, Mudra Hegde, Emma W. Vaimberg, Katherine F. Donovan, Ian Smith, Zuzana Tothova, Craig Wilen, Robert Orchard, Herbert W. Virgin, Jennifer Listgarten, and David E. Root. Optimized sgRNA design to maximize activity and minimize off-target effects of CRISPR-Cas9. *Nature Biotechnology*, 34(2):184–191, 2016. doi: 10.1038/nbt.3437.
- Hui Kwon Kim, Seonwoo Min, Myungjae Song, Sooim Jung, Jae Woo Choi, et al. Deep learning improves prediction of CRISPR–Cpf1 guide RNA activity. *Nature Biotechnology*, 36(3):239–241, 2018. doi: 10.1038/nbt.4061.
- Hui Kwon Kim, Younggwang Kim, Sungtae Lee, Seonwoo Min, Ji Yeon Bae, et al. SpCas9 activity prediction by DeepSpCas9, a deep learning-based model with high generalization performance. *Science Advances*, 5(11):eaax9249, 2019. doi: 10.1126/sciadv.aax9249.
- Xi Xiang, Giulia I. Corsi, Christian Anthon, et al. Enhancing CRISPR-Cas9 gRNA efficiency prediction by data integration and deep learning. *Nature Communications*, 12:3238, 2021. doi: 10.1038/s41467-021-23576-0.
- Guishan Zhang, Yuhang Luo, Xiaowen Dai, and Zhiming Dai. Benchmarking deep learning methods for predicting CRISPR/Cas9 sgRNA on- and off-target activities. *Briefings in Bioinformatics*, 24(6):bbad333, 2023. doi: 10.1093/bib/bbad333.
- Vasileios Konstantakos, Anastasios Nentidis, Anastasia Krithara, and Georgios Paliouras. CRISPR–Cas9 gRNA efficiency prediction: an overview of predictive tools and the role of deep learning. *Nucleic Acids Research*, 50(7):3616–3637, 2022. doi: 10.1093/nar/gkac192.
- Hui Yuan, Chao Song, Han Xu, Yu Sun, Christian Anthon, et al. An overview and comparative analysis of CRISPR–SpCas9 gRNA activity prediction tools. *The CRISPR Journal*, 8(2): 89–104, 2025. doi: 10.1089/crispr.2024.0058.
- Shachar Kaufman, Saharon Rosset, Claudia Perlich, and Osnat Stitelman. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4):1–21, 2012. doi: 10.1145/2382577.2382579.
- Sayash Kapoor and Arvind Narayanan. Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9):100804, 2023. doi: 10.1016/j.patter.2023.100804.
- Judith Bernett, David B. Blumenthal, Dominik G. Grimm, et al. Guiding questions to avoid data leakage in biological machine learning applications. *Nature Methods*, 21:1444–1453, 2024. doi: 10.1038/s41592-024-02362-y.

- Sean Whalen, Jacob Schreiber, William S. Noble, and Katherine S. Pollard. Navigating the pitfalls of applying machine learning in genomics. *Nature Reviews Genetics*, 23(3):169–181, 2022. doi: 10.1038/s41576-021-00434-9.
- Jacob Schreiber, Ritambhara Singh, Jeff Bilmes, and William Stafford Noble. A pitfall for machine learning methods aiming to predict across cell types. *Genome Biology*, 21(1):282, 2020. doi: 10.1186/s13059-020-02177-y.
- David R. Roberts, Volker Bahn, Simone Ciuti, et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8):913–929, 2017. doi: 10.1111/ecog.02881.
- Samantha Petti and Sean R. Eddy. Constructing benchmark test sets for biological sequence analysis using independent set algorithms. *PLOS Computational Biology*, 18(3):e1009492, 2022. doi: 10.1371/journal.pcbi.1009492.
- Ian Walsh, Dmytro Fishman, Dario Garcia-Gasulla, et al. DOME: recommendations for supervised machine learning validation in biology. *Nature Methods*, 18:1122–1127, 2021. doi: 10.1038/s41592-021-01205-4.
- Tianqi Chen and Carlos Guestrin. XGBoost: a scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, pages 785–794, 2016. doi: 10.1145/2939672.2939785.
- Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pages 4765–4774, 2017.
- Mukund Sundararajan, Ankur Taly, and Qiqi Yan. Axiomatic attribution for deep networks. In *Proceedings of the 34th International Conference on Machine Learning (ICML 2017)*, volume 70 of *Proceedings of Machine Learning Research*, pages 3319–3328, 2017.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pages 5998–6008, 2017.
- Gherman Novakovsky, Nick Dexter, Maxwell W. Libbrecht, et al. Obtaining genetics insights from deep learning via explainable artificial intelligence. *Nature Reviews Genetics*, 24(2):125–137, 2023. doi: 10.1038/s41576-022-00532-2.
- Kasidet Hiranniramol, Yuhao Chen, Weiguo Liu, and Xiaowei Wang. Generalizable sgRNA design for improved CRISPR/Cas9 editing efficiency. *Bioinformatics*, 36(9):2684–2689, 2020. doi: 10.1093/bioinformatics/btaa041.
- Maurice Labuhn, Felix F. Adams, Michelle Ng, Sabine Knoess, Axel Schambach, Emmanuelle Charpentier, Adrian Schwarzer, Jose L. Mateo, Jan-Henning Klusmann, and Dirk Heckl.

- Refined sgRNA efficacy prediction improves large- and small-scale CRISPR–Cas9 applications. *Nucleic Acids Research*, 46(3):1375–1385, 2018. doi: 10.1093/nar/gkx1268.
- Scott M. Lundberg, Gabriel Erion, Hugh Chen, et al. From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1):56–67, 2020. doi: 10.1038/s42256-019-0138-9.
- Surag Nair, Avanti Shrikumar, Jacob Schreiber, and Anshul Kundaje. fastISM: performant in silico saturation mutagenesis for convolutional neural networks. *Bioinformatics*, 38(9):2397–2403, 2022. doi: 10.1093/bioinformatics/btac135.
- Jian Zhou and Olga G. Troyanskaya. Predicting effects of noncoding variants with deep learning-based sequence model. *Nature Methods*, 12(10):931–934, 2015. doi: 10.1038/nmeth.3547.
- Sapir Elkayam, Ido Tziony, and Yaron Orenstein. DeepCRISTL: deep transfer learning to predict CRISPR/Cas9 on-target editing efficiency in specific cellular contexts. *Bioinformatics*, 40(8): btae481, 2024. doi: 10.1093/bioinformatics/btae481.
- Sandy L. Klemm, Zohar Shipony, and William J. Greenleaf. Chromatin accessibility and the regulatory epigenome. *Nature Reviews Genetics*, 20(4):207–220, 2019. doi: 10.1038/s41576-018-0089-8.
- Daqi Wang, Chengdong Zhang, Bei Wang, et al. Optimized CRISPR guide RNA design for two high-fidelity Cas9 variants by deep learning. *Nature Communications*, 10:4284, 2019. doi: 10.1038/s41467-019-12281-8.
- Yuta Ito, Sho Inoue, Takashi Nakashima, Han Zhang, Yang Li, et al. Epigenetic profiles guide improved CRISPR/Cas9-mediated gene knockout in human T cells. *Nucleic Acids Research*, 52(1):141–153, 2024. doi: 10.1093/nar/gkad1076.
- Ayal Luboshitz, Mohammad Rahimi, Ayal Hendel, and Yaron Orenstein. EpiCRISPR: Improving CRISPR/Cas9 on- and off-target prediction by flanking sequences, epigenetic marks, and high-throughput datasets. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, pages 1–14, 2026. doi: 10.1109/TCBBIO.2026.3727752.

## A 补充信息

### S1 分析阈值汇总

**表 15:** Analysis thresholds used in this study; all values are read from the central analysis configuration file rather than hard-coded in analysis code. Rows labelled 'Importance-deltaR2 only' feed the supplementary Importance-deltaR2 annotation and do NOT enter the evidence-tier rule; the authoritative tier rule is `classify_evidence_tier()` in `analysis/evidence/integration.py`.

| item                                                         | value            |
|--------------------------------------------------------------|------------------|
| evidence tier: min coverage / concordance                    | 2/0.8            |
| evidence tier: min  delta R2  gain gate                      | 0.01             |
| evidence tier: permutation FDR max / min bootstrap iter      | 0.05/200         |
| unstable effect threshold (all analyses)                     | 10.0             |
| bootstrap iterations / seed / alpha                          | 2000/2024/0.05   |
| permutation iterations                                       | 1000             |
| ANOVA min obs / min residual df                              | 32/5             |
| motif length range / similarity / merge                      | 4-12/0.9/0.95    |
| seqlet quantiles (position/continuity)                       | 0.9/0.75         |
| min support (seqlet/sample), min cell lines                  | 30/20/2          |
| motif enrichment foreground quantile / FDR                   | 0.67/0.05        |
| Importance-deltaR2 only: SNR (strong/mod./weak)              | 2.5/1.8/1.2      |
| Importance-deltaR2 only: min effect size / FDR (strong/mod.) | 0.005/0.001/0.01 |

### S1b Importance- $\Delta R^2$ 辅助视图

### S2 跨模型位置归因一致性

### S3 完整预测性能

全部 7 个模型配置在 *single* 与 *mixed* 划分下的留出集指标（中位数、均值、标准差与发散计数）见 `docs/paper/tables/tab2_prediction.tex`；按 held-out 细胞系分组的 28 行结果保存在 `tables/loco_performance.csv`，其中每一行对应的原始实验可在 `tables/experiment_table.csv` 中按 `(model,split_type,cell_line,environment,random_seed)` 追回。

**关于 *all* (LOCO) 分支的说明（本版已更正）：**在权威批次 `ultimate_run` 中，*all* 划分是**真实留一细胞系**——训练池先剔除与留出系共享身份类的全部序列，因此 *all* 与 *single* 不再逐位相同：*single* 下 7 个配置的中位  $R^2$  为 0.067–0.120，而 *all* 下全部落在 −0.027 至 +0.010（与均值基线不可区分），且逐留出系展开异质性很大（CNN  $k=3$ ：HCT116 +0.043、HeLa −0.023、HL60 −0.037、HEK293T −0.266）。这一差异正是 §3.3 的跨细胞系泛化证据。

需要保留的历史提示：该分支在**已废弃**的旧批次 `batch_20260909_full` 中确实与 *single* 逐位相同（因其 LOCO 未剔除留出系同源序列），这也是该批次被弃用的原因之一（见正文 §3.4）。旧批次的任何数字都不进入本文结论。




图 9: 辅助视图: 环境因子的增量预测价值 ( $\Delta R^2$ ) 与模型内归一化 importance 的关系。该图 \*\* 不 \*\* 是显著性图:  $\Delta R^2 \neq \text{importance}$ ,  $\text{importance} \neq \text{显著性}$ ; 各模型的 importance 在其模型/分析组内归一化, 绝对量级不可跨模型类直接比较。

表 16: Cross-model consistency of position-wise attribution (single split, sequence/all contexts). Peak positions are the argmax of each model's normalized attribution profile; Spearman is the mean pairwise rank correlation over 23 positions; top-3 overlap is the mean Jaccard-style overlap of each model's three highest positions.

| cell_line | context                     | n_positions | peak_linear | peak_xgboost | peak_mlp | peak_cnn | peak_transformer | mean_pairwise_spearman | mean_top3_overlap |
|-----------|-----------------------------|-------------|-------------|--------------|----------|----------|------------------|------------------------|-------------------|
| hct116    | all                         | 23          | 20          | 18           | 18       | 20       | 19               | 0.337                  | 0.567             |
| hct116    | sequence                    | 23          | 1           | 18           | 18       | 20       | 21               | 0.333                  | 0.400             |
| hct116    | sequence_ctcf               | 23          | 23          | 18           | 18       | 18       | 20               | 0.295                  | 0.400             |
| hct116    | sequence_ctcf_dnase         | 23          | 20          | 18           | 18       | 20       | 19               | 0.287                  | 0.433             |
| hct116    | sequence_ctcf_dnase_h3k4me3 | 23          | 20          | 18           | 18       | 20       | 21               | 0.310                  | 0.667             |
| hct116    | sequence_ctcf_dnase_rrbs    | 23          | 20          | 18           | 18       | 20       | 19               | 0.381                  | 0.600             |
| hct116    | sequence_ctcf_h3k4me3       | 23          | 1           | 18           | 18       | 20       | 19               | 0.277                  | 0.367             |
| hct116    | sequence_ctcf_h3k4me3_rrbs  | 23          | 1           | 18           | 18       | 18       | 19               | 0.328                  | 0.367             |
| hct116    | sequence_ctcf_rrbs          | 23          | 23          | 18           | 18       | 20       | 20               | 0.210                  | 0.367             |
| hct116    | sequence_dnase              | 23          | 19          | 18           | 18       | 18       | 19               | 0.375                  | 0.533             |
| hct116    | sequence_dnase_h3k4me3      | 23          | 19          | 18           | 18       | 20       | 21               | 0.345                  | 0.667             |
| hct116    | sequence_dnase_h3k4me3_rrbs | 23          | 20          | 18           | 18       | 20       | 21               | 0.364                  | 0.567             |
| hct116    | sequence_dnase_rrbs         | 23          | 3           | 18           | 18       | 20       | 21               | 0.318                  | 0.333             |
| hct116    | sequence_h3k4me3            | 23          | 18          | 18           | 18       | 18       | 21               | 0.475                  | 0.533             |
| hct116    | sequence_h3k4me3_rrbs       | 23          | 19          | 18           | 18       | 20       | 21               | 0.409                  | 0.567             |
| hct116    | sequence_rrbs               | 23          | 1           | 18           | 18       | 18       | 20               | 0.350                  | 0.367             |
| hek293t   | all                         | 23          | 3           | 18           | 18       | 18       | 20               | 0.327                  | 0.367             |
| hek293t   | sequence                    | 23          | 1           | 18           | 20       | 20       | 19               | 0.160                  | 0.467             |
| hek293t   | sequence_ctcf               | 23          | 22          | 18           | 20       | 20       | 19               | 0.116                  | 0.433             |
| hek293t   | sequence_ctcf_dnase         | 23          | 3           | 18           | 14       | 20       | 20               | 0.289                  | 0.367             |
| hek293t   | sequence_ctcf_dnase_h3k4me3 | 23          | 3           | 18           | 18       | 20       | 20               | 0.228                  | 0.333             |
| hek293t   | sequence_ctcf_dnase_rrbs    | 23          | 3           | 18           | 20       | 18       | 19               | 0.220                  | 0.467             |
| hek293t   | sequence_ctcf_h3k4me3       | 23          | 1           | 18           | 18       | 20       | 20               | 0.057                  | 0.333             |
| hek293t   | sequence_ctcf_h3k4me3_rrbs  | 23          | 20          | 18           | 20       | 18       | 20               | 0.482                  | 0.567             |
| hek293t   | sequence_ctcf_rrbs          | 23          | 23          | 18           | 20       | 18       | 20               | 0.045                  | 0.367             |
| hek293t   | sequence_dnase              | 23          | 3           | 18           | 18       | 20       | 20               | 0.317                  | 0.367             |
| hek293t   | sequence_dnase_h3k4me3      | 23          | 3           | 18           | 18       | 20       | 20               | 0.317                  | 0.500             |
| hek293t   | sequence_dnase_h3k4me3_rrbs | 23          | 3           | 18           | 18       | 20       | 20               | 0.297                  | 0.367             |
| hek293t   | sequence_dnase_rrbs         | 23          | 3           | 18           | 18       | 20       | 20               | 0.344                  | 0.333             |
| hek293t   | sequence_h3k4me3            | 23          | 1           | 18           | 20       | 20       | 20               | 0.335                  | 0.400             |
| hek293t   | sequence_h3k4me3_rrbs       | 23          | 20          | 18           | 20       | 20       | 20               | 0.558                  | 0.633             |
| hek293t   | sequence_rrbs               | 23          | 1           | 18           | 20       | 20       | 19               | 0.064                  | 0.467             |
| hela      | all                         | 23          | 5           | 18           | 18       | 20       | 19               | 0.265                  | 0.267             |
| hela      | sequence                    | 23          | 1           | 18           | 18       | 21       | 19               | 0.326                  | 0.267             |
| hela      | sequence_ctcf               | 23          | 1           | 18           | 14       | 18       | 20               | 0.249                  | 0.367             |

**表 17:** Cross-model consistency of position-wise attribution (single split, sequence/all contexts). Peak positions are the argmax of each model’s normalized attribution profile; Spearman is the mean pairwise rank correlation over 23 positions; top-3 overlap is the mean Jaccard-style overlap of each model’s three highest positions. (续 2/3)

| cell_line | context                     | n_positions | peak_linear | peak_xgboost | peak_mlp | peak_cnn | peak_transformer | mean_pairwise_spearman | mean_top3_overlap |
|-----------|-----------------------------|-------------|-------------|--------------|----------|----------|------------------|------------------------|-------------------|
| hela      | sequence_ctcf_dnase         | 23          | 1           | 18           | 1        | 18       | 19               | 0.291                  | 0.467             |
| hela      | sequence_ctcf_dnase_h3k4me3 | 23          | 2           | 18           | 18       | 20       | 19               | 0.249                  | 0.233             |
| hela      | sequence_ctcf_dnase_rrbs    | 23          | 1           | 18           | 18       | 18       | 19               | 0.252                  | 0.333             |
| hela      | sequence_ctcf_h3k4me3       | 23          | 17          | 18           | 18       | 18       | 1                | 0.217                  | 0.267             |
| hela      | sequence_ctcf_h3k4me3_rrbs  | 23          | 1           | 18           | 18       | 18       | 1                | 0.249                  | 0.333             |
| hela      | sequence_ctcf_rrbs          | 23          | 23          | 18           | 22       | 20       | 20               | 0.026                  | 0.233             |
| hela      | sequence_dnase              | 23          | 5           | 18           | 18       | 18       | 1                | 0.312                  | 0.233             |
| hela      | sequence_dnase_h3k4me3      | 23          | 5           | 18           | 18       | 20       | 1                | 0.291                  | 0.367             |
| hela      | sequence_dnase_h3k4me3_rrbs | 23          | 5           | 18           | 18       | 18       | 1                | 0.384                  | 0.467             |
| hela      | sequence_dnase_rrbs         | 23          | 5           | 18           | 18       | 21       | 20               | 0.220                  | 0.233             |
| hela      | sequence_h3k4me3            | 23          | 17          | 18           | 18       | 18       | 1                | 0.345                  | 0.333             |
| hela      | sequence_h3k4me3_rrbs       | 23          | 1           | 18           | 18       | 20       | 1                | 0.383                  | 0.433             |
| hela      | sequence_rrbs               | 23          | 1           | 18           | 18       | 18       | 1                | 0.319                  | 0.367             |
| hl60      | all                         | 23          | 21          | 18           | 18       | 20       | 19               | 0.495                  | 0.433             |
| hl60      | sequence                    | 23          | 1           | 18           | 20       | 20       | 19               | 0.376                  | 0.500             |
| hl60      | sequence_ctcf               | 23          | 1           | 18           | 18       | 20       | 19               | 0.386                  | 0.433             |
| hl60      | sequence_ctcf_dnase         | 23          | 5           | 18           | 20       | 20       | 19               | 0.379                  | 0.400             |
| hl60      | sequence_ctcf_dnase_h3k4me3 | 23          | 21          | 20           | 18       | 20       | 1                | 0.447                  | 0.400             |
| hl60      | sequence_ctcf_dnase_rrbs    | 23          | 5           | 18           | 18       | 20       | 19               | 0.402                  | 0.400             |
| hl60      | sequence_ctcf_h3k4me3       | 23          | 1           | 18           | 18       | 20       | 20               | 0.385                  | 0.367             |
| hl60      | sequence_ctcf_h3k4me3_rrbs  | 23          | 23          | 18           | 18       | 20       | 21               | 0.171                  | 0.367             |
| hl60      | sequence_ctcf_rrbs          | 23          | 23          | 18           | 20       | 20       | 21               | 0.177                  | 0.333             |
| hl60      | sequence_dnase              | 23          | 5           | 18           | 1        | 20       | 1                | 0.418                  | 0.433             |
| hl60      | sequence_dnase_h3k4me3      | 23          | 4           | 18           | 18       | 20       | 19               | 0.484                  | 0.433             |
| hl60      | sequence_dnase_h3k4me3_rrbs | 23          | 21          | 18           | 18       | 20       | 19               | 0.556                  | 0.433             |
| hl60      | sequence_dnase_rrbs         | 23          | 5           | 18           | 1        | 20       | 1                | 0.390                  | 0.400             |
| hl60      | sequence_h3k4me3            | 23          | 18          | 18           | 18       | 20       | 1                | 0.441                  | 0.467             |
| hl60      | sequence_h3k4me3_rrbs       | 23          | 1           | 18           | 20       | 20       | 1                | 0.485                  | 0.567             |
| hl60      | sequence_rrbs               | 23          | 1           | 18           | 20       | 20       | 19               | 0.226                  | 0.500             |
| none      | all                         | 23          | 3           | 18           | 18       | 18       | 20               | 0.441                  | 0.500             |
| none      | sequence                    | 23          | 1           | 18           | 18       | 18       | 18               | 0.446                  | 0.433             |
| none      | sequence_ctcf               | 23          | 22          | 18           | 18       | 18       | 20               | 0.431                  | 0.600             |
| none      | sequence_ctcf_dnase         | 23          | 3           | 18           | 18       | 20       | 18               | 0.442                  | 0.433             |
| none      | sequence_ctcf_dnase_h3k4me3 | 23          | 3           | 18           | 18       | 18       | 20               | 0.470                  | 0.367             |
| none      | sequence_ctcf_dnase_rrbs    | 23          | 3           | 18           | 18       | 18       | 18               | 0.440                  | 0.367             |

**表 18:** Cross-model consistency of position-wise attribution (single split, sequence/all contexts). Peak positions are the argmax of each model’s normalized attribution profile; Spearman is the mean pairwise rank correlation over 23 positions; top-3 overlap is the mean Jaccard-style overlap of each model’s three highest positions. (续 3/3)

| cell_line | context                     | n_positions | peak_linear | peak_xgboost | peak_mlp | peak_cnn | peak_transformer | mean_pairwise_spearman | mean_top3_overlap |
|-----------|-----------------------------|-------------|-------------|--------------|----------|----------|------------------|------------------------|-------------------|
| none      | sequence_ctcf_h3k4me3       | 23          | 18          | 18           | 18       | 18       | 20               | 0.550                  | 0.600             |
| none      | sequence_ctcf_h3k4me3_rrbs  | 23          | 1           | 18           | 18       | 20       | 20               | 0.405                  | 0.433             |
| none      | sequence_ctcf_rrbs          | 23          | 22          | 18           | 18       | 21       | 20               | 0.388                  | 0.433             |
| none      | sequence_dnase              | 23          | 3           | 18           | 18       | 1        | 19               | 0.317                  | 0.433             |
| none      | sequence_dnase_h3k4me3      | 23          | 3           | 18           | 18       | 1        | 20               | 0.460                  | 0.267             |
| none      | sequence_dnase_h3k4me3_rrbs | 23          | 1           | 18           | 18       | 18       | 19               | 0.284                  | 0.467             |
| none      | sequence_dnase_rrbs         | 23          | 3           | 18           | 18       | 1        | 18               | 0.354                  | 0.333             |
| none      | sequence_h3k4me3            | 23          | 18          | 18           | 18       | 18       | 18               | 0.630                  | 0.500             |
| none      | sequence_h3k4me3_rrbs       | 23          | 1           | 18           | 18       | 18       | 18               | 0.540                  | 0.333             |
| none      | sequence_rrbs               | 23          | 1           | 18           | 18       | 18       | 19               | 0.283                  | 0.433             |

## S4 环境因素的完整统计结果

完整结果包含：(i) 1978 条可检验 lattice 边的配对  $\Delta R^2$  及其逐样本 bootstrap 置信区间 (tables/environment\_edges.csv: 2671 条边记录, 其中 2633 条可检验、805 条 CI 不跨 0; 按「全部种子均不跨 0」的保守口径为 640 条; tables/bootstrap\_results.csv 另含 7954 行  $\Delta\text{MAE}/\Delta\text{RMSE}$  记录); (ii) 3444 条置换检验记录, 含每行的零假设、备择假设、观测效应、 $p$  值与所属 FDR 族 (tables/permutation\_results.csv); (iii) 94 项析因方差分析结果, 含  $F$ 、自由度、 $p$ 、partial  $\eta^2$  与效应的 bootstrap 置信区间 (tables/anova\_results.csv); (iv) Factorial Environment DAG 的节点与边表 (tables/environment\_nodes.csv、environment\_edges.csv), 其中每条边标注是否 metric inconsistency、是否有可用 CI。

## S5 候选序列模式

656 个候选模式的支持度、IUPAC、人类可读形式、正则形式、位置分布、方向与证据等级见 tables/motif\_candidates.csv; 聚类前共 559773 条 seqlet, 落盘为 tables/motif\_instances.csv 的 186737 条 (motif, 样本) 实例记录; 富集检验结果见 tables/motif\_enrichment.csv; 跨核配置与跨细胞系一致性见 tables/motif\_consistency.csv; motif 级证据行见 tables/motif\_evidence.csv。表 9 给出支持度最高的 10 个代表模式; 表 13 给出用于后续实验验证的候选假设与其最小扰动方案。

## S6 结果文件与交互式报告

平台同时输出可供交互探索的科学发现报告 (Interactive Scientific Discovery Report), 包含数据质量、预测、环境、序列与模式、细胞系、证据整合、假设与溯源等章节, 支持表格筛选、证据卡、图形查看与 artifact 追溯。报告层只读取结果文件, 不重新计算任何统计量, 从而保证论文数值与报告数值同源。

### A.1 论文事实来源映射

本文每一处定量结论均可在表 19 中追溯到具体结果文件与图表。生成脚本为 analysis/reporting/paper/完整映射表另见 docs/paper/review/claim\_provenance\_round2.md。

表 19: 论文结论与结果文件映射 (节选; 完整版见 docs/paper/review/claim\_provenance\_round2.md)。

| 结论                          | 结果文件 / 字段                                                  | 图表       |
|-----------------------------|------------------------------------------------------------|----------|
| 数据规模与组成                     | data/processed/*_metadata.csv                              | 表 2      |
| 预测性能 (中位数/IQR/发散数)          | tables/experiment_table.csv (R2)                           | 表 5、图 2  |
| 环境 $\Delta R^2$ 与跨模型一致性     | tables/environment_main_effects.csv                        | 表 6、图 3  |
| 逐样本配对 bootstrap CI          | tables/bootstrap_results.csv、<br>environment_bootstrap.csv | 图 3C     |
| 置换检验与 BH-FDR                | tables/permutation_results.csv                             | 表 6      |
| 析因方差分析                      | tables/anova_results.csv                                   | 图 3D     |
| 位置归因与区域划分                   | tables/attribution_summary.csv                             | 图 4A–B   |
| 第 18 位碱基效应                  | results/tables/paper/position18_efficacy_49_base.csv       | 图 4C     |
| CNN 核消融配对差                  | results/tables/paper/cnn_kernel_paired_test.csv            | 表 8、图 5A |
| 候选模式与富集                     | tables/motif_candidates.csv、<br>motif_enrichment.csv       | 图 5D、表 9 |
| 细胞系异质性                      | tables/cellline_effects.csv                                | 图 7      |
| 证据分级与 CI                    | tables/evidence_matrix.csv                                 | 表 6、图 8  |
| Importance- $\Delta R^2$ 关系 | tables/importance_vs_delta_r2.csv                          | 图 8B     |