

面向基因编辑系统的细胞环境感知型核酸工具 智能设计与影响因素发现平台

(作者信息待补)

ctexart

geometry graphicx booktabs amsmath,amssymb natbib caption xcolor url hyperref

font=small,labelfont=bf

ΔR^2

document

摘要

基因编辑效率的机器学习预测已取得进展，但预测精度的提升并未同步带来对影响因素的可靠解释；更关键的是，若训练与测试之间存在同源序列，跨条件的性能估计会被系统性高估，而这类问题在只报告精度时往往不可见。本研究构建了一个把质量控制、数据划分与泄漏审计、特征工程、受控多模型实验、模型归因、统计推断、环境因素析因分析、序列模式挖掘、细胞背景比较与跨模型证据整合组织为统一流程的科学发现平台，并以 DeepCRISPR 公开数据（4 个细胞系、16 749 条 23 nt 靶序列、1 344 次受控训练运行）开展案例研究。平台使用 Linear Regression、XGBoost、多层感知机（MLP）、双分支卷积神经网络（CNN，序列卷积核 3/5/7）与 Transformer 五类具有不同归纳偏置的模型，并严格区分预测效应（ ΔR^2 ）、模型归因、稳健性与统计证据。

本文最重要的方法学结果来自对自身历史批次的审计与整改：早期批次按记录随机划分，且留一细胞系（LOCO）分支未剔除留出系同源序列，导致同一 sgRNA 序列可同时进入训练与测试两侧。在按"序列及其反向互补构成同一身份类"重新划分并完整重跑 1 344 次实验后，mixed 划分的中位 R^2 由 0.118 降至 0.073，LOCO 由 +0.036 降至 -0.008，而单细胞系划分基本不变（0.070 0.081）。这一差异化变化表明：此前较高的跨细胞系性能至少有相当部分由跨细胞系的同源序列重复支撑。

在此基础上，本文按证据强度报告：（i）数据可信度层面，1 344/1 344 次运行的 train 序列重叠与反向互补重叠均为 0，划分摘要逐条复核一致，全批运行于同一数据、代码与数值栈之上；（ii）预测能力有限且跨细胞系泛化失败——细胞系内中位 R^2 为 0.067–0.120，真实 LOCO 的 7 个模型配置全部落在 -0.112 至 +0.010，并呈显著细胞系异质性（HEK293T 最低， $R^2=-0.266$ ）；（iii）跨模型归因在位置层级一致指向 PAM 邻近位置（跨模型平均谱峰值第 18 位；XGBoost 与 MLP 分别有 91.7%）

平台的科学性不体现在"所有分析均得到阳性结果"，而体现在统一、可追溯的框架中区分稳定证据、模型特异性现象、上下文依赖现象与不确定结果，并据此输出可检验的候选假设（如第 18 位碱基替换、PAM 邻近候选模式扰动）。本研究属于**计算案例研究（computational case study）**：已完成受控计算验证、统计推断与候选因素优先级排序，尚未开展湿实验验证；平台输出的是待验证假设，而非已确认的生物学机制，也不作任何因果断言。

关键词：CRISPR-Cas9；sgRNA 编辑效率；多模型可解释机器学习；增量预测贡献；序列归因；候选序列模式；细胞系异质性；证据整合；生物学假设生成

引言

基因编辑工具设计中的预测与理解

CRISPR-Cas9 通过可编程的 RNA–DNA 配对实现定点切割，sgRNA 的活性差异使"实验前筛选高效位点"成为核心计算问题[Jinek 等, Science 2012; Cong 等, Science 2013]。早期方法依赖序列组成与位置偏好的人工规则[Doench 等, Nat Biotechnol 2014; Moreno-Mateos 等, Nat Methods 2015]，随后被数据驱动模型取代：DeepBind 与 Basset 证明卷积网络可从序列实验数据中学习局部序列特异性[Alipanahi 等, Nat Biotechnol 2015; Kelley 等, Genome Res 2016]；DeepCRISPR 进一步把序列与细胞特异性表观遗传信息（CTCF、DNase、H3K4me3、RRBS）纳入统一编码，用于 sgRNA 活性与脱靶预测[Chuai 等, Genome Biol 2018]；Rule Set 2 等方法也显著提升了预测能力[Doench 等, Nat Biotechnol 2016]；此后一系列深度模型（CNN、迁移学习、数据整合模型）被用于 sgRNA 活性预测[Kim2018NatBiotechnol; Kim2019SciAdv; Xiang2021NatCommun]。

评估协议决定结论：为什么必须显式审计数据泄漏

在序列建模任务中，性能估计的可信度取决于划分是否把"同一身份"的样本完全隔离。本研究所处理的正是一个具体而普遍的问题：同一 sgRNA 序列会在多个细胞系中被重复测量，若划分按记录随机分配，则同一条序列（及其反向互补）可同时出现在训练与测试两侧，模型在测试集上部分复现了已见序列的标签，跨条件性能因此被系统性高估。此类"记忆被计入泛化"的失效模式在机器学习基准中并不罕见[Kaufman2012TKDD; Kapoor 2023Patterns]，生物医学机器学习社区已提出系统性的排查问题清单[Bernett2024NatMethods]，在基因组机器学习中已有系统性讨论[Whalen2022NatRevGenet]，其中"跨细胞类型预测"被明确指为易受该问题影响的一类任务[Schreiber2020GenomeBiol]；对 CRISPR 活性预测工具的独立基准测试也显示，报告的泛化能力在严格不重叠的评估集上会显著下降[Zhang2023BriefBioinform; Yuan2025CRISPRJ; Haeussler2016GenomeBiol]。

由此产生三个必须在方法层面显式回答的问题：（1）身份类如何定义（序列本身？其反向互补？同一 locus？）；（2）划分是否真的按身份类隔离，且这一点能否在运行期自证而非事后声称；（3）训练所用划分与分析所用划分是否一致，即结果文件能否证明下游统计没有用错划分。在以分组/嵌套结构为特征的数据上，随

机交叉验证会违反独立性假设并给出乐观偏置的估计[Roberts2017Ecography]，生物学序列基准因此主张构造与训练集序列独立的测试集[Petti2022PLOS], 并已形成要求显式声明划分与相似性的报告规范[Walsh2021NatMethods]。本文把这三问作为结果可信度的前置条件，并在 :methods-leakage 给出可执行约束：以 min(seq, revcomp(seq)) 为身份类整体划分、在划分函数内部计算重叠并在非零时直接中止、把划分摘要与数据/代码/环境指纹写入每个运行的元数据。

仅靠预测无法回答影响因素问题

预测能力的提升并不意味着研究者能够理解模型依据哪些因素作出判断。不同模型类别的可解释性各有边界：线性模型给出方向与统计量但表达受限；树模型可建模非线性与交互[Chen & Guestrin, KDD 2016]，但 Gain/Weight/Cover 没有方向；深度模型的内部表示难以直接解释。SHAP 与 Integrated Gradients 分别从 Shapley 值与公理化归因出发提供了通用解释工具[Lundberg & Lee, NeurIPS 2017; Sundararajan 等, ICML 2017]，Transformer 则以自注意力建模跨位置关系[Vaswani 等, NeurIPS 2017]。然而，即使归因可用，仍需回答：哪些序列位置与模式与效率相关？表观遗传环境是否在序列之外提供额外预测信息？同一因素在不同细胞背景下是否稳定？不同模型是否独立支持同一候选因素？以及——归因是否只是模型内部依赖，而不能被读作生物学机制？

从"模型解释"到"可审计的科学发现流程"

现有研究中，预测、归因、统计与跨条件比较往往分散在不同脚本与不同报告里，导致结论难以逐项追溯，也容易把模型依赖强度误读为生物学效应。本文的目标是构建一个可审计的科学发现平台：把质量控制、划分与泄漏审计、特征工程、受控多模型实验、归因、统计推断、环境析因、序列模式发现、细胞背景比较与证据整合组织为统一、可复现、可追溯的流程，并在全文显式区分三层证据：直接计算观测 (R^2 、 ΔR^2 、归因、富集)、统计证据 (置信区间、置换检验、FDR、一致性) 与生物学解释 (假设，需实验验证)。

平台围绕三个研究问题组织分析：(1) 序列：哪些位置与候选模式与编辑效率相关？(2) 环境：细胞表观遗传信息是否提供额外的预测信息？(3) 背景：同一因素在不同 cell line 中是否保持一致？在此框架中，预测模型是发现影响因素的工具，而不是最终结论；预测性能的作用是界定后续结论的强度上限。

案例研究与贡献定位

本文以 DeepCRISPR 公开数据作为案例研究 (case study)，并报告一个来自对自身历史批次审计的方法学结果：在发现早期批次的划分存在跨细胞系同源序列污染后，我们重新定义身份类与划分策略，完整重跑全部 1344 次实验，并以整改后的批次作为唯一结果来源。整改的后果是性能显著下降——跨细胞系 (LOCO) 中位 R^2 由 +0.036 变为 -0.008——本文如实报告该下降，并把它作为主要发现之一，而不是需要解释掉的异常。

据此，本文的贡献定位为：(i) 一个可在结果层面自证的泄漏防控与数据质量审计流程；(ii) 在该流程下对五类模型、三种划分与四个环境因子的受控比较，包括对"环境因素未检出增量效应"与"跨细胞系泛化失败"两个阴性结果的完整报告；(iii) 在位置层级与区域层级分别报告多模型归因，保留模型间分歧而非平均掉；(iv) 从计算证据出发给出可实验检验的候选假设与最小扰动方案 (第 18 位碱基替换、PAM 邻近候选模式破坏)。本文不主张平台在预测精度上优于已有方法，也不主张表观遗传环境必然提升预测；本案例中后者的检验结果为未检出 (:res-environment)。

材料与方法

平台总体架构

平台按"科学引擎生成结果文件、报告层消费结果文件"的原则组织 (图 图1)。数据质量控制、特征工程、受控训练、归因与统计模块之间只通过结构化结果文件 (CSV/JSON/Markdown) 交换信息，因此训练可以在本地或高性能计算环境中独立执行，下游分析在获得结果后离线运行。平台在分析阶段不修改任何训练产物：所有统计量与图表均由只读结果文件重新计算，随机种子、阈值与分析方案统一记录在配置文件中。工程实现细节 (模块划分、接口约定、测试) 见补充材料与项目仓库文档。

案例数据集

案例数据为 DeepCRISPR 公开数据集[Chuai 等, Genome Biol 2018]，包含四个细胞系 (HCT116、HEK293T、HeLa、HL60)，每条记录包含 23 nt 靶序列、实测归一化编辑效率与四条逐位点表观遗传轨道 (CTCF、DNase、H3K4me3、RRBS 的二值可及性)。过滤非法碱基后共 16 749 条序列进入分析 (表 表9)。

数据编号经核对：全部记录的第 22、23 位均为 G，即 PAM 位于第 21-23 位 (NGG)，第 1-20 位为 protospacer。本文据此定义 PAM 邻近种子区为第 17-20 位、种子核心区为第 9-16 位、PAM 远端区为第 1-8 位。

特征表示

序列采用 23×4 one-hot 编码；四条表观遗传轨道以逐位点二值形式拼接，形成 23×8 输入张量 (184 维展平特征)。环境组合通过通道掩码实现：给定环境因子集合 S，未启用的表观通道整体置零，张量维度保持不变，从而保证不同环境组合之间的差异只反映信息可用性。Linear Regression 按统计惯例剔除 T 参照列 (18 4161)，其余模型使用完整 184 维。

受控实验设计

每个 (模型配置 $\times$ 环境组合) 在三种划分下训练，三者均满足同一条**身份不可跨划分**约束 (见 :methods-leakage)：

* single：单细胞系内 70% * all (真实留一细胞系，LOCO)：以某一细胞系整体作为测试集；训练池由其余三个细胞系构成，**先剔除与留出系共享身份类 (序列或其反向互补) 的全部序列**，再按 85% * mixed：四

细胞系混合后按身份类整体划分 70\

7 个模型配置 × 16 个环境组合 × 12 个（划分，种子）设定共产生 **1 344 次训练运行**，全部在留出测试集上评估（R²、RMSE、MAE、Pearson、Spearman）。由于 LOCO 的训练池按留出系不同而缩减（n_train 由 1 453 至 12 313 不等），跨细胞系比较需同时报告训练集规模，本文在结果中一并给出。

数据质量、划分身份与泄漏防控

本文把“结果是否可信”作为先于模型性能报告的对象，因此在方法层面固定三项约束，并在结果中逐项给出审计数字（表 8）。

(1) 身份类与 group-aware 划分. 本研究的泛化声明是 sequence-level：模型应面向“未见过的 sgRNA 序列”。因此划分的最小不可分单位不是单条记录，而是**身份类**

id(s)=min(s, revcomp(s)),

即序列本身与其反向互补被视为同一身份。该定义与“构造与训练集序列独立的测试集”这一基准设计原则一致 [Petti2022PLOS; Roberts2017Ecography]。反向互补被纳入同一类，是因为二者靶向同一 locus 的两条链、标签来自同一靶点，属于近重复观测；在本数据集中此类配对确实存在（跨细胞系如 HCT116 与 rc(HeLa) 共 30 对）。三种划分均按身份类整体分配，同一身份类的全部记录只能进入 train、valid 或 test 之一。LOCO 分支额外要求训练池不含留出系的任何身份类 (:methods-design)。

(2) 划分运行期自证. 划分函数在返回前计算 train/valid/test 之间的原始序列重叠、反向互补重叠与 locus 重叠，写入每个 run 的元数据；若在 group-aware 模式下出现任何序列级重叠则直接抛错中止，而不是产出泄漏结果。同时计算划分摘要 split_digest（train/valid/test 序列集合与样本数的 SHA-256 前 16 位），用于事后核验“训练所用划分等于分析所用划分”。

(3) 全批一致性数值离散隔离. 每个 run 记录数据指纹（元数据内容哈希与特征文件大小）、代码指纹（关键源文件 md5）、环境指纹（依赖版本与设备可见性）与设备解析结果。数值离散（|R²| ≥ 10，源于线性模型在共线性设计矩阵上的病态求解）**不被删除**，而是在全部统计中隔离并单列计数。

(4) 泄漏排查协议. 除自动断言外，审计按生物机器学习泄漏排查问题清单逐项核对（重复样本、同源样本、训练-测试依赖、划分声明）[Bernett2024NatMethods; Kapoor2023Patterns]。(5) 历史泄漏整改的披露. 项目早期批次 (batch_20260909_full) 的划分按记录随机分配，且 LOCO 分支未剔除留出系同源序列；审计发现该批次中同一 sgRNA 序列可同时出现在训练与测试两侧 (mixed 划分中约 36\

模型与归因方法

平台使用五类模型（7 个配置）：Linear Regression（线性主效应与统计检验）、XGBoost（非线性与交互 [Chen & Guestrin, KDD 2016]）、MLP（一般非线性组合）、双分支 CNN（序列分支 + 环境分支，序列卷积核 k ∈ {3, 5, 7}，用于建模不同宽度的局部序列上下文）与 Transformer（跨位置交互 [Vaswani 等, NeurIPS 2017]）。归因方法分别为：回归系数（含 SE、t、p、FDR）、TreeSHAP [Lundberg & Lee, NeurIPS 2017; Lundberg2020NatMachIntell]、Integrated Gradients (IG) [Sundararajan 等, ICML 2017]、CNN 的 IG 与 In Silico Mutagenesis (ISM, 逐位点核苷酸替换效应) [Nair2022Bioinformatics; Zhou2015NatMethods] 以及注意力权重。

平台强制语义边界：Δ R² 表示增量预测价值；attribution 表示模型依赖强度；SNR 表示归因稳健性；p/FDR 仅来自具备明确零假设的统计检验（配对 bootstrap、置换检验、析因方差分析与富集检验）。**注意力权重、SNR 与树内部重要性均不作为统计显著性**，注意力在本研究中仅作支持性信息，不用于候选模式提取。

环境因素析因分析

对每个（划分，细胞系，模型，种子）分组定义配对增量

$$\Delta R^2_e | S = R^2(S \cup e) - R^2(S),$$

其中 S 为基线环境集合，e 为新增环境因子，二者来自同一测试集。平台枚举 16 节点的 factorial lattice 的全部单因素边（同一组合可有多个父节点），节点记录 R²/RMSE/MAE/Pearson/Spearman 均值，边记录配对的 Δ R²、Δ MAE、Δ RMSE。主效应为对全部不含 e 的背景 S 的条件增量均值；交互效应为 I(a,b)=Δ(a|S_0 ∪ b) - Δ(a|S_0) 在背景 S_0（不含 a,b）与种子上的平均。

统计方法

(1) 逐样本配对 bootstrap：对每条 lattice 边，使用两侧模型在同一测试样本上的逐样本预测，以 B=2000 次重采样计算 Δ R² 的百分置信区间（α=0.05，种子 2024）；样本数不等或预测文件缺失时标记为不可用。(2) Model-Level Bootstrap Interval (n=7 model configurations)：对每个环境因子，先计算各模型稳定主效应的均值（模型等权），再对该模型向量重采样（B=2000, seed 2024），保证置信区间与点估计同口径。自助法的重采样单元是模型配置而非单条 guide，所得区间用于刻画 effect 在不同模型归纳偏置之间的一致性 (cross-model robustness)，而不是 guide 总体的抽样不确定性；7 个模型共享同一份数据、标签、预处理与划分，不可视为独立生物学重复。(3) 置换检验：对逐样本损失差与条件增量使用符号翻转 (sign-flip) 随机化检验，B=1000。(4) 多重检验：BH-FDR 仅在同一个科学问题族内校正（环境边、环境主效应、环境交互、析因 ANOVA、motif 富集各自成族）。(5) 区组析因方差分析：以 R² 为响应变量，四个环境因子为二水平因子，模型、细胞系与划分作为区组因子，采用基于设计矩阵的 Type-II 边际平方和 F 检验（含成对交互项），效应量报告 η²=SS_term/SS_total；数据不足时返回不可用而非近似值。阈值集中于统一配置文件：参与证据等级判定的为最小绝对增益门 min|Δ R²|=0.01、覆盖度 ≥ 2 个模型、方向一致率 ≥ 0.80、置换 FDR < 0.05、bootstrap 迭代数 ≥ 200 与数值离散阈值 10.0；SNR 阶梯 (2.5/1.8/1.2)、最小效应量 0.005 与 FDR 阶梯 (0.001/0.01) 仅用于 Importance-Δ R² 辅助视图的特征级标注，不参与证据等级判定。完整清单见补充表 15。

序列模式发现

序列模式发现按"归因片段聚类共识富集稳定性"执行。首先计算归因特异性：位置 p 上碱基 b 的得分定义为其归因值减去该位置其它碱基归因均值，以避免原始幅值普遍偏高；随后按位置级分位阈值（0.90）与局部连续性要求（ ≥ 2 个连续位置超过 0.75 分位）提取窗口（长度 4–12 nt，每样本最多 2 个）。seqlet 按 CNN 核配置与方法分别聚类（与簇共识一致率 ≥ 0.90 则合并，聚类后再对相似共识 ≥ 0.95 二次合并）。共识以 IUPAC 退化码、人类可读形式与正则形式同时保存。候选模式需满足最小支持度（seqlet ≥ 30 、样本 ≥ 20 ）。由于当前批次的归因输出为无符号幅值，模式方向不取自 attribution 符号，而由"携带该模式的序列 vs 背景序列"的实测效率对比给出，并在结果中标注来源。富集分析为可选步骤：以效率上三分位序列为前景、全部可用序列为背景，采用 Fisher 精确检验并在 motif 富集族内 BH-FDR 校正；未执行富集时不报告任何 p 值。跨配置一致性通过比较不同 CNN 核与不同细胞系间共识序列的相似性（ ≥ 0.80 ）评估；当前批次没有 Transformer IG 产物，因此 CNN 与 Transformer 的跨模型模式比较标记为不可用。

证据整合

证据等级（Evidence Tier）由唯一的权威实现（analysis/evidence/integration.py 的 classify_evidence_tier）按四条门槛与两个正交"强度门"给出：(i) 覆盖度：与模型等权均值同号的模型数 ≥ 2 （不足 2 且无强证据记为 Inconclusive，等于 1 且有强证据记为 Tier 3）；(ii) 方向一致率：多数方向占比 ≥ 0.80 （仅 Tier 1 要求）；(iii) 置信区间：跨模型 bootstrap 置信区间跨 0 记为 Inconclusive（迭代数 < 200 的置信区间不参与判定）；(iv) cell-line 上下文：跨细胞系标签为 Context-conflicting 时一票否决。两个强度门分工不同：effect 门要求因子级效应（ M 个模型配置的等权平均 ΔR^2 ）满足 $|\Delta R^2| \geq 0.01$ （最小绝对预测增益门，不是统计显著性阈值）；统计门为该因子在置换检验中的 Minimal Edge-level FDR across Tested Contexts < 0.05 ，它是 existence-oriented 证据（回答"该因子是否至少在一个被测试上下文中出现统计证据"），因跨上下文取最小而存在 extremum selection，不是 factor-level FDR。统计证据不能单独把因子提升为 Tier 1：Tier 1 要求覆盖度与方向一致率达标、稳健性条件成立、且 effect 门通过；统计门用于支持已有 effect 证据、排除缺乏统计支持的候选，并参与 Tier 2 与注释。由此：满足覆盖度 + 一致率 + effect 门记为 Tier 1；仅满足覆盖度记为 Tier 2；单个模型且有支持性证据记为 Tier 3。证据等级只读取 edge-level 增量效应、跨模型 bootstrap 置信区间、置换检验与 cell-line 一致性标签；析因 ANOVA 不参与等级判定（见下）。

需要强调：****证据等级是对已有计算证据的收敛性、覆盖度与稳健性的综合评级，不代表生物学效应强度，也不是效应量排名、显著性刻度或因果结论****；在增量效应很小的情形下（ $|\Delta R^2| < 0.01$ ），高等级仅表示多个模型对该小效应的判断一致（或该小效应在置换检验下稳定），不能解读为"强影响因素"。此外，edge-level 证据刻画的是"在给定背景下加入某因子"这一具体增量效应，而析因 ANOVA 刻画的是因子及其交互在整个析因设计中的全局变异（响应变量为留出 R^2 ，区组为模型/细胞系/划分）；两者回答不同问题，因此"ANOVA 未检出显著主效应"与"某因子达到 Tier 1"并不矛盾，不应互相引用为对方的证据或反例。

候选优先级与最小扰动方案

在证据整合之后，平台按预先设定的标准从既有结果中筛选用于后续实验验证的候选：(i) 多模型支持；(ii) 效应具有方向；(iii) 至少在一个人细胞系中效应较大；(iv) 统计或稳健性证据非空白；(v) 可设计最小扰动（单碱基替换或短序列破坏）；(vi) 不依赖复杂环境操控。候选及其依据、最小扰动方案与优先级记录于表 表14。平台在此环节只做****候选优先级排序****，不进行序列从头生成，也不声称任何候选已被实验验证。


软件与可复现性

平台实现为 Python 模块化分析引擎，训练与分析相互独立。所有统计量均由只读结果文件重新计算；分析方案、任务执行状态（analysis_status.json）与每个任务的产物路径同时落盘；报告层与图形界面只读取这些文件。本文全部数值由 analysis/reporting/paper/make_assets.py -batch ultimate_run 与 analysis/reporting/paper_analysis/build_paper_tables.py -batch ultimate_run 从该批次结果文件重新计算生成（不手工填写），数据质量表由 analysis/reporting/paper/make_data_quality_table.py 从验收明细生成，并逐项记录于补充材料表 表20 与项目文档中的事实来源表。

结果

本节按"数据可信度 预测信号及其边界 泄漏整改的影响 环境增量信息 多模型序列归因 多尺度 CNN 候选序列模式 细胞背景依赖 证据整合与候选优先级"的顺序组织。每个小节均明确区分直接计算观测、统计证据与生物学解释（假设）三层，并在最后一层显式标注其不确定性。

Platform: prediction → interpretation → evidence → hypothesis



平台的科学发现流程。实验测量数据依次经过质量控制、特征配置、受控多模型实验、模型特异性归因、统计与析因分析、序列模式发现、细胞背景比较与跨模型证据整合，最终形成候选因素与可检验假设。各阶段之间以结构化结果文件为接口，分析阶段只读训练产物。

数据质量与泄漏防控审计

问题与方法. 在报告任何模型性能之前，先确认结果本身是否可信：实验矩阵是否完整、划分是否自治、是否存在跨划分的同源序列、全批是否运行在同一数据/代码/环境之上。

观察（直接计算观测）. 权威批次 ultimate_run 的审计结果见表 8：1 344 次运行全部产出且可解析（single/all/mixed 各 448），无 0 字节文件、无 JSON 解析失败；**1 344 个 run 的 train 序列重叠与反向互补重叠全部为 0**；1 344 次运行的划分摘要 _digest 与本地按同一代码重算的结果**逐条一致（0 处不一致）**，即训练实际使用的划分与分析阶段使用的划分完全相同；数据指纹、代码指纹、环境指纹各只有一种取值，960 个神经网络 run 全部在 GPU 上执行，无 CPU/GPU 混跑。

统计证据. 上述为覆盖度与一致性的穷举核对（1 344/1 344），不涉及抽样，因此不报告 p 值。

解释（假设）与边界. 该审计能够支持的科学陈述是：“在本文定义的身份类（序列及其反向互补）下，训练集与测试集之间不存在序列级污染，且划分在训练与分析两侧完全一致”。它不能支持“数据中不存在任何形式的泄漏”这一更强陈述：同一 locus 的不同序列、同一细胞系内的批次效应、以及公共数据集本身的组成偏差均不在该检查的覆盖范围内。

数据集与实验空间. 过滤后保留 16 749 条 23 nt 序列（HCT116 4 239、HEK293T 2 333、HeLa 8 101、HL60 2 076），四个细胞系的平均归一化效率接近（0.232–0.257，表 9）。全部记录的第 22、23 位均为 G，据此确定 PAM 位于第 21–23 位。设计空间为 7 个模型配置 × 16 个环境组合 × 12 个（划分，种子）设定 = 1 344 次运行。结果级检查发现 Linear Regression 在 192 次运行中有 33 次（17\

预测信号及其边界

问题与方法. 模型是否学到了编辑效率信号？其能力边界在哪里？我们在留出测试集上汇总 7 个模型配置的表现（每配置 64 次运行），报告稳健统计量（中位数与四分位距）而非均值，并分别给出细胞系内（single）、跨细胞系混合（mixed）与留出细胞系（all，真实 LOCO）三种划分。

观察 1（细胞系内与混合划分：弱但稳定的正信号）. single 划分下各配置的中位 R^2 为：XGBoost 0.120、Transformer 0.097、MLP 0.096、CNN k=7 0.092、Linear Regression 0.082（58/64 有效）、CNN k=5 0.073、CNN k=3 0.067。mixed 划分下排序相近但幅度更低（XGBoost 0.094、CNN k=7 0.080、MLP 0.075、CNN k=5 0.070、Transformer 0.073、Linear 0.069、CNN k=3 0.041）（表 10、图 2A）。


观察 2（跨细胞系划分：性能塌陷至 0 或负值）. all（LOCO）划分下，**7 个模型配置的中位 R^2 全部落在 -0.112 至 +0.010 之间**：Transformer -0.009、XGBoost -0.008、MLP -0.001、CNN k=3 -0.027、k=5 -0.022、k=7 -0.011、Linear Regression +0.010。按留出细胞系展开后异质性极大：以 CNN k=3 为例，HCT 116 R^2 =+0.043、HeLa -0.023、HL60 -0.037、**HEK293T -0.266**（图 2C）。

统计证据. 留出系间的差异远大于同系内不同环境组合之间的差异，说明“留出哪个细胞系”是主导性能的因素。由于每个（模型，留出系）单元只有 16 次运行（环境组合数），本文不对留出系间差异做显著性检验，仅报告点估计与分布范围。

解释（假设）与边界. 三层证据支持如下解读：模型确实学到了与编辑效率相关的、可泛化的序列信号（single/mixed 中位数为正且跨 64 次运行稳定）；但该信号**不能跨细胞系迁移**（LOCO 中位 0 或为负）。可能的原因包括训练/测试之间的细胞背景分布漂移、表现特征在不同细胞系中的可比性不足、以及各细胞系序列组成差异（例如 HEK293T 在位置 18 的碱基分布更均匀）。跨细胞类型预测的困难在方法学文献中已有报

告[Schreiber2020GenomeBiol], 且细胞背景信息通常需要显式迁移建模而非默认由序列携带[Elkayam2024Bioinformatics]; 独立基准测试同样显示深度预测器在严格不重叠评估下泛化有限[Zhang2023BriefBioinform]。这些均属待检验假设, 本文不将其判为机制。

边界. LOCO 的训练池因剔除留出系同源身份类而缩减 ($n_{\text{train}} 1453-12313$, 见表 表10 与仓库结果表), 因此"跨细胞系性能为负"同时包含"分布漂移"与"训练样本减少"两种因素, 本文无法在本数据中完全分离二者。这一限制在 :limitations 中进一步讨论。



留出测试集预测性能 (每配置 64 次运行)。(A) single、mixed 与 all (真实 LOCO) 三种划分下各模型配置的 R^2 中位数; LOCO 分支整体落在 0 附近或以下。(B) single 划分下逐次运行的 R^2 分布 (散点为单次实验, 红线为中位数), 可见 Linear Regression 的发散运行。(C) 按留出细胞系展开的 LOCO 行, 显示极端的细胞系间异质性 (HEK293T 最低)。

泄漏整改前后的对照：一个必须报告的方法学结果

问题与方法. 项目早期批次 (batch_20260909_full) 采用按记录随机划分, 且 LOCO 分支未剔除留出系同源序列。为量化该问题的影响, 我们比较整改前后两个批次的同一批统计量 (两批使用相同的数据、模型配置与环境组合, 仅划分策略不同; 旧批次不进入本文任何结论)。

观察. 整改后 mixed 划分的中位 R^2 由 0.1184 降至 0.0734, all (LOCO) 由 +0.0362 降至 -0.0083, 而 single 划分基本不变 (0.0704 0.0808)。

解释 (假设). 三种划分的差异化变化说明: 受影响的正是"训练与测试之间存在同源序列"的情形。single 划分在单细胞系内部进行, 序列唯一 (该系内无重复序列), 因此不受影响; mixed 与 LOCO 涉及跨细胞系合并, 此前同一 sgRNA 序列可同时进入训练与测试两侧, 模型在测试集上部分"记忆"了已见序列, 从而系统性高估跨细胞系性能。用文献中的表述, 即 leakage-controlled evaluation revealed that the previously observed cross-cell-line performance was substantially inflated by sequence homology / repeated sequence observations across cell lines。

边界. 本文不主张"旧批次结果全部无效": 在无同源重复的 single 划分上两批结论一致。同样也不主张"模型完全没有跨细胞系泛化能力": LOCO 中位 R^2 接近 0 而非显著为负, 且 HCT116 作为留出系时仍为正 (+0.043)。准确的陈述是: 在排除同源序列污染后, 跨细胞系泛化性能从"弱正"变为"与均值基线无法区分"。

环境增量信息：四个因子均未达到预设效应门槛

问题与方法. 表现遗传环境是否在序列信息之外提供额外预测信息? 我们以 sequence-only 为基线, 对 16 个环境组合的全部 lattice 边计算配对 ΔR^2 , 并用逐样本配对 bootstrap、符号翻转置换检验与区组析因方差分析三种互补方式评估。


观察 1 (效应量级低于预设门槛). 四个因子的跨模型等权平均主效应为: CTCF +0.0003 (95\

观察 2 (边级与置换检验的一致性有限). 在 1978 条可检验 lattice 边上, 逐样本配对 bootstrap 的 95\

观察 3 (区组析因方差分析未检出任何显著效应). 以 R^2 为响应、四个环境因子为二水平因子、模型/细胞系/划分为区组的 Type-II 析因方差分析 ($df_{\text{den}}=1301$) 给出四个主效应 $p=0.975-0.9996$, 六个成对交互 $p=0.58-0.97$ (图 图3D)。

解释 (假设) 与边界. 综合三种方法, 本数据集**没有**提供支持"这四个环境因子具有达到预设门槛的独立增量预测贡献"的证据。这一结论的准确含义是未检出, 而不是无作用: ΔR^2 度量的是在已有序列模型基础上的增量预测价值, 环境信息可能与序列特征冗余、可能受限于二值化编码的分辨率[Klemm2019NatRevGenet], 四个通道也不足以代表完整 cell state; 此外若干细胞系-通道组合近乎常数 (例如部分细胞系的 DNase

通道方差极低)，这会直接压缩可检测的效应上限。值得注意的是，已有研究报告在 sgRNA 活性预测中加入 DNase 可及性轨道后**并未**提升预测性能[Wang2019NatCommun]，而染色质可及性与 H3K4me3 的关联强度也呈弱效应或不显著[UusiMakela2018PLoSONE]；另一方面，也有研究在特定细胞类型中报告表观特征带来增益[Ito2024NAR; Luboshitz2026TCBB]。因此本结果为"在通用多细胞系设定下未检出"，与上述文献并不矛盾。统计可检测性与生物学相关性是两件事，本文只报告前者。



环境因素的增量预测贡献与统计证据。(A) 各模型配置对四个环境因子的主效应 ΔR^2 (排除发散行)。(B) 主效应跨模型/上下文的分布。(C) 逐样本配对 bootstrap 中 95%

多模型序列归因指向 PAM 邻近位置

问题与方法. 模型归因是否指向可重复的序列位置，且这种指向是否跨模型类一致？我们比较五类模型的主归因方法（线性系数、TreeSHAP、MLP-IG、CNN-IG、注意力）在 23 个位置上的归一化归因分布，并分别在单碱基位置与粗粒度区域两个层级汇总。


观察 1（位置层级：第 18 与 20 位最稳定）. 跨模型平均归因谱的峰值位置为**第 18 位 (0.089)**，其后为第 20 位 (0.076)、第 23 位 (0.070)、第 19 位 (0.066) 与第 22 位 (0.065)。逐 run 统计"归因最高的位置是否落在 PAM 邻近窗口 (17-20)"：XGBoost 91.7%

观察 2（区域层级：仅两个模型类的最高区域为 PAM 邻近区）. 按四个粗粒度区域汇总后，XGBoost (0.333) 与 Transformer (0.330) 的最高归因区域确为 PAM 邻近种子区 (17-20)；但**CNN (0.343) 与 MLP (0.327) 的最高区域为种子核心区 (9-16)**，Linear Regression 的最高区域为 PAM 本身 (0.529)（图 4B、表 16）。跨模型位置谱的平均两两 Spearman 相关系数为 0.34（范围随上下文变化），top-3 位置重叠率 0.42。

观察 3（第 18 位碱基的观测性关联具有细胞背景依赖）. 各细胞系在第 18 位的碱基组成不同。按碱基分组的实测平均效率差 (C 减 A) 为：HCT116 +0.090 (C 0.309 vs A 0.219)、HeLa +0.092 (0.315 vs 0.223)、HL60 +0.027 (0.256 vs 0.229)、**HEK293T -0.015 (0.224 vs 0.239, 方向反转)**（图 4C、图 6B）。模型侧的碱基依赖同样存在：第 18 位归因中 C 通道的占比随模型与细胞系变化，而 Transformer 注意力在通道维度上不可分（恒为 0.25）。

统计证据. 观察 3 的差值来自实测标签的分组比较（观测性关联，样本量 1377-3278 条/C 组，见结果表 position18_efficiency_by_base.csv），不是模型产物；观察 1-2 为归因幅值的描述性汇总，attribution 幅值不构成统计显著性证据。

解释（假设）与边界. 支持"PAM 邻近区域（尤其第 18/20 位）是与编辑效率最相关的序列位置"这一表述的证据在位置层级较强（4/5 模型类的逐 run 峰值多数落在该窗口，跨模型平均谱峰值即为第 18 位），但在区域层级仅为部分模型（2/5）。本文因此放弃"所有模型类的最高归因区域均为 PAM 邻近区"的表述，改为：PAM 邻近位置在位置层级上被多模型一致地排在最高位，但在粗粒度区域汇总下，CNN 与 MLP 归因同样显著分布于种子核心区。此外，位置效应与碱基效应在本数据中不能完全分离，故统一使用"候选序列相关模式"的表述。



跨模型序列归因与第 18 位分析。(A) 五类模型在 23 个位置上的归一化归因谱（阴影为 PAM 邻近种子区 17–20 与 PAM 21–23）。(B) 四个序列区域的平均归一化归因（按模型）；仅 XGBoost 与 Transformer 的最高区域为 PAM 邻近区。(C) 第 18 位碱基与实测归一化效率的关系（按细胞系，观测性关联）。(D) 第 18 位归因中 C 的占比（按模型与细胞系）。归因幅值仅表示模型依赖强度，不构成统计显著性证据；不同模型的 importance 在模型内归一化，绝对值不可跨模型类直接比较。

多尺度 CNN：更宽的局部感受野带来小幅但可复现的提升


问题与方法. 序列卷积核大小（感受野）是否影响预测与解释？我们在 192 组严格配对的实验（同一划分、细胞系、环境组合与种子，仅卷积核不同）中比较 R^2 ，并比较三个核配置的归因谱与候选模式长度。

观察 1（提升方向一致但幅度有限）. 配对差分为： $k=5$ 相对 $k=3$ 提高 +0.0046（95%）

观察 2（解释随之改变）. 区域平均归因显示，感受野增大使归因向 PAM 邻近区与 PAM 区集中，而 PAM 远端区下降（图 图5C）。

观察 3（模式长度不随核大小改变）. 三个核配置提取的候选模式长度中位数均为 4 nt（分布 4–11），说明**卷积核大小是模型感受野参数，不能等同于候选模式长度**。

解释（假设）与边界. 结果支持一个模型层面的谨慎解释：在本案例数据中，更宽的局部感受野能更好地捕获 PAM 邻近上下文的依赖关系，从而带来小幅但方向一致的预测提升。该结论**限于预测与归因层面**，不能推断“更宽的序列上下文具有生物学因果必要性”。同时， $k=7$ 的归因谱与 $k=3/5$ 差异较大，说明归因结果对模型超参数敏感——这正是平台保留多配置交叉验证的原因。



CNN 感受野（多尺度局部序列上下文）分析。(A) 192 组配对实验的 ΔR^2 （均值与 95%）

候选序列模式及其统计支持

问题与方法. 归因能否进一步形成具有支持度、方向与统计检验的候选序列模式？我们按 :methods 流程从 C

NN IG/ISM 归因中提取 seqlet 并聚类，随后进行共识构建、支持度筛选与富集检验。

观察. 最终得到 **656 个候选模式** (标签反映跨核与跨细胞系复现性)，长度以 4 nt 为主；位置分布高度集中于 PAM 邻近区。富集检验 (前景为效率上三分位序列，背景为全部可用序列) 共 656 次，其中 **65 个通过 BH-FDR <0.05 (9.9\

统计证据. 富集检验提供的是"该模式在高效序列中更常见"的统计支持；由于多数候选模式与 PAM/种子区重叠，其统计支持部分来自该区域的整体重要性，未必构成独立的模式语法。


解释 (假设) 与边界. 三项限制尤须强调：其一，候选模式目前**仅具计算证据**，跨模型比较仅限 CNN 三个核配置 (缺少 Transformer IG 产物)，因此不能宣称"跨模型收敛的生物学 motif"；其二，富集结果目前多在单一细胞系中达到显著，属 context-dependent 候选；其三，通过 FDR 的 65 个模式须视为待实验验证的候选序列模式，而不是功能性 motif。本文统一使用"候选序列模式 (candidate sequence pattern)"的表述。

细胞背景依赖效应

问题与方法. 同一因素在不同细胞背景下是否保持方向与幅度？我们在环境因子主效应上按细胞系汇总，并依据方向一致率、幅度异质性与置信区间给出 context 标签。

观察. 环境效应的细胞系依赖明显 (图 图6A)：按模型与划分统计的 context 标签中，CTCF 有 12 个上下文被判为 Context-conflicting、1 个 Context-consistent、7 个 Uncertain；H3K4me3 同样为 12 个 Context-conflicting；DNase 以 Context-dependent (10) 与 Uncertain (11) 为主；RRBS 以 Uncertain (13) 与 Context-dependent (7) 为主。序列层面的异质性同样存在：第 18 位 C 相对 A 的实测效率差在 HCT116/HeLa 约为 +0.09，HL60 为 +0.027，HEK293T 为 -0.015。

解释 (假设) 与边界. 上述模式与"环境/序列效应具有细胞背景依赖性"这一假设一致，但本文不将其解释为机制差异：不同细胞系的样本量 (2 076–8 101)、标签分布与序列组成不同，也可能产生类似的方向变化。因此这里的结论限于"context-dependent association"。



细胞背景下的效应异质性。(A) 各环境因子的平均 ΔR^2 按细胞系展开 (排除发散行)。(B) 第 18 位碱基效应在四个细胞系中的方向与幅度 (HCT116/HeLa 为正且较大，HL60 较小，HEK293T 反向)。(C) 按模型与划分统计的 cell-line context 标签分布：冲突与不确定占多数。

证据整合与候选优先级


问题与方法. 如何把预测增量、模型归因、统计稳健性与一致性组织为可比较的证据，并据此排定后续实验的候选？平台按覆盖度、方向一致率、统计/归因强度与置信区间给出证据等级 (定义见 :methods)，并按 :methods 的六条标准筛选候选。

观察 1 (环境因素：四个因子全部为 Inconclusive)。CTCF、DNase、H3K4me3、RRBS 均未通过 effect 门 ($|\Delta R^2|$ 为 3×10^{-4} – 1.5×10^{-3} ，门槛 0.01)，跨模型 bootstrap 区间全部跨 0；CTCF 与 H3K4me3 另带 cell-line Context-conflicting 标签，DNase 与 RRBS 为 Uncertain。因此四者均判为 **Inconclusive** (表 表11、图 图7)。

观察 2 (序列层面：位置层级一致，区域层级部分一致)。一致的部分是 PAM 邻近位置在位置层级被多模型排在最高位 (跨模型平均谱峰值第 18 位；XGBoost/MLP 86–92\

观察 3 (候选优先级)。按预设标准筛选得到三类候选 (表 表14)：C1 为**第 18 位碱基替换** (多模型位置层级支持、细胞系依赖的实测效率差 +0.090/+0.092/+0.027/-0.015、CNN 替换敏感性支持，最小扰动为单碱基替换)；C2/C3 为**PAM 邻近候选序列模式的序列破坏** (在 65 个通过富集校正的候选中选取支持度最高者，最小扰动为 4 nt 核心替换)。

解释（假设）与边界. 证据整合的作用是区分稳定候选与模型特异性现象。需要强调：****所有候选均为待验证假设****，本文不包含任何湿实验验证；第 18 位的方向性结论以模型内部扰动（signed ISM 一类反事实分析）与观测性碱基关联为基础，尚不构成因果证据（:discussion、:future）。



证据整合：环境因子的跨模型平均主效应与 95\

讨论

泄漏审计改变了结论的方向，而不只是数值

本文最值得强调的结果是一个方法学结果：在排除跨细胞系的同源序列之后，同一批实验的 mixed 与 LOCO 性能显著下降，而单细胞系划分几乎不变（:res-leakage）。这种"只有涉及跨细胞系合并的划分才受影响"的模式，与"同源序列在训练与测试两侧重复出现"这一机制一致：在 single 划分中每个细胞系内部序列唯一，该问题不可发生；在 mixed 与 LOCO 中，同一 sgRNA 序列可同时出现在训练与测试两侧，模型在测试集上部分复现了已见序列的标签。

这一观察的意义超出本数据集：当模型评估使用随机划分时，"性能"同时包含泛化能力与记忆能力，而只报告精度无法区分二者。因此本文主张把"身份类定义 + 划分审计 + 划分摘要复核"作为基因组机器学习评估的常规组成部分[Kaufman2012TKDD; Whalen2022NatRevGenet]，而不是可选的工程细节；:methods-leakage 给出的三条约束（身份类整体划分、运行期重叠自证、划分摘要落盘）可直接迁移到其它序列建模任务。

CRISPR 活性预测领域已有基准工作指出，工具报告中较高的泛化性能在严格不重叠的评估集上会下降[Zhang2023BriefBioinform; Yuan2025CRISPRJ; Konstantakos2022NAR]，本文的结果与这一判断一致。跨领域审计也表明，泄漏与重复样本在机器学习文献中系统性存在且常未被报告[Kapoor2023Patterns]。需要克制的是结论边界：本文并不主张旧批次所有结果无效——在无同源重复的 single 划分上两批结论一致；也不主张模型完全没有跨细胞系泛化能力——LOCO 中位 R^2 接近 0 而非显著为负，且 HCT116 作为留出系时仍为正（+0.043）。准确的陈述是：leakage-controlled evaluation revealed that the previously observed cross-cell-line performance was substantially inflated by sequence homology and repeated sequence observations across cell lines。

为什么跨细胞系泛化接近 0

有证据支持的成分. (i) 训练与测试的细胞背景不同：LOCO 测试集完全来自未参与训练的细胞系，而四个细胞系的标签分布、序列组成与样本量均不同（表 表9）；(ii) 训练集规模随留出系变化：为满足无同源要求，训练池剔除与留出系共享身份类的全部序列（HCT116 留出剔除 4 266 条、HeLa 4 285 条、HL60 173 条、HEK293T 0 条）， n_{train} 由 12 313 降至 1 453；(iii) 留出系间的性能差异远大于同系内环境组间的差异，说明决定性能的是"留出哪个细胞系"。

可能但未被本文证实的解释（假设）. (i) 分布漂移：不同细胞系的序列-效率映射本身可能不同；(ii) 环境特征在不同细胞系中的可比性不足：二值可及性编码在不同细胞系中的动态范围与基线不同，部分通道在某些细胞系中近平常数；(iii) 各细胞系 library 设计差异导致的序列组成偏置（例如 HEK293T 在位置 18 的碱基分布更均匀）；(iv) 模型外推能力限制：全部模型在四个细胞系的联合分布上训练，缺少对未见细胞类型的显式建模（如领域自适应、细胞系不变表示或迁移学习[Elkayam2024Bioinformatics; Schreiber2020GenomeBioI]）。以上均为假设；本文的配对设计与现有数据不足以分离它们，:future 给出了分离"分布漂移"与"训练集缩减"的对照设计。

环境增量效应为何如此之小

四个表观因子的增量效应量级为 3×10^{-4} – 1.5×10^{-3} ，比预设门槛低 1–2 个数量级，且四者在证据框架中均

为 Inconclusive。本文强调这是未检出而非无作用，并给出四条可核查的解释路径：

1. 分辨率与编码：四个通道均为逐位点二值可及性，可能丢失连续信号（峰高、覆盖度、细胞类型特异的定量差异）。
2. 方差压缩：部分细胞系-通道组合接近常数，直接压缩可检测效应上限；常数特征在原理上不可能提供增量信息。
3. 与序列特征的冗余：若表观状态与序列组成在给定数据中相关，“序列 + 环境”相对“仅序列”的增量会很小，即使环境本身与效率相关。
4. 表征不完整：四个通道不足以代表 cell state；三维染色质结构、转录因子占据、DNA 修复状态、细胞周期等未纳入，缺失变量可能同时影响可及性与编辑结果。

上述解释路径有独立的文献支持其合理性：核小体与染色质状态在机制上限制 Cas9 的靶点接近[Horlbeck2016eLife; Liu2019GenomeBiol]，组蛋白修饰与可及性改造可改变编辑结果[Chen2022PNAS]，而表观药物的效应严格依赖细胞背景[Schep2024NAR]。但**这些文献支持的是“这些通道值得检验”，而不是“本文数据中它们具有可检测的增量贡献”**——两者不能互相替代。同时，已有研究在加入 DNase 轨道后未观察到预测提升[Wang2019NatCommun]，染色质可及性与 H3K4me3 的效应也报告为弱或不显著[UusiMakela2018PLoSone]，而报告增益的研究通常依赖与目标细胞类型匹配的表现基因组[Ito2024NAR]，或使用更丰富的侧翼序列与表观特征[Luboshitz2026TCBB]。

方法学上还需强调：统计可检测性与生物学相关性是两个不同问题； ΔR^2 度量的是增量预测价值，而非生物学效应的存在与否。!limitations 已把“未逐通道量化方差”列为未解决项。

序列层面的信号：位置层级一致、区域层级部分一致

跨模型归因在位置层级给出稳健指向：跨模型平均谱峰值位置为第 18 位，其后为第 20、23、19 位；XGBoost 与 MLP 分别有 91.7\

但本文明确不采用“所有模型类一致指向 PAM 邻近区”的强表述：按粗粒度区域汇总时，只有 XGBoost 与 Transformer 的最高区域为 PAM 邻近种子区，CNN 与 MLP 的归因更偏向种子核心区，线性模型集中在 PAM 本身(:res-sequence)。这种“位置层级一致、区域层级分歧”的模式本身有信息量：不同归纳偏置的模型对“重要性”的空间聚集方式不同，因此把归因汇总为单一区域结论会掩盖模型间差异。

同样需要限定的还有解释语言：归因表示模型依赖强度，不表示统计显著性，也不表示生物学机制；不同模型的 importance 在模型内归一化，绝对值不可跨模型类比较。这一限定有方法学依据：梯度类归因在基因组模型中会被网络结构（缩放、归一化层）系统性扭曲[Majdandzic2023GenomeBiol]，归因方法之间在同一预测上频繁不一致[Krishna2024TMLR; Reynolds2025PLoSComputBiol]，领域综述同样强调归因属于需要实验验证的模型层信号[Novakovsky2023NatRevGenet]。

第 18 位 C：一个待验证的候选假设

平台输出中最具体的候选来自第 18 位：多模型位置层级归因将其排在首位；观测数据显示该位置 C 相对 A 的实测效率差在 HCT116 (+0.090) 与 HeLa (+0.092) 中较大、在 HL60 中减小 (+0.027)、在 HEK293T 中方向反转 (-0.015)；模型内部的方向性扰动分析（signed in-silico mutagenesis 一类反事实计算）提示 C/G/T 均对应预测效率下降、其中 C 幅度最大。

本文对该结果的定位是候选机制假设（candidate mechanistic hypothesis），而不是发现。理由有三：其一，方向性结论来自模型在输入空间上的扰动响应，刻画的是模型的敏感性，不是 Cas9 在细胞内的行为；其二，该位置的观测性碱基关联与“携带该碱基的序列子集的其它特征”在本数据中不可完全分离；其三，本文没有任何湿实验验证。因此正确的表述链条是

center 模型预测 方向性反事实 候选生物学假设 需要实验验证， center

而不是“C18A 导致编辑效率下降”。:future 给出了最小扰动实验设计（仅替换第 18 位碱基、其余 22 nt 不变）与预注册判定标准。该假设的生物学合理性可参考 Cas9-DNA 识别、种子区特异性与 PAM 邻近位置敏感性的既有研究[Jinek 等, Science 2012; Semenova2011PNAS; Fu2014NatBiotechnol; Hsu2013NatBiotechnol; Zheng2017SciRep]；但文献只能支持“该假设值得检验”，不能替代本文缺失的实验证据。需要特别说明的是，**本文未检索到针对第 18 位（或该位点 C 替换）的实验测量报道**，因此该候选是一个**尚无文献先例的、由模型反事实推导出的新假设**；对单碱基位置效应的系统表征需要饱和突变或组合突变类实验[Doench 等, Nat Biotechnol 2014; Thean2022NatCommun]。

平台层面的贡献与适用边界

本文的贡献不在于性能：细胞系内中位 R^2 仅 0.067–0.120，LOCO 为 0 或负值。平台的价值在于三点：(i) 可审计性——数据质量、划分身份与泄漏状况在使用任何结果之前被穷举核对并落盘（表 8）；(ii) 证据分层——直接计算观测、统计证据与生物学解释在全文被显式区分，模型特异性与上下文依赖的分歧被保留而非平均掉；(iii) 可检验输出——所有候选均附带最小扰动方案、优先级与判定标准，可直接进入实验设计。

适用边界必须同时说明：平台的流程级结论（泄漏可审计、证据可分级、候选可追溯）具有一般性；而可及性本身是细胞类型特异的[Klemm2019NatRevGenet]、CTCF 位点功能依赖局部结构与合作因子[Guo2018GenomeBiol]，这两点也解释了为什么单一全局标量特征难以跨细胞系迁移；具体效应量级、候选因素与“环境因子未检出增量效应”的结论限于本数据集、当前编码方式与 SpCas9/NGG 体系。当环境特征分辨率提高、细胞系覆盖扩展或引入领域自适应建模时，本文关于环境增量与环境泛化的结论都可能改变——这也是本文严格区分“未检出”与“无作用”的原因。

局限性

本节把限制按“数据、模型与评估、因果、泛化”四层列出，并在每一条后标注本文是否已给出对应证据。凡本文未能验证者，一律标为未解决，不以推断代替证据。

数据层面

1. 使用公开数据，非本研究自建实验。全部标签与表观轨道来自 DeepCRISPR 公开数据集[Chuai 等, Genome Biol 2018]，其 library 设计、实验批次与筛选条件由原始研究决定；本研究无法追溯每个位点的实验批次效应。状态：已确认的边界，不可由本文数据解决。
2. 细胞系数量有限且不平衡。仅 4 个细胞系，样本量 2 076–8 101（相差近 4 倍）。混合与 LOCO 划分下，训练与测试的细胞系构成差异会同时改变样本量与序列组成，本文无法完全分离二者影响。状态：已量化（表 表9、表 表10），未解决。
3. 环境变量仅四条且分辨率有限。CTCF、DNase、H3K4me3、RRBS 为逐位点二值可及性编码；四个通道不足以代表完整 cell state（三维染色质结构、转录因子占据、细胞周期、DNA 修复状态等未纳入）。部分细胞系–通道组合近似常数，会直接压缩可检测效应上限。状态：已报告效应量级与区间（:res-environment），但未逐通道量化方差，属未解决。
4. 泄漏审计的身份类仅覆盖序列与反向互补。本文审计覆盖 sequence 与 reverse-complement 两个层级，未覆盖同一 locus 的不同序列、同源但不完全相同的序列以及公共数据库层面的重复提交。状态：审计边界已明确（:res-data）；更广层级的污染未排除。
5. 历史泄漏批次的对照受限于两批可比的统计量。本文仅在 single/mixed/all 三个中位 R^2 上做前后对照（:res-leakage），未对旧批次重算全部下游分析。状态：对照范围有限，已在文中标注。

模型与评估层面

1. 预测性能总体较弱。细胞系内与混合划分的中位 R^2 约 0.04–0.12，跨细胞系（LOCO）中位 R^2 为 -0.11 至 +0.01。本文不将预测精度作为主要贡献，也不据此判断生物学重要性。状态：已量化（表 表10）。
2. LOCO 的“分布漂移”与“训练集缩减”混杂。为保证无同源泄漏，LOCO 训练池剔除了与留出系共享身份类的全部序列（HCT116 留出时剔除 4 266 条、HeLa 4 285 条、HL60 173 条、HEK293T 0 条），训练样本量随留出系由 12 313 降至 1 453。跨细胞系性能下降同时包含两种原因，本文无法在本数据中定量分离。状态：剔除条数已量化，混杂未解决。
3. 模型选择未独立于评估集。平台在同一批测试集上比较 7 个模型配置与 16 个环境组合，属探索性比较；虽有配对设计与 bootstrap/置换稳健性检验，仍存在选择偏差风险。本文不把“某配置最优”作为结论。状态：已声明，未通过嵌套验证解决。
4. 不同模型的 attribution 语义不同。线性系数、TreeSHAP、IG、ISM 与注意力权重在定义、尺度与可加性上均不同；本文在模型内部归一化后比较相对分布，并禁止跨模型比较绝对值。状态：已在方法与图注中限定。
5. 归因对超参数敏感。CNN k=7 的归因谱与 k=3/5 差异较大（:res-kernel），说明解释结果依赖模型配置；本文通过保留多配置交叉验证暴露该敏感性，而不选取单一“最好”配置。状态：已展示。
6. 自助区间的推断单位是模型而非样本。因子级区间为 Model-Level Bootstrap Interval（n=7 个模型配置）；7 个模型共享同一份数据、标签、预处理与划分，不构成独立生物学重复，该区间刻画 effect 的跨模型稳健性，不应解释为总体抽样置信区间，n=7 下百分位自助法的覆盖性质亦无严格保证。状态：已限定。
7. 部分 run 数值发散。33 个 Linear Regression run 出现 $|R^2| \geq 10$ （共线性设计矩阵导致病态求解），全部被隔离而非删除，相关统计量以有效 run 数报告。状态：已量化并在表中单列。

因果层面

1. 预测关联不等于因果关系。本文全部结果均为观察性数据上的预测与归因分析，不能支持“某因素导致编辑效率变化”的陈述。
2. signed ISM 是模型内部反事实，不是实验验证。第 18 位 C/G/T 的方向性结论来自模型在输入空间上的扰动响应，刻画的是模型的敏感性，而非 Cas9 在细胞内的行为；该结果只能产生候选假设。
3. 无湿实验验证。本文未开展任何 guide 效率测定、竞争实验或结构实验，所有“候选”均停留在待验证状态。
4. 观测性碱基关联存在混杂。第 18 位 C 与 A 的效率差在不同细胞系中幅度与方向不同，而四个细胞系的序列组成、样本量与标签分布均不同，“位置 18 的碱基效应”与“携带该碱基的序列子集的其它特征”在本数据中不可完全分离。
5. 模型归因的一致性不等于生物学正确性。多个模型类给出一致归因只能说明它们在当前数据上依赖了相似的特征，不能排除它们共同依赖了数据中的混杂结构。

泛化层面

1. 结论不可直接外推到其它 Cas 蛋白。本文仅使用 SpCas9（NGG PAM）数据，不覆盖 Cas12a、碱基编辑器、先导编辑或其它编辑模态。
2. 结论不可直接外推到其它细胞系与实验协议。LOCO 结果显示跨细胞系迁移失败，因此性能结论不

应外推到未参与训练的细胞类型；不同 library 设计、转染方式与 readout 也会改变可学习信号。

3. 平台层面的结论比具体数值更可外推。"流程可追溯、泄漏可审计、证据可分级"属于方法学贡献；具体效应量级与候选因素均限于本数据集。

结论

本文提出并在一个经过完整质量审计的批次上验证了一个面向基因编辑影响因素发现的科学发现平台，以 DeepCRISPR 公开数据作为案例研究。平台的定位不是构造单一最优预测器，也不是证明表观遗传环境必然提升预测，而是把质量控制、数据划分与泄漏审计、模型归因、统计推断、环境增量分析、序列模式发现、细胞背景比较与证据整合组织为统一且可追溯的流程。

案例研究的主要结论如下，每条均标注其证据强度：

1. 数据可信度（穷举核对，强）：1344 次运行的实验矩阵完整，1344/1344 的 train 序列重叠与反向互补重叠为 0，划分摘要逐条复核一致，全批运行于同一数据、代码与数值栈之上（表 8）。
2. 泄漏整改改变结论方向（对照观测，中）：在排除跨细胞系的同源序列后，mixed 中位 R^2 由 0.118 降至 0.073，LOCO 由 +0.036 降至 -0.008，而 single 划分基本不变。这一差异化变化表明此前较高的跨细胞系性能至少有相当部分由同源序列重复支撑。
3. 预测能力有限且跨细胞系泛化失败（定量观测，强）：细胞系内中位 R^2 为 0.067–0.120，混合划分为 0.041–0.094，而真实 LOCO 的 7 个模型配置全部落在 -0.112 至 +0.010，并呈显著细胞系异质性（HEK293T 最低， $R^2=-0.266$ ）。因此本文不主张一个具有跨细胞系泛化能力的通用预测器，而将平台定位为受控、可追溯的影响因素研究框架。
4. 序列信号集中在 PAM 邻近位置（多模型描述性汇总，中）：跨模型平均归因谱的峰值位置为第 18 位（其后为 20、23、19），XGBoost 与 MLP 分别有 91.7\
5. 环境因素未获得增量预测证据（区间与门槛判定，强）：CTCF、DNase、H3K4me3、RRBS 的效应量为 3×10^{-4} – 1.5×10^{-3} ，比预设门槛 0.01 低 1–2 个数量级；跨模型区间全部跨 0；区组析因方差分析四个主效应 $p=0.975$ – 0.9996 。四者在证据框架中均为 Inconclusive。这一结论是未检出，不是无作用。
6. 感受野带来小幅但可复现的提升（配对实验，中）： $k=7$ 相对 $k=3$ 提高 +0.0169（区间 +0.0077–+0.0257，79.7\
7. 可检验的候选假设（模型内部反事实，弱—中）：平台输出第 18 位碱基替换与 PAM 邻近候选模式破坏两类最小扰动候选，用于后续实验验证。这些候选基于模型归因与观测性碱基关联，不构成因果证据。

综上，本文的贡献不在于报告一个高精度预测器，而在于展示：在严格控制数据真实性、明确划分身份并审计泄漏之后，仍可以从有限预测能力中提取可解释、可检验的科学信号，同时明确哪些问题当前数据无法回答。后续工作有两条主线：一是在独立编辑数据集上检验流程与候选的可迁移性；二是对本文提出的候选假设开展最小扰动实验验证。

未来实验验证

本文不包含任何湿实验数据；本节说明如何用最小实验设计检验平台输出的候选假设，并给出判定标准。

方向一：第 18 位碱基替换（候选 C1）。选择若干携带目标位点的 sgRNA，仅替换第 18 位碱基（C→T/right arrowA），保持其余 22 nt 完全不变，在同一实验体系中测定编辑效率并做配对比较。该设计直接检验"模型优先排序的核苷酸差异是否伴随实测效率变化"，并可通过在多于一个细胞系中重复，检验平台提示的上下文依赖性（HCT116/HeLa 的 C-A 差约 +0.09，而 HEK293T 为 -0.015）。读出指标建议与本文数据一致（归一化编辑效率），并预先登记样本量、重复次数与分层比较方案。

方向二：PAM 邻近候选序列模式破坏（候选 C2/C3）。在包含目标 4 nt 核心的 sgRNA 中替换该核心，同时匹配 GC 含量与长度以控制混杂，比较携带与不携带核心序列的实测效率。由于富集证据目前仅见于单一细胞系，实验应优先在该细胞系中进行，并在其它细胞系作为探索性重复。

方向三：独立数据集与真正的泛化验证。本文的 LOCO 分支已按无同源泄漏的方式重跑（448 次运行），结果显示跨细胞系泛化为 0 或负值；后续应在独立编辑数据集（不同细胞类型或不同编辑系统）上检验：(i) 平台流程的可迁移性；(ii) 位置层级序列信号（第 18/20 位）是否复现；(iii) 环境增量效应是否在更高分辨率的环境特征下变得可检测。

方向四：分离"分布漂移"与"训练集缩减"。本文 LOCO 中两种因素混杂（:limitations）。建议的对照设计为：在保持训练样本量不变的前提下构造无同源泄漏的训练池（例如对留出系同源序列做等量重采样替代），从而分离二者的贡献。

预期输出与判定标准。上述实验的预期输出为"候选假设被支持/不被支持"的判定与效应量估计；判定应基于预先登记的统计方案（分层比较与多重检验校正），并使用与本文一致的指标口径。无论方向如何，实验都将用于评估"AI 候选优先级 实验验证"闭环的实用价值。

数据与代码可用性

案例数据来自公开的 DeepCRISPR 数据集[Chuai 等, Genome Biol 2018]；处理后特征位于 data/processed/，数据划分与泄漏审计代码位于 core/data/splitting/。

本文全部定量结论仅来自经过验收的权威批次 ultimate_run（results/batches/ultimate_run/）：1344 次运行，`single`/`all`/`mixed` 各 448。该批次的逐 run 验收明细（覆盖度、划分摘要复核、序列与反向互补重叠、数据/代码/环境指纹、设备）由 deploy/hpc/verify_hpc_rerun.py 生成并保存为 tresults/table

s/audit/ultimate_run_verify_\runs,summary,report\,csv/md。存在已确认划分泄漏的历史批次 batch_20260909_full 已标记废弃，仅用于 :res-leakage 的前后对照，不作为任何结论依据。

图表与表格由结果文件重新计算生成，不手工填写：analysis/reporting/paper/make_assets.py -batch ultimate_run（图 1-7 与表 1-6）、analysis/reporting/paper_analysis/build_paper_tables.py -batch ultimate_run（论文中间表）、analysis/reporting/paper/make_data_quality_table.py -batch ultimate_run（表 表8）。分析方案（AnalysisPlan）、任务执行状态与每个任务的产物路径随批次一并保存（summary/analysis_plan.json、analysis_status.json、execution_log.json），可逐项追溯（附录 表19）。

作者贡献

（待补）

利益冲突声明

作者声明不存在利益冲突。


附录

补充信息

S1 分析阈值汇总

S1b Importance- ΔR^2

\$ 辅助视图



辅助视图：环境因子的增量预测价值（ ΔR^2 ）与模型内归一化 importance 的关系。该图**不**是显著性图： ΔR^2 i mportance, importance 显著性；各模型的 importance 在其模型/分析组内归一化，绝对量级不可跨模型类直接比较。

S2 跨模型位置归因一致性

S3 完整预测性能

全部 7 个模型配置在 single 与 mixed 划分下的留出集指标（中位数、均值、标准差与发散计数）见 paper/tables/tab2_prediction.tex；按 held-out 细胞系分组的 28 行结果保存在 tables/loco_performance.csv，其中每一行对应的原始实验可在 tables/experiment_table.csv 中按 (model,split_type,cell_line,environment,random_seed) 追回。需要再次强调，本批次中 all 划分与 single 划分逐位相同，因此该表不构成跨细胞系泛化证据。

S4 环境因素的完整统计结果

完整结果包含：(i) 1906 条 lattice edge 的配对 ΔR^2 及其逐样本 bootstrap 置信区间（tables/bootstrap_results.csv, 7770 行含 $\Delta MAE/\Delta RMSE$ ）；(ii) 3444 条置换检验记录，含每行的零假设、备择假设、观测效应、p 值与所属 FDR 族（tables/permutation_results.csv）；(iii) 94 项析因方差分析结果，含 F、自由度、p、partial η^2 与效应的 bootstrap 置信区间（tables/anova_results.csv）；(iv) Fact orial Environment DAG 的节点与边表（tables/environment_nodes.csv、environment_edges.csv），其中每条边标注是否 metric inconsistency、是否有可用 CI。

S5 候选序列模式

596 个候选模式的支持度、IUPAC、人类可读形式、正则形式、位置分布、方向与证据等级见 tables/motif_candidates.csv；545 060 条 seqlet 实例见 tables/motif_instances.csv；富集检验结果见 tables/motif_enrichment.csv；跨核配置与跨细胞系一致性见 tables/motif_consistency.csv；motif 级证据行见 tables/motif_evidence.csv。表 表13 给出支持度最高的 10 个代表模式；表 表14 给出用于后续实验验证的候选假设与其最小扰动方案。

S6 结果文件与交互式报告

平台同时输出可供交互探索的科学发现报告（Interactive Scientific Discovery Report），包含数据质量、预测、环境、序列与模式、细胞系、证据整合、假设与溯源等章节，支持表格筛选、证据卡、图形查看与 artifact 追溯。报告层只读取结果文件，不重新计算任何统计量，从而保证论文数值与报告数值同源。

论文事实来源映射

本文每一处定量结论均可在表 表20 中追溯到具体结果文件与图表。生成脚本为 paper/make_assets.py，完整映射表另见 docs/paper_claim_provenance.md。

论文结论与结果文件映射（节选；完整版见 docs/paper_claim_provenance.md）。

p6.6cmp2.6cm 结论	结果文件 / 字段	图表
数据规模与组成	data/proceeded_data/*_metadata.csv	表 表9
预测性能（中位数/IQR/发散数）	tables/experiment_table.csv (R2)	表 表10、图 图2
环境 ΔR^2 与跨模型一致性	tables/environment_main_effects.csv	表 表11、图 图3
逐样本配对 bootstrap	tables/bootstrap_results.csv、environment_bootstrap_results.csv	图 图3C
置换检验与 BH-FDR	tables/permutation_results.csv	表 表11
析因方差分析	tables/anova_results.csv	图 图3D
位置归因与区域划分	tables/attribution_summary.csv	图 图4A–B
第 18 位碱基效应	docs/paper_analysis/position18_efficacy_by_cell_line.csv	图 图4C
CNN 核消融配对差	docs/paper_analysis/cnn_kernel_paired_difference.csv	表 表12、图 图5A
候选模式与富集	tables/motif_candidates.csv、motif_enrichment.csv	图 图5D、表 表13
细胞系异质性	tables/cellline_effects.csv	图 图6
证据分级与 CI	tables/evidence_matrix.csv	表 表11、图 图7
Importance- ΔR^2 关系	tables/importance_vs_delta_r2.csv	图 图7B

document

参考文献（完整 BibTeX 见 references.bib）

[1] Jinek 等, Science 2012 (Jinek2012Science)
[2] Cong 等, Science 2013 (Cong2013Science)
[3] Doench 等, Nat Biotechnol 2014 (Doench2014NatBiotechnol)
[4] Doench 等, Nat Biotechnol 2016 (Doench2016NatBiotechnol)
[5] Moreno-Mateos 等, Nat Methods 2015 (MorenoMateos2015NatMethods)
[6] Chuai 等, Genome Biol 2018 (Chuai2018GenomeBiol)
[7] Alipanahi 等, Nat Biotechnol 2015 (Alipanahi2015NatBiotechnol)
[8] Kelley 等, Genome Res 2016 (Kelley2016GenomeRes)
[9] Chen \& Guestrin, KDD 2016 (Chen2016KDD)
[10] Lundberg \& Lee, NeurIPS 2017 (Lundberg2017NeurIPS)
[11] Sundararajan 等, ICML 2017 (Sundararajan2017ICML)
[12] Vaswani 等, NeurIPS 2017 (Vaswani2017NeurIPS)