

面向基因编辑系统的细胞环境感知型核酸工具 智能设计与影响因素发现平台

(作者信息待补)

2026 年 9 月 12 日

摘要

基因编辑效率的机器学习预测已取得进展，但预测精度的提升并未同步带来对影响因素的可靠解释：线性模型方向明确但表达受限，树模型的重要性指标缺乏方向，深度模型的内部表示难以直接解读。针对这一“预测—解释”缺口，本研究构建了一个基因编辑影响因素科学发现平台，把质量控制、特征工程、受控多模型实验、模型归因、统计推断、环境因素析因分析、序列模式挖掘、细胞背景比较与跨模型证据整合组织为一条可追溯的分析流程，并以 DeepCRISPR 公开数据（4 个细胞系、16 749 条 23 nt 靶序列、1 344 次受控训练运行）开展案例研究。平台使用 Linear Regression、XGBoost、多层感知机（MLP）、双分支卷积神经网络（CNN，序列卷积核 3/5/7）与 Transformer 五类具有不同归纳偏置的模型，并严格区分预测效应（ ΔR^2 ）、模型归因、稳健性与统计证据。

案例研究的主要观察包括：(i) 五类模型均取得正的中位留出集 R^2 (0.035–0.115)，说明数据中存在可学习但较弱的编辑效率信号；(ii) 四个模型类（CNN、MLP、Transformer、XGBoost）独立地将 PAM 邻近种子区（第 17–20 位）识别为最高归因区域，第 18 位在跨模型平均归因谱中排序最高，且该位置 C 相对 A 的实测效率差在 HCT116 (+0.090) 与 HeLa (+0.092) 中较大、在 HL60 中减小 (+0.028)、在 HEK293T 中方向反转 (−0.015)，提示该位置的碱基关联具有细胞背景依赖性；(iii) 在 192 组严格配对实验中，CNN 序列卷积核 5 与 7 相对核 3 的 ΔR^2 分别为 +0.042 与 +0.056，且归因向 PAM 邻近区域集中，而三个配置提取的候选模式长度中位数均为 4 nt，说明卷积核是模型感受野参数而非模式长度；(iv) 环境因素的跨模型平均增量预测价值很小 ($|\Delta R^2| < 0.01$)，2 541 个边 × 种子检验中仅 257 个置信区间不跨 0，区组析因方差分析未检出显著主效应 ($p = 0.056$ –0.663)；(v) 从 CNN 归因中提取到 596 个候选序列模式，其中 64 个通过富集错误发现率校正，但这些候选模式目前仅具计算证据。

平台的科学性不体现在“所有分析均得到阳性结果”，而体现在统一的、可追溯的框架中区分稳定证据、模型特异性现象、上下文依赖现象与不确定结果，并据此输出可检验的候选假设（如第 18 位碱基替换、PAM 邻近候选模式扰动）。本研究属于 ** 计算案例研究 (computational case study) **：已完成受控计算验证、统计推断与候选因素优先级排序，尚未开展湿实验验证；平台输出的是待验证假设，而非已确认的生物学机制。

关键词： CRISPR-Cas9；sgRNA 编辑效率；多模型可解释机器学习；增量预测贡献；序列归因；候选序列模式；细胞系异质性；证据整合；生物学假设生成

1 引言

1.1 基因编辑工具设计中的预测与理解

CRISPR-Cas9 通过可编程的 RNA-DNA 配对实现定点切割，sgRNA 的活性差异使“实验前筛选高效位点”成为核心计算问题 [Jinek et al., 2012, Cong et al., 2013]。早期方法依赖序列组成与位置偏好的人工规则 [Doench et al., 2014, Moreno-Mateos et al., 2015]，随后被数据驱动模型取代：DeepBind 与 Basset 证明卷积网络可从序列实验数据中学习局部序列特异性 [Alipanahi et al., 2015, Kelley et al., 2016]；DeepCRISPR 进一步把序列与细胞特异性表观遗传信息 (CTCF、DNase、H3K4me3、RRBS) 纳入统一编码，用于 sgRNA 活性与脱靶预测 [Chuai et al., 2018]；Rule Set 2 等方法也显著提升了预测能力 [Doench et al., 2016]。

1.2 仅靠预测无法回答影响因素问题

预测能力的提升并不意味着研究者能够理解模型依据哪些因素作出判断。不同模型类别的可解释性各有边界：线性模型给出方向与统计量但表达受限；树模型可建模非线性与交互 [Chen and Guestrin, 2016]，但 Gain/Weight/Cover 没有方向；深度模型的内部表示难以直接解释。SHAP 与 Integrated Gradients 分别从 Shapley 值与公理化归因出发提供了通用解释工具 [Lundberg and Lee, 2017, Sundararajan et al., 2017]，Transformer 则以自注意力建模跨位置关系 [Vaswani et al., 2017]。然而，即使归因可用，仍需回答：哪些序列位置与模式与效率相关？表观遗传环境是否在序列之外提供 ** 额外预测信息 **？同一因素在不同细胞背景下是否稳定？不同模型是否 ** 独立 ** 支持同一候选因素？

1.3 从“模型解释”到“科学发现流程”

现有研究中，预测、归因、统计与跨条件比较往往分散在不同脚本与不同报告里，导致结论难以逐项追溯，也容易把模型依赖强度误读为生物学效应。本研究的目标是构建一个 ** 科学发现平台 **：把上述分析组织为统一、可复现、可追溯的流程，使每一步结论都能回溯到具体结果文件，并明确区分：预测效应 (ΔR^2)、模型归因 (attribution)、稳健性（如信噪比）与统计证据 (p /FDR)。

平台围绕三个研究问题组织分析：(1) ** 序列 **：哪些位置与候选模式与编辑效率相关？(2) ** 环境 **：细胞表观遗传信息是否提供额外的预测信息？(3) ** 背景 **：同一因素在不同 cell line 中是否保持一致？在此框架中，预测模型是发现影响因素的工具，而不是最终结论。

1.4 案例研究与贡献定位

本文以 DeepCRISPR 公开数据作为 ** 案例研究 (case study) **，检验平台能否从多模型、多条件的受控实验中发现可解释、可追踪、可比较的候选因素。案例研究 ** 不 ** 用于主张平台在预测精度上优于已有方法，也 ** 不 ** 用于证明表观遗传环境必然提升预测——后者的检验结果在本案例中为弱证据（见 §3.3）。平台的贡献在于：(i) 统一的、以结果文件为接口的多模型发现流程；(ii) 在该流程中同时保留稳定证据与模型特异性/上下文依赖证据；(iii) 从计算证据出发给出可实验检验的候选假设与最小扰动方案。

2 材料与方法

2.1 平台总体架构

平台按“科学引擎生成结果文件、报告层消费结果文件”的原则组织（图 1）。数据质量控制、特征工程、受控训练、归因与统计模块之间只通过结构化结果文件（CSV/JSON/Markdown）交换信息，因此训练可以在本地或高性能计算环境中独立执行，下游分析在获得结果后离线运行。平台在分析阶段不修改任何训练产物：所有统计量与图表均由只读结果文件重新计算，随机种子、阈值与分析方案统一记录在配置文件中。工程实现细节（模块划分、接口约定、测试）见补充材料与项目仓库文档。

2.2 案例数据集

案例数据为 DeepCRISPR 公开数据集 [Chuai et al., 2018]，包含四个细胞系（HCT116、HEK293T、HeLa、HL60），每条记录包含 23 nt 靶序列、实测归一化编辑效率与四条逐位点表观遗传轨道（CTCF、DNase、H3K4me3、RRBS 的二值可及性）。过滤非法碱基后共 16 749 条序列进入分析（表 1）。

数据编号经核对：全部记录的第 22、23 位均为 G，即 PAM 位于第 21–23 位（NGG），第 1–20 位为 protospacer。本文据此定义 PAM 邻近种子区为第 17–20 位、种子核心区为第 9–16 位、PAM 远端区为第 1–8 位。

2.3 特征表示

序列采用 23×4 one-hot 编码；四条表观遗传轨道以逐位点二值形式拼接，形成 23×8 输入张量（184 维展平特征）。环境组合通过通道掩码实现：给定环境因子集合 S ，未启用的表观通道整体置零，张量维度保持不变，从而保证不同环境组合之间的差异只反映信息可用性。Linear Regression 按统计惯例剔除 $_T$ 参照列（184→161），其余模型使用完整 184 维。

2.4 受控实验设计

每个（模型配置 $\times$ 环境组合）在三种划分下训练：*single*（单细胞系内 70%/15%/15%，种子 42，四个细胞系各一次）；*all*（按 held-out 细胞系分组的行）；*mixed*（四细胞系混合，种子 42–45）。7 个模型配置 $\times$ 16 个环境组合 $\times$ 12 个（划分，种子）设定共产生 **1 344 次训练运行**，全部结果在留出测试集上评估（ R^2 、RMSE、MAE、Pearson、Spearman）。

需要明确的数据限制：本批次中 *all* 划分的 R^2 与 *single* **逐位相同** ($\max |R_{\text{all}}^2 - R_{\text{single}}^2| = 0$)，说明预期的留一细胞系（LOCO）分支在该批次中退化，因此本文 **不** 将其解释为独立的跨细胞系泛化证据；真正的 LOCO 验证属于后续工作 (§7)。

2.5 模型与归因方法

平台使用五类模型（7 个配置）：Linear Regression（线性主效应与统计检验）、XGBoost（非线性与交互 [Chen and Guestrin, 2016]）、MLP（一般非线性组合）、双分支 CNN（序列分支 + 环境分支，序列卷积核 $k \in \{3, 5, 7\}$ ，用于建模不同宽度的局部序列上下文）与 Transformer（跨位置交

互 [Vaswani et al., 2017])。归因方法分别为：回归系数 (含 SE、 t 、 p 、FDR)、TreeSHAP [Lundberg and Lee, 2017]、Integrated Gradients (IG) [Sundararajan et al., 2017]、CNN 的 IG 与 In Silico Mutagenesis (ISM, 逐位点核苷酸替换效应) 以及注意力权重。

平台强制语义边界： ΔR^2 表示增量预测价值；attribution 表示模型依赖强度；SNR 表示归因稳健性； p /FDR 仅来自具备明确零假设的统计检验 (配对 bootstrap、置换检验、析因方差分析与富集检验)。** 注意力权重、SNR 与树内部重要性均不作为统计显著性 **，注意力在本研究中仅作支持性信息，不用于候选模式提取。

2.6 环境因素析因分析

对每个 (划分, 细胞系, 模型, 种子) 分组定义配对增量

$$\Delta R^2_{e|S} = R^2(S \cup \{e\}) - R^2(S), \quad (1)$$

其中 S 为基线环境集合, e 为新增环境因子, 二者来自同一测试集。平台枚举 16 节点的 factorial lattice 的全部单因素边 (同一组合可多个父节点), 节点记录 R^2 /RMSE/MAE/Pearson/Spearman 均值, 边记录配对的 ΔR^2 、 Δ MAE、 Δ RMSE。主效应为对全部不含 e 的背景 S 的条件增量均值; 交互效应为 $I(a, b) = \Delta(a | S_0 \cup \{b\}) - \Delta(a | S_0)$ 在背景 S_0 (不含 a, b) 与种子上的平均。

2.7 统计方法

(1) **逐样本配对 bootstrap**: 对每条 lattice 边, 使用两侧模型在同一测试样本上的逐样本预测, 以 $B = 2000$ 次重采样计算 ΔR^2 的百分位置信区间 ($\alpha = 0.05$, 种子 2024); 样本数不等或预测文件缺失时标记为不可用。(2) **因子级 bootstrap**: 对每个环境因子, 先计算各模型稳定主效应的均值 (模型等权), 再对该模型向量重采样, 保证置信区间与点估计同口径 ($n = 7$ 个模型, 属跨模型不确定性)。(3) **置换检验**: 对逐样本损失差与条件增量使用符号翻转 (sign-flip) 随机化检验, $B = 1000$ 。(4) **多重检验**: BH-FDR 仅在同一个科学问题族内校正 (环境边、环境主效应、环境交互、析因 ANOVA、motif 富集各自成族)。(5) **区组析因方差分析**: 以 R^2 为响应变量, 四个环境因子为二水平因子, 模型、细胞系与划分作为区组因子, 采用基于设计矩阵的 Type-II 边际平方和 F 检验 (含成对交互项), 效应量报告 partial η^2 ; 数据不足时返回不可用而非近似值。所有阈值统一配置 (SNR 2.5/1.8/1.2; FDR 0.001/0.01/0.05; 最小效应量 0.005; 数值发散阈值 10.0; bootstrap $B = 2000$; 置换 $B = 1000$), 完整清单见补充表 7。

2.8 序列模式发现

序列模式发现按“归因 $\rightarrow$ 片段 $\rightarrow$ 聚类 $\rightarrow$ 共识 $\rightarrow$ 富集 $\rightarrow$ 稳定性”执行。首先计算归因特异性: 位置 p 上碱基 b 的得分定义为其归因值减去该位置其它碱基归因均值, 以避免原始幅值普遍偏高; 随后按位置级分位阈值 (0.90) 与局部连续性要求 (≥ 2 个连续位置超过 0.75 分位) 提取窗口 (长度 4–12 nt, 每样本最多 2 个)。seqlet 按 CNN 核配置与方法分别聚类 (与簇共识一致率 ≥ 0.90 则合并, 聚类后再对相似共识 ≥ 0.95 二次合并)。共识以 IUPAC 退化码、人类可读形式与正则形式同时保存。候选模式需满足最小支持度 (seqlet ≥ 30 、样本 ≥ 20)。由于当前批次的归因输出为无符号幅值, 模式方向不取自 attribution 符号, 而由“携带该模式的序列 vs 背景序列”的实测效率对比给出, 并在结果中标注来源。富集分析为可选步骤: 以效率上三分位

序列为前景、全部可用序列为背景，采用 Fisher 精确检验并在 motif 富集族内 BH-FDR 校正；未执行富集时不报告任何 p 值。跨配置一致性通过比较不同 CNN 核与不同细胞系间共识序列的相似性 (≥ 0.80) 评估；当前批次没有 Transformer IG 产物，因此 CNN 与 Transformer 的跨模型模式比较标记为不可用。

2.9 证据整合

平台按覆盖度、方向一致率、统计/归因强度与置信区间给出证据等级：覆盖度不足两个模型、方向冲突或置信区间跨 0 记为 Inconclusive；两个及以上模型支持、方向一致率达标且存在强统计或归因证据记为 Tier 1；其余满足覆盖度的情形为 Tier 2；仅单模型且有强证据时为 Tier 3（模型特异）。

需要强调：** 证据等级反映证据的一致性、覆盖度与稳健程度，而不代表生物学效应强度 **；在增量效应很小的情形下 ($|\Delta R^2| < 0.01$)，高等级仅表示多个模型对该小效应的判断一致，不能解读为“强影响因素”。

2.10 候选优先级与最小扰动方案

在证据整合之后，平台按预先设定的标准从既有结果中筛选用于后续实验验证的候选：(i) 多模型支持；(ii) 效应具有方向；(iii) 至少在一个人细胞系中效应较大；(iv) 统计或稳健性证据非空白；(v) 可设计最小扰动（单碱基替换或短序列破坏）；(vi) 不依赖复杂环境操控。候选及其依据、最小扰动方案与优先级记录于表 6。平台在此环节只做 ** 候选优先级排序 **，不进行序列从头生成，也不声称任何候选已被实验验证。

2.11 软件与可复现性

平台实现为 Python 模块化分析引擎，训练与分析相互独立。所有统计量均由只读结果文件重新计算；分析方案、任务执行状态 (`analysis_status.json`) 与每个任务的产物路径同时落盘；报告层与图形界面只读取这些文件。本文全部数值由 `paper/make_assets.py` 从结果文件重新生成，并逐项记录于补充材料表 9 与项目文档中的事实来源表。

3 结果

本节按“数据与受控实验空间 → 预测信号及其边界 → 环境增量信息 → 多模型序列归因 → 多尺度 CNN → 候选序列模式 → 细胞背景依赖 → 证据整合与候选优先级”的顺序组织。每个小节均给出观察、稳健性检验、解释与限制。

3.1 数据与受控实验空间

问题与方法. 数据与实验设计是否足以支撑后续的解释性分析？我们对四个细胞系的记录进行序列合法性、标签分布与设计完整性检查，并统计受控实验空间。

观察. 过滤后保留 16 749 条 23 nt 序列 (HCT116 4 239、HEK293T 2 333、HeLa 8 101、HL60 2 076)，四个细胞系的平均归一化效率接近 (0.232–0.257，表 1)。设计空间为 7 个模型配置 $\times$ 16 个环境组合 $\times$ 12 个（划分，种子）设定 = 1 344 次运行（图 2 对应的汇总见 §3.2）。碱基组

Platform: prediction → interpretation → evidence → hypothesis




图 1: 平台的科学发现流程。实验测量数据依次经过质量控制、特征配置、受控多模型实验、模型特异性归因、统计与析因分析、序列模式发现、细胞背景比较与跨模型证据整合，最终形成候选因素与可检验假设。各阶段之间以结构化结果文件为接口，分析阶段只读训练产物。

成检查显示，全部记录在第 22、23 位为 G，据此确定 PAM 位于第 21–23 位。结果级检查发现 Linear Regression 在 192 次运行中有 56 次 (29%) R^2 数值发散 ($|R^2| > 10$)；其余模型配置无发散。

稳健性与处理. 平台不删除发散运行，而是在统计阶段将其隔离，并在所有表格中单列发散计数；因此涉及 Linear Regression 的量均以中位数或”排除发散后”的口径报告。

解释与限制. 该异常说明结果级质控是解释性分析的前提。案例的另一项限制是 *all* 划分的 LOCO 分支在本批次退化 (§2)，因此本文不将其作为跨细胞系泛化证据。

表 1: Case-study dataset composition. Normalized editing efficiency per cell line; GC content is the fraction of G/C across all 23-nt targets.

cell_line	n	mean	sd	median	gc
HCT116	4239	0.254	0.172	0.210	0.584
HEK293T	2333	0.238	0.120	0.208	0.556
HeLa	8101	0.257	0.182	0.207	0.585
HL60	2076	0.232	0.114	0.220	0.580
Total	16749	0.250	0.165	0.210	0.580

3.2 预测信号及其边界

问题与方法. 模型是否学到了编辑效率信号？我们在留出测试集上汇总 7 个模型配置的表现（每配置 64 次运行），报告稳健统计量（中位数与四分位距）而非均值。

观察. 在 *single* 划分下，各配置的中位 R^2 为：XGBoost 0.115 (IQR 0.090–0.124)、MLP 0.085 (0.041–0.099)、CNN $k = 7$ 0.080 (0.063–0.101)、Transformer 0.069 (0.047–0.105)、CNN $k = 5$ 0.057 (0.044–0.088)、CNN $k = 3$ 0.035 (0.022–0.063)；Linear Regression 中位 0.087 但 21/64 次运行为发散值（表 2、图 2）。*mixed* 划分下排序一致但整体更高（例如 XGBoost 中位 $R^2 = 0.161$ ），与多种子训练降低单次划分方差一致。

稳健性与解释. 所有模型的中位 R^2 均为正，说明数据中存在可学习的编辑效率信号；但绝对值有限 (0.03–0.16)，属于”弱信号”区间。因此本文 **不** 把预测性能作为平台的主要贡献，也 **不** 据此判断模型发现了更重要的生物学因素；预测性能仅用于确认平台可以进入解释与因素发现阶段，并界定后续结论的强度上限。

3.3 环境增量信息：一个需要如实报告的小效应结果

问题与方法. 表观遗传环境是否在序列信息之外提供额外预测信息？我们以 *sequence-only* 为基线，对 16 个环境组合的全部 lattice 边计算配对 ΔR^2 ，并用逐样本配对 bootstrap、符号翻转置换检验与区组析因方差分析三种互补方式评估。

观察 1 (效应量级很小). 排除数值发散行后，四个因子的跨模型平均主效应为：CTCF -0.0010 (95% CI -0.0105 – -0.0048)、DNase -0.0020 (-0.0045 – -0.0003)、H3K4me3 -0.0059 (-0.0127 – -0.0011)、RRBS -0.0093 (-0.0243 – -0.0010)（表 3、图 3A–B）。方向分布不统一：CTCF 在 7 个模型配置中 6 个为正，而 DNase、H3K4me3、RRBS 分别只有 2、1、1 个为正。

表 2: Held-out test performance. Medians over experiments are reported because the Linear Regression configuration diverged in a subset of experiments (see diverged column); no result was discarded from the raw artifacts.

model	split	n_experiments	R2_median	R2_mean	R2_sd	RMSE_median	MAE_median	Spearman_median	diverged
cnn(3 3)	single	64	0.038	0.038	NA	0.145	0.116	0.209	0
cnn(3 3)	mixed	64	0.059	0.059	NA	0.161	0.126	0.239	0
cnn(5 3)	single	64	0.064	0.064	NA	0.143	0.113	0.261	0
cnn(5 3)	mixed	64	0.134	0.134	NA	0.155	0.117	0.353	0
cnn(7 3)	single	64	0.078	0.078	NA	0.142	0.113	0.277	0
cnn(7 3)	mixed	64	0.145	0.145	NA	0.154	0.115	0.380	0
mlp	single	64	0.072	0.072	NA	0.142	0.113	0.260	0
mlp	mixed	64	0.110	0.110	NA	0.157	0.121	0.329	0
transformer	single	64	0.074	0.074	NA	0.142	0.114	0.275	0
transformer	mixed	64	0.111	0.111	NA	0.157	0.122	0.322	0
xgboost	single	64	0.104	0.104	NA	0.140	0.112	0.305	0
xgboost	mixed	64	0.164	0.164	NA	0.152	0.119	0.387	0
linear	single	64	-18662702800850988.000	-18662702800850988.000	NA	2988385.925	226474.526	0.268	1
linear	mixed	64	-1441841130121658368.000	-1441841130121658368.000	NA	68521538.657	1366881.612	0.273	1




图 2: 留出测试集预测性能（每配置 64 次运行）。(A) *single* 与 *mixed* 划分下各模型配置的 R^2 中位数。(B) *single* 划分下逐次运行的 R^2 分布（散点为单次实验，红线为中位数），可见 Linear Regression 的发散运行。(C) 按 held-out 细胞系分组的行；由于本批次该划分与 *single* 逐位相同（见 §5），此面板不作为跨细胞系泛化证据。

观察 2 (边级不确定性大) . 在 1906 条 lattice 边上, 逐样本配对 bootstrap 的 95% 置信区间只有 166 条 (8.7%) 不跨 0; 按边 $\times$ 种子计为 257/2541 (图 3C)。置换检验在边级同样严格: 2688 次边检验中仅 6 次通过 $FDR < 0.05$; 主效应检验 35/252、交互检验 9/504 通过 $FDR < 0.05$ 。

观察 3 (区组析因方差分析未检出显著主效应) . 以 R^2 为响应、四个环境因子为二水平因子、模型/细胞系/划分为区组的 Type-II 析因方差分析 ($n = 1288$, $df_{den} = 1265$) 给出 $F = 0.60, 2.31, 1.95, 2.18$, 对应 $p = 0.663, 0.056, 0.100, 0.069$; 六个成对交互项 $p \geq 0.26$, partial $\eta^2 \leq 0.002$ (图 3D)。

稳健性与差异来源. 三种方法结论并不一致: 置换检验在”背景间条件增量”这一单位上检验均值, 析因方差分析在”组合均值”这一单位上以模型/细胞系为区组, 边级 bootstrap 则显示绝大多数单条边的增量与 0 无法区分。综合来看, 环境信息在本案例中 ** 没有 ** 获得稳健的增量预测支持。

解释与限制. 这一结果应被理解为平台的 ** 能力体现 **: 在统一框架下, 平台识别出环境增量信息在本数据集与当前编码方式下较弱且不稳定, 而不是预设环境信息必然带来提升。该结论不能被解读为”表观遗传环境与编辑效率无关”: ΔR^2 度量的是在已有序列模型基础上的增量预测价值, 环境信息可能与序列特征冗余, 或受限于二值化编码与细胞系覆盖。




图 3: 环境因素的增量预测贡献与统计证据。(A) 各模型配置对四个环境因子的主效应 ΔR^2 (排除 $|\Delta R^2| > 10$ 的发散行)。(B) 主效应跨模型/上下文的分布。(C) 逐样本配对 bootstrap 中 95% 置信区间不跨 0 的 lattice 边数量 (分母为可检验边数)。(D) 区组析因方差分析的 F 与 p ; 四个主效应均未达到 $p < 0.05$ 。所有效应量级均小于 0.01。

表 3: Environmental factors: cross-model incremental predictive value (mean main-effect ΔR^2 over models after excluding numerically diverged rows, $|\Delta R^2| > 10$), cross-model factor-level bootstrap CI, paired per-sample edge bootstrap (CI excluding zero), permutation-based FDR, blocked factorial ANOVA and cell-line context label.

factor	models_positive	models_negative	cross_model_mean_dR2	ci_low	ci_high	ci_excludes_zero	edges_ci_excl0	permutation_fdr	anova_F	anova_p	cell_line_context	tier
CTCTF	6/7	1/7	-0.0009	-0.0105	0.0048	False	30/474	0.0093	0.6000	0.6627	Context-conflicting	Inconclusive
DNase	2/7	5/7	-0.0020	-0.0045	0.0003	False	48/470	0.0140	2.3053	0.0564	Uncertain	Tier 2: Moderate convergent evidence
H3K4ME3	1/7	6/7	-0.0059	-0.0127	-0.0011	True	38/480	0.0093	1.9498	0.0999	Context-conflicting	Inconclusive
RRBS	1/7	6/7	-0.0093	-0.0243	-0.0010	True	50/482	0.0093	2.1839	0.0687	Uncertain	Tier 1: Strong convergent evidence

3.4 多模型序列归因指向 PAM 邻近候选区域

问题与方法. 模型归因是否指向可重复的序列位置, 且这种指向是否跨模型类一致? 我们比较五类模型的主归因方法 (线性系数、TreeSHAP、MLP-IG、CNN-IG、注意力) 在 23 个位置上的归一化归因分布, 计算两两 Spearman 秩相关与 top-3 位置重叠率, 并按四个序列区域汇总。

观察 1 (区域层级一致). CNN、MLP、Transformer 与 XGBoost 的 **最高** 归因区域均为 PAM 邻近种子区 (17–20, 均值 0.049–0.082); 线性模型把最大权重放在 PAM 位点 (21–23, 0.194) (图 4B)。即四个模型类独立地支持”PAM 邻近区域携带最多被模型利用的序列信息”。

观察 2 (跨模型相关性中等, 峰值位置部分重合). 五模型位置谱的平均两两 Spearman 相关系数为 0.28–0.61, top-3 位置重叠率为 0.30–0.53 (表 8)。第 18 位进入 CNN、MLP、XGBoost 三个模型的 top-3, 并在跨模型平均谱中排序最高; 线性模型的峰值在第 19 位, Transformer 注意力的峰值位于第 1–2 或 19–20 位, 与梯度/树归因不一致。

观察 3 (第 18 位碱基关联具有细胞背景依赖). 第 18 位在四个细胞系中的碱基组成不同。按碱基分组后, C 与 A 的平均效率差在 HCT116 为 +0.090、HeLa 为 +0.092、HL60 为 +0.028, 而在 HEK293T 为 −0.015 (方向反转) (图 4C、图 6B)。CNN 的替换敏感性 (ISM) 在该位置亦呈细胞系差异: HCT116 与 HeLa 中 A/C 的替换效应 (0.037–0.038) 高于 G/T (0.015–0.020), 而 HEK293T 中四种碱基的替换效应接近 (约 0.010)。模型归因同样呈细胞系依赖: 第 18 位归因中 C 的占比在 XGBoost 为 0.64–0.77、MLP 为 0.28–0.63、CNN 为 0.23–0.37, Transformer 恒为 0.25 (注意力不区分碱基通道)。

稳健性与证据链. 第 18 位的证据来自三类相互独立的信息: 位置级模型归因 (跨模型区域一致、3/5 模型 top-3)、实测效率的碱基分组对比 (细胞系依赖) 与 CNN 替换敏感性 (ISM)。需要强调: 位置效应与碱基效应在本数据中 **不能完全分离**——第 18 位的高归因既可能反映该位置的序列语法, 也可能来自该位置特定核苷酸的非均匀效应; 因此本文使用”候选序列相关模式 (candidate sequence-associated pattern)”的表述。

解释与限制. 该结果提示一个可检验假设: 第 18 位 (尤其 C/A 差异) 与编辑效率的关联可能具有细胞背景依赖性。限制包括: HEK293T 的第 18 位碱基分布更均匀且含 24.7% T, 其方向反转可能部分来自队列组成差异; attribution 幅值不构成统计显著性, 方向性结论依据的是实测效率对比。




图 4: 跨模型序列归因与第 18 位分析。 (A) 五类模型在 23 个位置上的归一化归因谱 (阴影为 PAM 邻近种子区 17–20 与 PAM 21–23)。 (B) 四个序列区域的平均归一化归因 (按模型)。 (C) 第 18 位碱基与实测归一化效率的关系 (按细胞系)。 (D) 第 18 位归因中 C 的占比 (按模型与细胞系)。归因幅值仅表示模型依赖强度, 不构成统计显著性证据; 不同模型的 importance 在模型内归一化, 绝对值不可跨模型类直接比较。

3.5 多尺度 CNN: 更宽的局部序列上下文改善预测

问题与方法. 序列卷积核大小 (感受野) 是否影响预测与解释? 我们在 192 组严格配对的实验 (同一划分、细胞系、环境组合与种子, 仅卷积核不同) 中比较 R^2 , 并比较三个核配置的归

因谱与候选模式长度。

观察 1 (性能提升稳定) . 配对差分为: $k = 5$ 相对 $k = 3$ 提高 0.0423 (95% bootstrap CI 0.0375–0.0470), $k = 7$ 相对 $k = 3$ 提高 0.0557 (0.0514–0.0600), $k = 7$ 相对 $k = 5$ 提高 0.0134 (0.0107–0.0162); 三组比较分别在 88.5%、95.8% 与 77.1% 的配对实验中为正 (表 4、图 5A)。分层结果一致: 按细胞系 (HCT116 +0.037/+0.057、HeLa +0.038/+0.047、HL60 +0.017/+0.040、HEK293T +0.011/+0.017) 与按划分 (*single* +0.026/+0.040、*mixed* +0.075/+0.086) 均单调。

观察 2 (解释随之改变, 方向一致) . 归因谱的核间相关为: $k = 3$ 与 $k = 5$ 之间 Spearman $\rho = 0.82$, 而 $k = 7$ 与二者仅 0.21–0.23 (图 5B)。区域平均归因显示, 感受野增大使归因更集中于 PAM 邻近区域: PAM 邻近种子区由 0.0484 ($k = 3$) 升至 0.0557 ($k = 7$), PAM 区由 0.0341 升至 0.0473, 而 PAM 远端区由 0.0443 降至 0.0388。

观察 3 (模式长度不随核大小改变) . 三个核配置得到的候选模式长度中位数均为 4 nt (范围 4–11), 最高支持度模式均为同一类 PAM 邻近模式 (图 5D)。

解释与限制. 上述结果支持一个谨慎的模型层面解释: 在本案例数据中, 更宽的局部感受野可能更好地捕获 PAM 邻近区域的上下文依赖关系, 而不是仅仅改变已识别的重要区域。该结论限于预测与归因层面, 不能推断“更宽的序列上下文具有生物学因果必要性”。同时, $k = 7$ 的归因谱与 $k = 3/5$ 差异较大, 说明归因结果对模型超参数敏感——这也正是平台保留多配置交叉验证的原因。最关键的方法学结论是: ** 卷积核大小是模型感受野参数, 不能等同于候选模式长度 **。




图 5: CNN 感受野 (多尺度局部序列上下文) 分析。(A) 192 组配对实验的 ΔR^2 (均值与 95% bootstrap CI), 标注配对中为正的比率。(B) 三个核配置的位置归因谱。(C) 区域平均归因随核大小的变化。(D) 三配置提取的候选模式长度分布 (中位数均为 4 nt, 说明核大小不等于模式长度)。

表 4: CNN receptive-field (kernel size) ablation. Paired differences of held-out R^2 over 192 matched experiment pairs (same split, cell line, environment and seed); CI is a percentile bootstrap over pairs.

comparison	n_pairs	mean_dR2	ci_low	ci_high	pct_positive	excludes_zero
k5 - k3	192	0.0423	0.0375	0.0470	0.8854	True
k7 - k3	192	0.0557	0.0514	0.0600	0.9583	True
k7 - k5	192	0.0134	0.0107	0.0162	0.7708	True

3.6 候选序列模式及其统计支持

问题与方法. 归因能否进一步形成具有支持度、方向与统计检验的候选序列模式? 我们按 §2 流程从 CNN IG/ISM 归因中提取 seqlet 并聚类 (共 172 098 条 seqlet 实例 (24 个模型 × 环境 × 细胞系上下文)), 随后进行共识构建、支持度筛选与可选的富集检验。

观察. 最终得到 596 个候选模式 (50 个 Strong、340 个 Moderate、206 个 Model-specific, 标签反映跨核与跨细胞系复现性), 长度以 4nt 为主 (532/596), 支持度中位数 194 个 seqlet。位置分布高度集中: 382/596 的起始位置为第 20 位, 其余集中在第 16–19 位, 即绝大多数候选模式覆盖 PAM 邻近区域。富集检验 (前景为效率上三分位序列, 背景为全部可用序列) 共 596 次, 其中 **64 个通过 BH-FDR < 0.05**; 通过富集的模式中, 跨上下文复现最好的是 GAGG (899 个 seqlet, 效应 +0.012, OR 1.11, FDR 0.030) 与 GGGG (435 个 seqlet, 效应 +0.060, OR 1.38, FDR 7×10^{-6}), 二者目前均仅在 HeLa 中达到富集 (cell-line support = 1)。支持度最高的模式 CTGG (1 273 个 seqlet, 方向为负, Δ 效率 -0.046) ** 未通过富集校正 ** (FDR = 1.0), 因此仅作为高支持度候选而非富集模式报告。

稳健性与限制. 方向的判定来源于携带模式序列与背景序列的实测效率对比, 而非 attribution 符号 (当前批次归因为无符号幅值)。三项限制尤须强调: 其一, 多数候选模式与 PAM/种子区重叠, 其统计支持部分来自该区域的整体重要性, 未必构成独立的模式语法; 其二, 跨模型比较目前仅限 CNN 三个核配置, 缺少 Transformer IG 产物, 因此不能宣称”跨模型收敛的生物学 motif”; 其三, 富集结果目前只在单一细胞系中达到显著, 属于 context-dependent 候选。本文因此统一使用”候选序列模式 (candidate sequence pattern)”的表述, 不使用”功能性/调控性 motif”。

表 5: Representative motif candidates discovered from CNN attribution. Support counts are seqlet instances; enrichment and FDR come from the Fisher exact test against the all-eligible-sequence background (BH-FDR within the motif_enrichment family). Effect direction is the carrier-vs-background measured-efficiency contrast, not a causal effect.

motif_id	human_pattern	iupac	regex	length	support_count	sample_support	celline_support	effect_direction	mean_effect	enrichment	FDR	evidence_strength
motif_cnn53_hela_all_cnn_ig_001	CTGG	CTGG	CTGG	4	1273	1273	1	-	-0.046	0.870	1.000	Moderate motif evidence
motif_cnn53_hela_all_cnn_ig_011	CAGG	CAGG	CAGG	4	1083	1083	1	-	-0.030	0.934	1.000	Moderate motif evidence
motif_cnn73_hela_all_cnn_ig_023	GAGG	GAGG	GAGG	4	899	899	1	+	0.012	1.081	0.030	Strong motif evidence
motif_cnn53_hela_all_cnn_ig_027	AAGG	AAGG	AAGG	4	890	890	1	-	-0.010	0.983	1.000	Moderate motif evidence
motif_cnn53_hela_all_cnn_ig_041	ATGG	ATGG	ATGG	4	789	789	1	+	0.011	1.050	0.259	Moderate motif evidence
motif_cnn73_hela_all_cnn_ig_057	CTGG	GTGG	GTGG	4	740	740	1	+	0.017	1.030	0.468	Moderate motif evidence
motif_cnn73_hela_all_cnn_ig_075	AGGG	AGGG	AGGG	4	610	610	1	+	0.028	1.068	0.212	Moderate motif evidence
motif_cnn73_hela_all_cnn_ig_131	GGGG	GGGG	GGGG	4	435	435	1	+	0.060	1.353	0.000	Strong motif evidence
motif_cnn33_hela_all_cnn_ism_143	AGAGG	AGAGG	AGAGG	5	383	383	1	+	0.012	1.047	0.468	Model-specific motif
motif_cnn53_hela_all_cnn_ig_145	CCGG	CCGG	CCGG	4	377	377	1	+	0.008	1.055	0.308	Moderate motif evidence

3.7 细胞背景依赖效应

问题与方法. 同一因素在不同细胞背景下是否保持方向与幅度? 我们在稳定主效应上按细胞系汇总每个环境因子, 并依据方向一致率、幅度异质性与置信区间给出 context 标签。

观察. 环境效应存在明显的细胞系依赖 (图 6A): CTCF 的 ΔR^2 在 HCT116 (+0.0048)、HEK293T (+0.0077) 与 HeLa (+0.0009) 为正, 而在 HL60 为负 (-0.0038); H3K4me3 在 HEK293T 为 -0.0168, 在 HL60 为 +0.0065; RRBS 在 HeLa 近似为 0 (+0.0004) 而在其余细胞系为负。按模型与划分统计的 context 标签中, CTCF 有 12 个上下文被判为 Context-conflicting、2 个为 Context-consistent、7 个为 Uncertain; DNase 与 RRBS 中则出现 Context-dependent

(各 8 与 6 个) (图 6C)。序列层面的异质性同样存在：第 18 位 C 的效应在 HCT116/HeLa 约为 +0.09，在 HL60 为 +0.028，在 HEK293T 为 -0.015。

解释与限制。 上述模式与”环境/序列效应具有细胞背景依赖性”这一假设一致，但本文不将其解释为机制差异：不同细胞系的样本量 (2076–8101)、标签分布与序列组成不同，也可能产生类似的方向变化；同时 LOCO 分支在本批次退化，缺少独立的跨细胞系验证。因此这里的结论限于”context-dependent association” (上下文依赖关联)。




图 6: 细胞系背景下的效应异质性。(A) 各环境因子的平均 ΔR^2 按细胞系展开 (排除发散行)。(B) 第 18 位碱基效应在四个细胞系中的方向与幅度 (HCT116/HeLa 为正且较大, HL60 较小, HEK293T 反向)。(C) 按模型与划分统计的 cell-line context 标签分布: 冲突与不确定占多数, 说明平台不把跨细胞系差异简单平均掉。

表 6: Candidate hypotheses prioritised from the existing results for minimal follow-up perturbation experiments. No wet-lab validation was performed in this study; effects are model-derived or measured associations, not causal estimates.

candidate	type	multi_mod
C1: position-18 base substitution	single-nucleotide	3/5 models in top-3 positions; PAM-proximal region high
C2: GAGG candidate pattern (enriched)	motif disruption	shared by CNN k=3/5/7 contexts (5
C3: GGGG candidate pattern (most enriched)	motif disruption	CNN contexts (
reference: CTGG (highest support, not enriched)	motif disruption	highest seqlet sup

3.8 证据整合与候选优先级

问题与方法。 如何把预测增量、模型归因、统计稳健性与一致性组织为可比较的证据，并据此排定后续实验的候选？平台按覆盖度、方向一致率、统计/归因强度与置信区间给出证据等级 (定义见 §2)，并按 §2 的六条标准筛选候选。

观察 1 (环境因素的证据分级, 须与效应量级分开解读)。 四个环境因子中, RRBS 与 DNase 分别达到 Tier 1 与 Tier 2 (覆盖 7 个模型、方向一致率 0.86/0.71、跨模型 CI 不跨 0、方向为负), CTCF 与 H3K4me3 因置信区间跨 0 或方向冲突被判为 Inconclusive (表 3、图 7)。** 证据等级反映一致性与稳健性, 而非生物学效应强度 **：这些因素的效应量级均小于 0.01，因此 Tier 等级不能解读为”强影响因素”。

观察 2 (跨模型既有一致也有分歧)。 平台同时输出两类信息：一致的部分是 PAM 邻近区域的最高归因 (4/5 模型类) 与 CNN 核间的一致趋势；分歧的部分包括线性模型峰值位置偏移、

Transformer 注意力与梯度/树归因不一致、以及 MLP 的 ΔR^2 -importance 关系与其他模型方向相反。这些分歧被保留为 model-dependent evidence，而不被平均掉。

观察 3 (候选优先级)。按 §2 的标准筛选得到两个高/中优先级候选与一个参考项 (表 6): C1 为 ** 第 18 位碱基替换 ** (多模型 top-3 支持、PAM 邻近区域最高归因、细胞系依赖的实测效率差 +0.090/+0.092/+0.028/-0.015、ISM 支持, 最小扰动为单碱基替换); C2/C3 为 **PAM 邻近候选模式 GAGG / GGGG 的序列破坏 ** (富集 FDR 0.030 与 < 0.001 , 最小扰动为 4nt 核心替换); CTGG 因未通过富集校正列为低优先级参考。

解释与限制。 证据整合的作用是区分稳定候选与模型特异性现象, 并输出可检验假设。以本案例为例, 序列层面 (PAM 邻近区域、第 18 位) 具备多模型覆盖、跨细胞系差异与独立于归因的实测效率关联, 属于较强候选; 环境因素尽管在部分统计视角下达到一致, 仍因效应量级极小、区间宽与模型间方向不一致而只能记为弱或不确定证据。所有候选均为 ** 待验证假设 **, 本文不包含湿实验验证。




图 7: 证据整合: 环境因子的跨模型平均主效应与 95% bootstrap 置信区间, 并标注证据等级与置换 FDR。证据等级反映一致性与稳健程度, 不代表效应量级; 四个因子的 $|\Delta R^2|$ 均小于 0.01。Importance- ΔR^2 辅助视图见补充图 8。

4 讨论

4.1 平台实际发现了什么

在本案例中, 平台得到的不是“更高的预测精度”, 而是一组经过分层筛选的因素证据: 序列层面指向 PAM 邻近区域 (尤其第 18 位) 作为候选序列相关因素; 模型层面显示更宽的局部感受野带来稳定但有限的预测改善, 并改变归因分布; 环境层面则得到一个小效应且不稳健的结果; 细胞背景层面显示同一因素的效应方向与幅度依赖细胞系。这些结论共同构成一条从“预测”到“候选因素”的证据链, 而其中最重要的能力是: 平台在统一框架内 ** 同时 ** 输出了稳定证据、模型特异性现象与不确定结果。

4.2 为什么多模型证据比单模型更可信

五类模型的归纳偏置不同：线性模型给出方向明确的主效应，树模型刻画非线性与交互，MLP 表示一般非线性组合，CNN 建模局部序列模式，Transformer 建模跨位置关系。本案例中，PAM 邻近区域的最高归因在四个模型类中重复出现，而线性模型的峰值位置与注意力谱的峰值位置不同。若只报告单一模型，这种差异不可见，读者会把某一种归因方式误当作事实。平台的做法是：把跨模型重复出现的结构作为较强候选，把仅在某类模型出现的现象标记为 model-dependent evidence。这不仅提高了结论的可信度，也明确了结论的适用范围。

4.3 环境效应为什么弱，以及这一结果的价值

表观遗传环境在本案例中提供的增量预测价值很小 ($|\Delta R^2| < 0.01$)，边级置信区间多数跨 0，区组析因方差分析也未检出显著主效应 ($p = 0.056-0.663$)。可能的解释有三：其一，四条轨道以逐位点二值形式编码，信息容量有限；其二，环境信息与序列特征存在冗余，sequence-only 模型已能捕获相关信息；其三，不同模型类对环境通道的利用方式不同，跨模型平均会削弱单一模型的效应。三种口径（置换检验、区组 ANOVA、边级 bootstrap）结论不一致本身也说明该效应对依赖结构假设敏感。**** 这一结果的价值在于平台没有把它包装成阳性结论 ****：科学发现平台的可信度取决于它能否识别并如实报告“信息增量不足”的情形。

4.4 第 18 位结果意味着什么

第 18 位的证据由三部分构成：多个模型的位置归因（3/5 模型 top-3，跨模型平均谱第 1 位）、细胞系依赖的实测效率对比（C 相对 A：HCT116 +0.090、HeLa +0.092、HL60 +0.028、HEK293T -0.015）以及 CNN 替换敏感性（HCT116/HeLa 中 A/C 的替换效应明显高于 G/T，HEK293T 中四种碱基接近）。这提示一个候选序列相关模式，但需要严格区分两类解释：**** 位置效应 ****（该位置本身的序列语法重要性）与 **** 碱基特异性效应 ****（该位置上特定核苷酸的效应）。本数据无法把二者完全分离，且 HEK293T 的反向可能部分来自其碱基组成差异（该细胞系第 18 位含 24.7% T）。因此本文的结论是“具有上下文依赖性的候选序列关联”，而非“第 18 位 C 是普适决定因素”。

4.5 感受野消融告诉我们什么

配对实验显示更宽的卷积核稳定改善预测 ($k = 7 - k = 3$: +0.056, 95% CI 0.051-0.060; $k = 5 - k = 3$: +0.042; $k = 7 - k = 5$: +0.013)，并使归因更集中于 PAM 邻近区域。这支持“更宽的局部序列上下文包含额外预测信息”的模型层面解释。但候选模式长度并未随核大小增加（三个配置的模式长度中位数均为 4 nt），说明卷积核描述的是模型感受野，而不是生物学模式长度。这一区分具有普遍方法学意义：在把深度模型的滤波器或窗口长度解释为生物学单元之前，必须用独立于模型结构的证据加以检验。

4.6 为什么细胞背景必须被建模而不是被平均

同一环境因子在不同细胞系中方向与幅度不同（CTCF 在 HL60 反向；H3K4me3 在 HEK293T 与 HL60 方向相反），序列特征同样如此（第 18 位 C 的效应在 HEK293T 反转）。若把细胞系简

单合并，会得到接近零的平均效应，从而掩盖上下文依赖结构。平台因此输出 context 标签（一致/依赖/冲突/不确定）而非单一平均值。同时必须克制：细胞系差异也可能来自数据量、标签分布或序列组成差异，因此本文只作“上下文依赖关联”的表述，不作机制断言。

4.7 哪些结论仍未经验证

本文的所有结果都属于计算证据：预测性能来自留出测试集，归因来自模型内部，统计检验来自对既有结果的重新分析，候选模式来自归因聚合与富集检验。**** 尚未完成 ****的工作包括：直接序列扰动实验、编辑效率的湿实验验证、独立生物学验证，以及在本批次中退化的真正 LOCO 重训。因此平台输出的是可检验假设，而不是已确认的生物学机制。

4.8 如何由此设计后续实验

候选优先级（表 6）给出了两条最小扰动路径：C1 以单碱基替换检验第 18 位的 C/A 差异（同一 sgRNA 其余序列保持不变，可同时在不同细胞系中测试以检验上下文依赖）；C2/C3 通过破坏 PAM 邻近的 4 nt 候选核心检验模式层面的假设。两条路径均不依赖复杂的环境操控，便于在常规编辑效率测定体系中实施。相关的实验设计与预期读出方式见 §7。

4.9 面向赛道定位的能力对照

从“AI 基因编辑与核酸工具设计”的角度，本工作的重点可以概括为三点：其一，**** 方法层面 ****使用异构模型族与多源特征（序列 + 表观通道 + 细胞背景），并把每个分析单元的可解释输出统一到可追溯的结果文件；其二，**** 发现层面 ****给出可排序的候选因素与候选序列模式，而不是只给出预测分数；其三，**** 验证层面 ****明确区分已完成的计算验证与尚未开展的湿实验验证，并给出可执行的最小扰动方案。平台当前实现的是候选优先级排序（candidate prioritization / ranking），不是序列从头生成；这一点在方法 (§2) 与候选章节中均如实说明。

5 局限性

已完成与未完成. 本研究完成了大规模计算验证：1344 次受控多模型实验、环境因素析因与统计推断、跨模型序列归因、多尺度感受野分析、候选模式挖掘、细胞背景比较与证据整合。本研究 **** 未完成 ****：直接序列扰动实验、编辑效率湿实验验证、独立生物学验证，以及在本批次中退化的真正留一细胞系（LOCO）重训。因此平台输出的是可检验假设，而非已验证机制。

案例数据与设计. 本文以 DeepCRISPR 数据作为案例研究，而非平台适用性的普遍证明。本批次中 *all*（留一细胞系）划分与 *single* 划分的 R^2 逐位相同（ $\max |R_{\text{all}}^2 - R_{\text{single}}^2| = 0$ ），说明该分支在网格中退化：本文因此不把按 held-out 细胞系分组的数字解释为跨细胞系泛化证据；真正的 LOCO 验证需要重新执行训练配置（本文未进行，以避免修改训练体系）。

数值稳定性. Linear Regression 在 192 次运行中有 56 次发散。平台通过隔离（ $|R^2| > 10$ ）而非删除处理，并在所有统计中以“排除发散后”的口径报告；该处理仍会影响线性模型在环境效应与归因比较中的权重，相关结论以中位数与非参数统计为主。

环境编码与效应量级. 表观遗传信息以逐位点二值形式进入模型，可能丢失连续信号与更高阶组合信息；环境中性结论限于当前编码方式，不能外推为生物学无关。此外，四个环境因子的

效应量级均小于 0.01，即使证据等级较高 (Tier 1/2) 也不表示效应强度大。

归因方法的边界. 归因幅值不构成统计显著性；注意力权重不区分方向，本文仅将其作为支持性信息，且在本案中其峰值位置与梯度/树归因不一致，故未用于候选模式提取。CNN 归因对卷积核大小敏感 ($k = 7$ 与 $k = 3/5$ 的位置谱相关性仅 0.21–0.23)，单一配置的归因不应作为独立结论。不同模型的 importance 在模型内归一化，其绝对量级不可跨模型类直接比较。

候选模式与富集. 候选模式以 4nt 为主且高度集中于 PAM 邻近区域，其统计支持部分来自该区域的整体重要性；通过富集的模式目前仅在单一细胞系 (HeLa) 中达到显著，属上下文依赖候选；跨模型比较仅限 CNN 三个核配置 (缺少 Transformer IG 产物)，seed 级支持无法计算。因此“跨模型收敛的生物学 motif”这一表述在本数据上不成立。

统计口径. 边级 bootstrap 基于逐样本重采样，与区组析因方差分析在依赖结构假设上不同，两类结论的差异已在 §3.3 说明；因子级置信区间由模型级均值 bootstrap 得到 ($n = 7$ 个模型)，属于跨模型不确定性而非样本级不确定性。

细胞背景与机制. 细胞系间的效应差异可部分由样本量、标签分布与序列组成差异解释；本文不对其作机制性断言。

工具范围. 当前模型针对 SpCas9 与 NGG PAM；NAG/NGA 等非经典 PAM、其他 Cas 变体与碱基编辑系统均未纳入。平台当前的“设计”能力为候选优先级排序，不包含序列从头生成或约束满足式设计。

6 结论

本文提出并验证了一个面向基因编辑影响因素发现的科学发现平台，并以 DeepCRISPR 公开数据作为案例研究。平台的定位不是构造单一最优预测器，也不是证明表观遗传环境必然提升预测，而是把预测、模型归因、统计推断、环境增量分析、序列模式发现、细胞背景比较与证据整合组织为统一且可追溯的流程。

案例研究的主要结论是：(i) 五类模型均能学到但仅能较弱地预测编辑效率 (中位 R^2 0.035–0.115)，预测性能因此只作为进入解释阶段的准入条件；(ii) 四个模型类独立地把 PAM 邻近种子区 (17–20) 识别为最高归因区域，第 18 位在跨模型平均谱中排序最高，其 C/A 效率差在 HCT116 与 HeLa 中约为 +0.09、在 HL60 中减小、在 HEK293T 中反向，构成一个具有上下文依赖性的候选序列关联；(iii) 更宽的 CNN 感受野稳定改善预测 ($k = 7 - k = 3$: +0.056) 并使归因向 PAM 邻近区域集中，而候选模式长度不随核大小改变，说明感受野不等于模式长度；(iv) 环境因素提供的增量预测信息很小且不稳健 ($|\Delta R^2| < 0.01$ ，多数边级置信区间跨 0，区组析因方差分析未检出显著主效应)；(v) 平台据此给出两个可执行的最小扰动候选 (第 18 位碱基替换、PAM 邻近候选模式核心破坏)，供后续实验验证。

综上，平台的科学性不来自“所有分析都得到阳性结果”，而来自能够在统一、可追溯的框架中区分稳定证据、模型特异性现象、上下文依赖现象与不确定结果，并把它们转换为可检验的生物学假设。后续工作将围绕两条主线展开：一是在独立编辑数据集上检验流程的可迁移性；二是对本文提出的候选假设开展最小扰动实验验证。

7 未来实验验证

本文不包含任何湿实验数据；本节仅说明如何用最小实验设计检验平台输出的候选假设。

方向一：第 18 位碱基替换（候选 C1）。最小设计为：选择若干携带目标位点的 sgRNA，仅替换第 18 位碱基（C↔A），保持其余 22 nt 完全不变，在同一实验体系中测定编辑效率。该设计直接检验“模型优先排序的核苷酸差异是否伴随编辑效率变化”，并可通过在多于一个细胞系中重复，检验平台提示的上下文依赖性（HCT116/HeLa 与 HEK293T 的方向差异）。读出指标建议使用与本文数据一致的归一化编辑效率（indel 比例或报告基因活性），并预先设定样本量与重复次数。

方向二：PAM 邻近候选模式破坏（候选 C2/C3）。最小设计为：在包含 GAGG/GGGG 核心的 sgRNA 中替换该 4 nt 核心（保持 GC 含量与长度不变以控制混杂），比较携带与不携带核心的序列的实测效率。由于该候选目前仅在 HeLa 中达到富集，实验应优先在 HeLa 中进行，并在其他细胞系中作为探索性重复。

方向三：独立数据集与真正 LOCO 验证。本批次的留一细胞系分支退化，因此需要重新执行训练配置以完成真正的 LOCO 评估；此外，应在独立编辑数据集（不同细胞类型或不同编辑系统）上检验平台流程的可迁移性，包括候选模式与位置效应的可重复性。

预期输出与判定标准。上述实验的预期输出为“候选假设被支持/不被支持”的二值判定与效应量估计；判定应基于预先登记的统计方案（分层比较与多重检验校正），并使用与本文一致的指标口径。无论结果方向如何，实验都将用于评估平台在“AI 候选优先级 → 实验验证”闭环中的实用价值。

数据与代码可用性

案例数据来自公开的 DeepCRISPR 数据集 [Chuai et al., 2018]。本文所有定量结论均由平台输出结果文件重新生成，结果目录结构、分析方案 (AnalysisPlan)、任务执行状态与每个任务的产物路径一并保存，可逐项追溯 (附录 A.1)。图表生成脚本为 `paper/make_assets.py`，论文事实来源表见 `docs/paper_claim_provenance.md`，质量检查清单见 `docs/paper_quality_check.md`。训练与分析代码、配置文件与结果 artifact 的组织方式见项目仓库说明。

作者贡献

(待补)

利益冲突声明

作者声明不存在利益冲突。

参考文献

- Martin Jinek, Krzysztof Chylinski, Ines Fonfara, Michael Hauer, Jennifer A. Doudna, and Emmanuelle Charpentier. A programmable dual-RNA-guided DNA endonuclease in adaptive bacterial immunity. *Science*, 337(6096):816–821, 2012. doi: 10.1126/science.1225829.
- Le Cong, F. Ann Ran, David Cox, Shuailiang Lin, Robert Barretto, Naomi Habib, Patrick D. Hsu, Xuebing Wu, Wenyan Jiang, Luciano A. Marraffini, and Feng Zhang. Multiplex genome engineering using CRISPR/Cas systems. *Science*, 339(6121):819–823, 2013. doi: 10.1126/science.1231143.
- John G. Doench, Ella Hartenian, Daniel B. Graham, Zuzana Tothova, Mudra Hegde, Ian Smith, Meagan Sullender, Benjamin L. Ebert, Ramnik J. Xavier, and David E. Root. Rational design of highly active sgRNAs for CRISPR-Cas9-mediated gene inactivation. *Nature Biotechnology*, 32(12):1262–1267, 2014. doi: 10.1038/nbt.3026.
- Miguel A. Moreno-Mateos, Charles E. Vejnár, Jean-Denis Beaudoin, Juan P. Fernandez, Emily K. Mis, Mustafa K. Khokha, and Antonio J. Giraldez. CRISPRscan: designing highly efficient sgRNAs for CRISPR-Cas9 targeting in vivo. *Nature Methods*, 12(10):982–988, 2015. doi: 10.1038/nmeth.3543.
- John G. Doench, Nicolo Fusi, Meagan Sullender, Mudra Hegde, Emma W. Vaimberg, Katherine F. Donovan, Ian Smith, Zuzana Tothova, Craig Wilen, Robert Orchard, Herbert W. Virgin, Jennifer Listgarten, and David E. Root. Optimized sgRNA design to maximize activity and minimize off-target effects of CRISPR-Cas9. *Nature Biotechnology*, 34(2):184–191, 2016. doi: 10.1038/nbt.3437.
- Babak Alipanahi, Andrew DeLong, Matthew T. Weirauch, and Brendan J. Frey. Predicting the sequence specificities of DNA- and RNA-binding proteins by deep learning. *Nature Biotechnology*, 33(8):831–838, 2015. doi: 10.1038/nbt.3300.
- David R. Kelley, Jasper Snoek, and John L. Rinn. Basset: learning the regulatory code of the accessible genome with deep convolutional neural networks. *Genome Research*, 26(7):990–999, 2016. doi: 10.1101/gr.200535.115.
- Guohui Chuai, Hanhui Ma, Jifang Yan, Ming Chen, Nanfang Hong, Dongyu Xue, Chi Zhou, Chenyu Zhu, Ke Chen, Bin Duan, Fei Gu, Shuang Qu, Deshuang Huang, Jia Wei, and Qi Liu. DeepCRISPR: optimized CRISPR guide RNA design by deep learning. *Genome Biology*, 19(1):80, 2018. doi: 10.1186/s13059-018-1459-4.
- Tianqi Chen and Carlos Guestrin. XGBoost: a scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, pages 785–794, 2016. doi: 10.1145/2939672.2939785.

- Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pages 4765–4774, 2017.
- Mukund Sundararajan, Ankur Taly, and Qiqi Yan. Axiomatic attribution for deep networks. In *Proceedings of the 34th International Conference on Machine Learning (ICML 2017)*, volume 70 of *Proceedings of Machine Learning Research*, pages 3319–3328, 2017.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pages 5998–6008, 2017.

A 补充信息

S1 分析阈值汇总

表 7: Analysis thresholds used in this study; all values are read from the central analysis configuration file rather than hard-coded in analysis code.

item	value
SNR thresholds (strong/moderate/weak)	2.5/1.8/1.2
min effect size (attribution)	0.005
FDR thresholds (strong/moderate/weak)	0.001/0.01/0.05
unstable effect threshold	10.0
bootstrap iterations / seed / alpha	2000/2024/0.05
permutation iterations	1000
ANOVA min obs / min residual df	32/5
motif length range / similarity / merge	4-12/0.9/0.95
seqlet quantiles (position/continuity)	0.9/0.75
min support (seqlet/sample), min cell lines	30/20/2
motif enrichment foreground quantile / FDR	0.67/0.05
evidence tier min coverage / concordance	2/0.8

S1b Importance- ΔR^2 辅助视图

S2 跨模型位置归因一致性

表 8: Cross-model consistency of position-wise attribution (single split, sequence/all contexts). Peak positions are the argmax of each model's normalized attribution profile; Spearman is the mean pairwise rank correlation over 23 positions; top-3 overlap is the mean Jaccard-style overlap of each model's three highest positions.

cell_line	context	n_positions	peak_linear	peak_xgboost	peak_mlp	peak_cnn	peak_transformer	mean_pairwise_spearman	mean_top3_overlap
hct116	all	23	19	18	18	18	1	0.327	0.467
hct116	sequence	23	18	18	18	21	1	0.432	0.467
hek293t	all	23	22	20	20	17	19	0.409	0.367
hek293t	sequence	23	22	20	20	18	20	0.277	0.300
hela	all	23	18	18	18	18	2	0.611	0.367
hela	sequence	23	19	18	18	20	19	0.406	0.433
hl60	all	23	23	20	20	20	1	0.318	0.533
hl60	sequence	23	22	20	20	20	19	0.367	0.433

S3 完整预测性能

全部 7 个模型配置在 *single* 与 *mixed* 划分下的留出集指标（中位数、均值、标准差与发散计数）见 `paper/tables/tab2_prediction.tex`；按 held-out 细胞系分组的 28 行结果保存在 `tables/loco_performance.csv`，其中每一行对应的原始实验可在 `tables/experiment_table.csv` 中按 (model,split_type,cell_line,environment,random_seed) 追回。需要再次强调，本批次中 *all* 划分与 *single* 划分逐位相同，因此该表不构成跨细胞系泛化证据。




图 8: 辅助视图: 环境因子的增量预测价值 (ΔR^2) 与模型内归一化 importance 的关系。该图 **不** 是显著性图: $\Delta R^2 \neq \text{importance}$, $\text{importance} \neq \text{显著性}$; 各模型的 importance 在其模型/分析组内归一化, 绝对量级不可跨模型类直接比较。

S4 环境因素的完整统计结果

完整结果包含: (i) 1906 条 lattice edge 的配对 ΔR^2 及其逐样本 bootstrap 置信区间 (tables/bootstrap_results.csv, 7770 行含 $\Delta \text{MAE}/\Delta \text{RMSE}$); (ii) 3444 条置换检验记录, 含每行的零假设、备择假设、观测效应、 p 值与所属 FDR 族 (tables/permutation_results.csv); (iii) 94 项析因方差分析结果, 含 F 、自由度、 p 、partial η^2 与效应的 bootstrap 置信区间 (tables/anova_results.csv); Factorial Environment DAG 的节点与边表 (tables/environment_nodes.csv, environment_edges.csv), 其中每条边标注是否 metric inconsistency、是否有可用 CI。

S5 候选序列模式

596 个候选模式的支持度、IUPAC、人类可读形式、正则形式、位置分布、方向与证据等级见 tables/motif_candidates.csv; 545060 条 seqlet 实例见 tables/motif_instances.csv; 富集检验结果见 tables/motif_enrichment.csv; 跨核配置与跨细胞系一致性见 tables/motif_consistency.csv; motif 级证据行见 tables/motif_evidence.csv。表 5 给出支持度最高的 10 个代表模式; 表 6 给出用于后续实验验证的候选假设与其最小扰动方案。

S6 结果文件与交互式报告

平台同时输出可供交互探索的科学发现报告 (Interactive Scientific Discovery Report), 包含数据质量、预测、环境、序列与模式、细胞系、证据整合、假设与溯源等章节, 支持表格筛选、证据卡、图形查看与 artifact 追溯。报告层只读取结果文件, 不重新计算任何统计量, 从而保证论文数值与报告数值同源。

A.1 论文事实来源映射

本文每一处定量结论均可在表 9 中追溯到具体结果文件与图表。生成脚本为 `paper/make_assets.py`，完整映射表另见 `docs/paper_claim_provenance.md`。

表 9: 论文结论与结果文件映射（节选；完整版见 `docs/paper_claim_provenance.md`）。

结论	结果文件 / 字段	图表
数据规模与组成	<code>data/proceeded_data/*_metadata.csv</code>	表 1
预测性能（中位数/IQR/发散数）	<code>tables/experiment_table.csv</code> (R2)	表 2、图 2
环境 ΔR^2 与跨模型一致性	<code>tables/environment_main_effects.csv</code>	表 3、图 3
逐样本配对 bootstrap CI	<code>tables/bootstrap_results.csv</code> 、 <code>environment_bootstrap.csv</code>	图 3C
置换检验与 BH-FDR	<code>tables/permutation_results.csv</code>	表 3
析因方差分析	<code>tables/anova_results.csv</code>	图 3D
位置归因与区域划分	<code>tables/attribution_summary.csv</code>	图 4A–B
第 18 位碱基效应	<code>docs/paper_analysis/position18_efficacy_by_base.csv</code>	图 4C
CNN 核消融配对差	<code>docs/paper_analysis/cnn_kernel_paired.csv</code>	表 4、图 5A
候选模式与富集	<code>tables/motif_candidates.csv</code> 、 <code>motif_enrichment.csv</code>	图 5D、表 5
细胞系异质性	<code>tables/cellline_effects.csv</code>	图 6
证据分级与 CI	<code>tables/evidence_matrix.csv</code>	表 3、图 7
Importance- ΔR^2 关系	<code>tables/importance_vs_delta_r2.csv</code>	图 7B